
Курс: Рекомендательные системы

Занятие 2: Базовые подходы

Подготовил: Лашинин Олег

Дата: 21.01.25

Обо мне



Образование: МФТИ + учусь в аспирантуре

Опыт работы: 5.5 года в Тинькофф

Сфера деятельности: R&D + проекты для прода


Публикации: 12 публикаций по RecSys на воркшопах + конференциях

План занятия

- Подзадачи рекомендаций
- Статистические персональные и неперсональные подходы
- Разбиение данных для экспериментов
- Что такое проблема холодного старта
- User- и item- расстояния
- Линейные модели (EASE, SLIM)
- Что такое popularity bias


Почему сегодня эта тема?

- Базовые подходы позволяют собрать быстрое и эффективное MVP
- Узнаем общепринятые подходы




Подзадачі рекомендацій


Какие подзадачи вообще есть?



Какие подзадачи вообще есть?



Какие подзадачи вообще есть?



Статистические персональные и неперсональные подходы


Три важных подхода к user2item

Рекомендуем (персонально)

Популярное

Новое

Три важных подхода к user2item



Три важных подхода к user2item

Мои клипы
Для вас
Подписки
Опубликовать

ЧЕСТНО, СТОК

ЧЕСТНО, СТОК!

28 апр в 23:45

Подписаться

Гении офроуда

63 222

431

21 188

18M

Приложение VK Клипы

Создавайте и смотрите короткие видео в удобном вертикальном формате

Загрузите в App Store

СКАЧАТЬ ИЗ Google Play

Доступно в RuStore

Тренды

#впечатлето2023

1,8М просмотров

#ДачныйСтиль

1,6М просмотров

#ДизайнБуквально

1,2М просмотров

#ФотоИзШкафа

3,1М просмотров

#ЭтоМойГород

2,2М просмотров

#ОтпускаюКамеру

2,4М просмотров

11

Три важных подхода к user2item

The screenshot displays the VK Video interface. On the left is a sidebar with navigation options: 'Для вас' (For you), 'Тренды' (Trends), 'Трансляции' (Streams), 'Спорт' (Sports), 'Киберспорт и игры' (Esports and games), and 'Фильмы' (Movies). The main content area features a search bar at the top with the text 'Поиск видео'. Below it are category tabs: 'Все' (All), 'Интервью и шоу' (Interviews and shows), 'Тревел' (Travel), 'Технологии' (Technology), 'Музыка' (Music), 'Культура' (Culture), 'Еда' (Food), and 'Здор' (Health). Two video thumbnails are visible:

- Left video:** A blue thumbnail titled 'Мечтаем ли мы об AGI? Сценарии, возможности и ожидания' (Do we dream of AGI? Scenarios, possibilities and expectations) by Сергей Николенко (Sergey Nikolenko), an author and professor at the MADE Academy. It is part of the 'education' series and has a duration of 1:02:34. The post is from VK Team, has 321 views, and was posted 1 month ago.
- Right video:** A thumbnail titled 'ПВН. #4 Илья Соболев x Стас Костюшкин x Денис Дорохов x...' (PWN. #4 Ilya Sobolev x Stas Kostyushkin x Denis Dorokhov x...) from LABELCOM. It features a collage of faces and a red banner with the text 'ПЛОХИЕ ВЫДУМАННЫЕ НОВОСТИ' (Bad fake news). It has 9.5 million views and was posted 3 months ago.

Три важных подхода к user2item

Яндекс Музыка

Главное • Подкасты и книги Детям Потоки Коллекция

🔍

Главное

ВСЁ НАСТРОЕНИЯ И ЖАНРЫ НОВЫЕ РЕЛИЗЫ ЧАРТ ПОДБОРКИ НЕЙРОМУЗЫКА

▶ Моя волна

⌵ Настроить

Премьера

Премьера •
Открывает вам главные новинки

04.03
СУПЕРЛОНЧ

Суперлонч
Топ премьер за уик-энд



Дежавю

Дежавю
Знакомит с тем, что вы ещё не слушали



Плейлист дня

Плейлист дня
Звучит по-вашему каждый день


Три важных подхода к user2item



Три важных подхода к user2item



Три важных подхода к user2item



Новое + Популярное = Тренды

Популярное – часто есть в интерфейсах

Рекомендуем

Важно: людям нужны не только персональные рекомендации, но также подборки «новых» и «популярных»

Популярность

User_id	Item_id	Timestamp	label
1	2	124	0
2	3	2512	0
1	1	12	1
3	1	1	1

Что такое популярность айтема?



Популярность




User_id	Item_id	Timestamp	label
1	2	124	0
2	3	2512	0
1	1	12	1
3	1	1	1

Что такое популярность айтема?

$$P(i) = \frac{\text{\# интеракций с айтемом } i}{\text{размер датасета}}$$


Популярность по времени

$$P(i, t) = \frac{\# \text{ взаимодействий с айтемом } i}{\text{размер датасета}} \mid t > \text{now()} - t_i$$




Popularity	HR@5	HR@10	NDCG@5	NDCG@10
MostPop	0.0304	0.0462	0.0198	0.0248
RecentPop	0.0530	0.0845	0.0338	0.0440
DecayPop	0.0532	0.0843	0.0341	0.0441

Что еще важно на этом графике?



Что еще важно на этом графике?




Item A уже не продается -> его нет смысла рекомендовать

Item C в t_2 не известен, модель не сможет его рекомендовать

Популярность как временной ряд

Два айтема и их популярность



История

Как еще можно отсортировать айтемы?

User_id	Item_id	Timestamp	label
1	2	124	0
2	3	2512	0
1	1	12	1
3	1	1	1
4	2	23424	1



Как еще можно отсортировать айтемы?

По Click through rate (CTR)!

User_id	Item_id	Timestamp	label
1	2	124	0
2	3	2512	0
1	1	12	1
3	1	1	1
4	2	23424	1

Item_id	views	clicks	CTR
2	2	1	0.5
3	1	0	0
1	2	2	1




Какие еще проблемы?

Популярность: что надо запомнить

- 1) Можно считать как долю интеракций по каждому айтому
- 2) Меняется со временем, надо учитывать
- 3) У некоторых айтемов падает до 0 со временем
- 4) В литературе: Pop, MostPop, Popular, TopPop, Top
- 5) Рекомендации популярных – часто могут давать «релевантные» рекомендации. Почему?




Популярность бывает персональная



$$UP(u, i, t_k) = \frac{\# \text{ взаимодействий } (u, i)}{\text{размер датасета}} \mid t > \text{now()} - t_k$$

Как объединить TopPersonal + Pop?




$$UP(u, i, t_k) = \frac{\# \text{ взаимодействий } (u, i)}{\text{размер датасета}} \mid t > \text{now()} - t_k$$

$$P(i, t) = \frac{\# \text{ взаимодействий с айтемом } i}{\text{размер датасета}} \mid t > \text{now()} - t_i$$



Как объединить TopPersonal + Pop?



$$UP(u, i, t_k) = \frac{\# \text{ интеракций } (u, i)}{\text{размер датасета}} \mid t > \text{now()} - t_k$$

$$P(i, t) = \frac{\# \text{ интеракций с айтемом } i}{\text{размер датасета}} \mid t > \text{now()} - t_i$$

$$\text{TopPersonal}(u, i, t) = (\#(u, i) + \frac{\# \text{ интеракций с айтемом } i}{\text{размер датасета}}) \mid t > \text{now()} - t_i$$

Разбиение данных для экспериментов

Как разбить данные для экспериментов?

	user_id	item_id	timestamp
0	38	89	92
1	68	32	94
2	9	76	78
3	75	53	47
4	30	48	64
...	...	...	...
95	63	48	13
96	57	50	55
97	47	90	59
98	82	66	93
99	44	92	99



Есть 4 основных способа

Leave One Last		Temporal Split		Random Split	User Split
Item	Basket/Session	User-based	Global		




Figure 3: Train/test with leave-one-out split




Figure 1: Train/test in practical systems, where t_c indicates the current time point.




Fig. 1. Temporal global split v.s. Temporal user split/Leave one last



Также есть симуляции + движущееся окно

- Collection: 88 papers in RecSys conferences (2020 – 2022)


No. papers	Percentage	Train/test split	Global timeline?
30	34%	Random split	No
22	25%	Leave-one-out	No
17	19.5%	Single time point	Partially
15	17%	Simulation-based online	Yes
4	4.5%	Sliding window	Yes

В индустрии почти наверно все используют single time point, но это не так в академии

Что такое оффлайн эксперимент?



Персональные рекомендации



Действия пользователя в тесте


Подробнее про это в следующие
разы

Для оффлайн эксперимента нужно выбрать метрику для оптимизации


RECALL@10_new	0.157	0.180	0.196	0.200	0.199	0.192	0.209	0.198	0.181	0.173
RECALL@25_new	0.255	0.317	0.330	0.339	0.320	0.322	0.345	0.339	0.307	0.302
RECALL@50_new	0.374	0.446	0.446	0.462	0.454	0.447	0.473	0.461	0.420	0.420
PRECISION@10_new	0.041	0.046	0.048	0.049	0.048	0.046	0.049	0.049	0.043	0.041
PRECISION@25_new	0.027	0.032	0.033	0.034	0.032	0.032	0.034	0.033	0.030	0.030
PRECISION@50_new	0.019	0.023	0.023	0.023	0.023	0.023	0.024	0.023	0.021	0.021
NOVELTY@10_new	0.273	0.299	0.352	0.331	0.369	0.345	0.338	0.372	0.334	0.342
NOVELTY@25_new	0.301	0.327	0.380	0.362	0.386	0.375	0.369	0.392	0.361	0.370
NOVELTY@50_new	0.327	0.353	0.406	0.387	0.406	0.401	0.396	0.412	0.385	0.395
MNAP@10_new	0.062	0.075	0.077	0.079	0.082	0.073	0.082	0.085	0.069	0.067
MNAP@25_new	0.070	0.086	0.089	0.090	0.092	0.083	0.093	0.097	0.079	0.078
MNAP@50_new	0.075	0.092	0.094	0.096	0.098	0.089	0.099	0.102	0.084	0.083
MIL_D@10_new	0.535	0.700	0.880	0.797	0.912	0.803	0.819	0.884	0.781	0.778



Холодный старт по user/item



Холодный старт по user/item




1) Включать ли пользователя в метрики? **Зависит от ситуации**

2) Выкинуть ли новый айтем из теста? **Лучше нет**

Регистрация

Про фильтрацию айтемов



Но когда вы отфильтруете, вы не предскажете новый айтем!

Холодный старт

«Нужно сделать предсказания, но нет истории взаимодействий»

Способы:

1. Популярные айтемы
2. Построить модель на соцдеме или других данных
3. Провести онбординг, собрать данные и на них делать предикты

UserKNN, ItemKNN

“Collaborative filtering simply means that people collaborate to help one another perform filtering by recording their reactions to documents they read”


CF – это идея (подход), не конкретный алгоритм!




(a) Electronic mail overload



(b) Using distribution lists



(c) Conventional filtering



(d) Collaborative filtering

UserKNN, ItemKNN

Items

1				1				
				1		1		
1		1					1	1
					1			
	1							
		1						1
					1	1		
1		1					1	1?

Users

Items

1	1?		1				
			1		1		
1	1					1	1
				1			
	1						
		1					1
				1	1		
1	1					1	

Users

1 – было взаимодействие, отсутствие – нет взаимодействия

UserKNN

Items

	1				1				
					1		1		
	1		1					1	1
						1			
1		1							
			1						1
					1	1			
1		1					1	1?	

Users

$$\hat{r}_{ui} = \frac{1}{|\mathcal{N}_i(u)|} \sum_{v \in \mathcal{N}_i(u)} r_{vi}$$

1 – было взаимодействие, отсутствие – нет взаимодействия

UserKNN: как определить $N_i(u)$?

	Items								
	1				1				
					1		1		
	1		1					1	1
						1			
Users		1							
				1					1
					1	1			
	1		1					1	1?

$$\hat{r}_{ui} = \frac{1}{|\mathcal{N}_i(u)|} \sum_{v \in \mathcal{N}_i(u)} r_{vi}$$

Table 1 OTUs Expression of Binary Instances i and j

$j \backslash i$	1 (Presence)	0 (Absence)	Sum
1 (Presence)	$a = i \bullet j$	$b = \bar{i} \bullet j$	$a+b$
0 (Absence)	$c = i \bullet \bar{j}$	$d = \bar{i} \bullet \bar{j}$	$c+d$
Sum	$a+c$	$b+d$	$n=a+b+c+d$

$$S_{COSINE} = \frac{a}{\sqrt{(a+b)(a+c)}}^2$$

1 – было взаимодействие, отсутствие – нет взаимодействия

Есть 76+ методов для поиска соседей

A Survey of Binary Similarity and Distance Measures

Table 2 Definitions of Measures for binary data

$$S_{JACCARD} = \frac{a}{a+b+c} \tag{1}$$

$$S_{DICE} = \frac{2a}{2a+b+c} \tag{2}$$

$$S_{CZEKANOWSKI} = \frac{2a}{2a+b+c} \tag{3}$$

$$S_{3W-JACCARD} = \frac{3a}{3a+b+c} \tag{4}$$

$$S_{NEI\&LI} = \frac{2a}{(a+b)+(a+c)} \tag{5}$$

$$S_{SOKAL\&SNEATH-I} = \frac{a}{a+2b+2c} \tag{6}$$

$$S_{SOKAL\&MICHENER} = \frac{a+d}{a+b+c+d} \tag{7}$$

$$S_{SOKAL\&SNEATH-II} = \frac{2(a+d)}{2a+b+c+2d} \tag{8}$$

$$S_{ROGER\&TANIMOTO} = \frac{a+d}{a+2(b+c)+d} \tag{9}$$

$$S_{FAITH} = \frac{a+0.5d}{a+b+c+d} \tag{10}$$

$$S_{GOWER\&LEGENDRE} = \frac{a+d}{a+0.5(b+c)+d} \tag{11}$$

Seung-Seok Choi, Sung-Hyuk Cha, Charles C. Tappert
 Department of Computer Science, Pace University
 New York, US

$$D_{VARI} = \frac{(b+c)}{4(a+b+c+d)} \tag{23}$$

$$D_{SIZEDIFFERENCE} = \frac{(b+c)^2}{(a+b+c+d)^2} \tag{24}$$

$$D_{SHAPEDIFFERENCE} = \frac{n(b+c)-(b-c)^2}{(a+b+c+d)^2} \tag{25}$$

$$D_{PATTERNDIFFERENCE} = \frac{4bc}{(a+b+c+d)^2} \tag{26}$$

$$D_{LANCE\&WILLIAMS} = \frac{b+c}{(2a+b+c)} \tag{27}$$

$$D_{BRAY\&CURTIS} = \frac{b+c}{(2a+b+c)} \tag{28}$$

$$D_{HELLINGER} = 2\sqrt{1-\frac{a}{\sqrt{(a+b)(a+c)}}} \tag{29}$$

$$D_{CHORD} = \sqrt{2\left(1-\frac{a}{\sqrt{(a+b)(a+c)}}\right)} \tag{30}$$

$$S_{COSINE} = \frac{a}{\sqrt{(a+b)(a+c)}} \tag{31}$$

Часто используется Jaccard, Dice, Cosine

$$\hat{r}_{ui} = \frac{1}{|\mathcal{N}_i(u)|} \sum_{v \in \mathcal{N}_i(u)} r_{vi}$$

Table 1 OTUs Expression of Binary Instances i and j

$j \backslash i$	1 (Presence)	0 (Absence)	Sum
1 (Presence)	$a = i \bullet j$	$b = \bar{i} \bullet j$	$a+b$
0 (Absence)	$c = i \bullet \bar{j}$	$d = \bar{i} \bullet \bar{j}$	$c+d$
Sum	$a+c$	$b+d$	$n=a+b+c+d$

Гиперпараметры userKNN

$$s_{ij} = \frac{\mathbf{r}_i \cdot \mathbf{r}_j}{\|\mathbf{r}_i\| \|\mathbf{r}_j\| + h}$$

1) Число соседей

2) h – сглаживающий параметр

3) Метрика близости

ItemKNN

		Items							
Users		1 ↔ 1?		1					
				1		1			
		1 ↔ 1					1	1	
					1				
			1						
				1				1	
					1	1			
		1 ↔ 1					1		

Пример: почти все к пельменям покупают кетчуп.

Пользователь уже купил Пельмени, возможно ему будет нужен кетчуп

$$\hat{r}_{ui} = \frac{\sum_{j \in \mathcal{N}_u(i)} w_{ij} r_{uj}}{\sum_{j \in \mathcal{N}_u(i)} |w_{ij}|}$$

ItemKNN/ item2item модели

USERS * ITEMS

1				1				
				1		1		
1		1					1	1
					1			
	1							
			1					1
					1	1		
1		1					1	

X

ITEMS * ITEMS

•	•	•		•	•	•	•	•
•	•	•	•	•	•	•	•	•
•	•	•	•	•	•	•	•	•
•	•	•	•	•	•	•	•	•
•	•	•		•	•	•	•	•
•	•	•	•	•	•	•	•	•
•	•	•	•	•	•	•	•	•
•	•	•	•	•	•	•	•	•
•	•	•	•	•	•	•	•	•

USERS * ITEMS

.	.	.	.	.	.	.	.	.
				1		1		
1		1					1	1
					1			
	1							
			1					1
					1	1		
1		1					1	

$$\hat{r}_{ui} = \frac{\sum_{j \in \mathcal{N}_u(i)} w_{ij} r_{uj}}{\sum_{j \in \mathcal{N}_u(i)} |w_{ij}|}$$

$$r(u, 3) = 1 * \text{sim}(3, 0) + 1 * \text{sim}(3, 4)$$

Матрица схожести айтемов

User/item сравнение

Table 2.2 The space and time complexity of user-based and item-based neighborhood methods, as a function of the maximum number of ratings per user $p = \max_u |\mathcal{J}_u|$, the maximum number of ratings per item $q = \max_i |\mathcal{U}_i|$, and the maximum number of neighbors used in the rating predictions k

	Space	Time	
		Training	Online
User-based	$O(\mathcal{U} ^2)$	$O(\mathcal{U} ^2 p)$	$O(\mathcal{J} k)$
Item-based	$O(\mathcal{J} ^2)$	$O(\mathcal{J} ^2 q)$	$O(\mathcal{J} k)$

Нужно ли это кому-то сейчас?

Top-N Recommendation Algorithms: A Quest for the State-of-the-Art

VITO WALTER ANELLI, Politecnico di Bari, Italy

ALEJANDRO BELLOGÍN, Universidad Autónoma de Madrid, Spain

TOMMASO DI NOIA, Politecnico di Bari, Italy

DIETMAR JANNACH, University of Klagenfurt, Austria

CLAUDIO POMO, Politecnico di Bari, Italy

Rank	Algorithm	Count
1	EASE ^R	185
2	RP ³ β	169
3	SLIM	160
4	UserKNN	154
5	MF2020	115
6	ItemKNN	99
7	MultiVAE	92
8	iALS	90
9	NeuMF	61
10	BPRMF	45
11	MostPop	18
12	Random	0

(a) Overall

Нужно ли это кому-то сейчас?

Are We Really Making Much Progress? A Worrying Analysis of Recent Neural Recommendation Approaches

Maurizio Ferrari Dacrema
Politecnico di Milano, Italy
maurizio.ferrari@polimi.it

Paolo Cremonesi
Politecnico di Milano, Italy
paolo.cremonesi@polimi.it

Dietmar Jannach
University of Klagenfurt, Austria
dietmar.jannach@aau.at

Table 6: Experimental results for NCF.

	Pinterest			
	HR@5	NDCG@5	HR@10	NDCG@10
TopPopular	0.1663	0.1065	0.2744	0.1412
UserKNN	0.7001	0.5033	0.8610	0.5557
ItemKNN	0.7100	0.5092	0.8744	0.5629
$P^3\alpha$	0.7008	0.5018	0.8667	0.5559
$RP^3\beta$	0.7105	0.5116	0.8740	0.5650
NeuMF	0.7024	0.4983	0.8719	0.5536
	Movielens 1M			
	HR@5	NDCG@5	HR@10	NDCG@10
TopPopular	0.3043	0.2062	0.4531	0.2542
UserKNN	0.4916	0.3328	0.6705	0.3908
ItemKNN	0.4829	0.3328	0.6596	0.3900
$P^3\alpha$	0.4811	0.3331	0.6464	0.3867
$RP^3\beta$	0.4922	0.3409	0.6715	0.3991
NeuMF	0.5486	0.3840	0.7120	0.4369
SLIM	0.5589	0.3961	0.7161	0.4470

Линейные модели (EASE, SLIM)

Вернемся к таблице с рейтингом моделей

Rank	Algorithm	Count	
1	EASE ^R	185	Разберем сегодня
2	RP ³ β	169	Разберем дальше
3	SLIM	160	Разберем сегодня
4	UserKNN	154	Разобрали
5	MF2020	115	Под вопросом
6	ItemKNN	99	Разобрали
7	MultiVAE	92	Разберем дальше
8	iALS	90	Разберем дальше
9	NeuMF	61	Разберем дальше
10	BPRMF	45	Разберем дальше
11	MostPop	18	Разобрали
12	Random	0	np.random.choice

(a) Overall

SLIM: Sparse Linear Model (2011)

USERS * ITEMS

1				1				
				1		1		
1		1					1	1
					1			
	1							
			1					1
					1	1		
1		1					1	

X

ITEMS * ITEMS

0	.	.		.	.	.	.	.
.	0	.		.	.	.	.	.
.	.	0		.	.	.	.	.
.	.	.	0	.	.	.	.	.
.	.	.		0	.	.	.	.
.	.	.		.	0	.	.	.
.	.	.		.	.	0	.	.
.	.	.		.	.	.	0	.
.	.	.		.	.	.	.	0

=

USERS * ITEMS

1	.	.		.	.	.	.	.
				1		1		
1		1					1	1
					1			
	1							
			1					1
					1	1		
1		1					1	

$$\hat{r}_{ui} = \mathbf{r}_u \mathbf{w}_i^\top$$

minimize _{W} $\frac{1}{2} \|R - RW\|_F^2 + \frac{\beta}{2} \|W\|_F^2 + \lambda \|W\|_1$
 subject to $W \geq 0$
 $\text{diag}(W) = 0.$

SLIM: Sparse Linear Model (2011)

Are We Really Making Much Progress? A Worrying Analysis of Recent Neural Recommendation Approaches

Maurizio Ferrari Dacrema
Politecnico di Milano, Italy
maurizio.ferrari@polimi.it

Paolo Cremonesi
Politecnico di Milano, Italy
paolo.cremonesi@polimi.it

Dietmar Jannach
University of Klagenfurt, Austria
dietmar.jannach@aau.at

Table 6: Experimental results for NCF.

	Pinterest			
	HR@5	NDCG@5	HR@10	NDCG@10
TopPopular	0.1663	0.1065	0.2744	0.1412
UserKNN	0.7001	0.5033	0.8610	0.5557
ItemKNN	0.7100	0.5092	0.8744	0.5629
$P^3\alpha$	0.7008	0.5018	0.8667	0.5559
$RP^3\beta$	0.7105	0.5116	0.8740	0.5650
NeuMF	0.7024	0.4983	0.8719	0.5536
	Movielens 1M			
	HR@5	NDCG@5	HR@10	NDCG@10
TopPopular	0.3043	0.2062	0.4531	0.2542
UserKNN	0.4916	0.3328	0.6705	0.3908
ItemKNN	0.4829	0.3328	0.6596	0.3900
$P^3\alpha$	0.4811	0.3331	0.6464	0.3867
$RP^3\beta$	0.4922	0.3409	0.6715	0.3991
NeuMF	0.5486	0.3840	0.7120	0.4369
SLIM	0.5589	0.3961	0.7161	0.4470

Popularity bias на примере SLIM

USERS * ITEMS

1				1				
				1		1		
1		1					1	1
					1			
	1							
			1					1
					1	1		
1		1					1	

X

ITEMS * ITEMS

0	.	.	.	.	.	.	.	.
.	0	.	.	.	.	.	.	.
.	.	0	.	.	.	.	.	.
.	.	.	0	.	.	.	.	.
.	.	.	.	0	.	.	.	.
.	.	.	.	.	0	.	.	.
.	.	.	.	.	.	0	.	.
.	.	.	.	.	.	.	0	.
.	.	.	.	.	.	.	.	0

=

USERS * ITEMS

1			.	1				
			.	1		1		
1		1	.				1	1
			.		1			
	1		.					
			1					1
			.		1	1		
1		1	?				1	

$$\underset{W}{\text{minimize}} \quad \frac{1}{2} \|R - RW\|_F^2 + \frac{\beta}{2} \|W\|_F^2 + \lambda \|W\|_1$$

$$\text{subject to} \quad W \geq 0$$

$$\text{diag}(W) = 0.$$

Веса выучатся маленькими,
айтем будет редко
рекомендоваться

Popularity bias

Popularity bias – смещение в сторону рекомендаций популярных объектов (их преобладание в выдаче). Несколько фактов:

1. Смещение на популярные изначально есть в данных. Люди сами так ведут себя
2. Модель «рискует», рекомендуя менее популярные айтемы, идет против статистики
3. «Богатые богатеют, бедные беднеют»

Ключевая проблема с Popular Bias

USERS * ITEMS

1				1				
				1		1		
1		1	1	?			1	1
				1	1			
	1			1				
			1	1				1
				1	1	1		
1		1		1			1	

X

ITEMS * ITEMS

0	.	.	.	.	.	.	.	.
.	0	.	.	.	.	.	.	.
.	.	0	.	.	.	.	.	.
.	.	.	0	.	.	.	.	.
.	.	.	.	0	.	.	.	.
.	.	.	.	.	0	.	.	.
.	.	.	.	.	.	0	.	.
.	.	.	.	.	.	.	0	.
.	.	.	.	.	.	.	.	0

=

USERS * ITEMS

1				1				
				1		1		
1		1	1				1	1
				1	1			
	1			1				
				1				1
				1	1	1		
1		1		1			1	



Порекомендует ли модель айтем №4?

Ключевая проблема с Popular Bias

USERS * ITEMS

1				1				
				1		1		
1		1	1	?			1	1
				1	1			
	1			1				
			1	1				1
				1	1	1		
1		1		1			1	

X

ITEMS * ITEMS

0	.	.	.	.	.	.	.	.
.	0	.	.	.	.	.	.	.
.	.	0	.	.	.	.	.	.
.	.	.	0	.	.	.	.	.
.	.	.	.	0	.	.	.	.
.	.	.	.	.	0	.	.	.
.	.	.	.	.	.	0	.	.
.	.	.	.	.	.	.	0	.
.	.	.	.	.	.	.	.	0



=

USERS * ITEMS

1				1				
				1		1		
1		1	1				1	1
				1	1			
	1			1				
				1				1
				1	1	1		
1		1		1			1	

Но пользователь скорее всего осознанно
не провзаимодействовал с ним

Как залететь в рекомендации или проблемы начинающих авторов



Popularity bias форсирует не только система, но и люди.

Если автор контента стал делать плохой контент, он все равно имеет инерцию/лояльность в сознании подписчиков. Факт привычки



Если новый автор делает качественный контент, система может не поддерживать его, а люди по инерции смотреть популярные каналы

Почему нельзя рекомендовать только популярные?

Если нет трафика на непопулярный контент, его может становиться меньше. Притока новых поставщиков контента может быть меньше.

Но чем меньше такого трафика – тем меньше интересов людей вы покрываете

Позднее вернемся к этой проблеме



Анастасия Павловская – Удерживая таланты: как построить систему роста авторов и не уронить метрики

YfD • 213 views • 1 month ago

EASE (2019): топ-2* модель, которую надо знать

Embarrassingly Shallow Autoencoders for Sparse Data*

Harald Steck
Netflix
Los Gatos, California
hsteck@netflix.com

The predicted score $S_{u,j}$ for an item $j \in \mathcal{I}$ given a user $u \in \mathcal{U}$ is defined by the dot product

$$S_{uj} = X_{u,\cdot} \cdot B_{\cdot,j}, \quad (1)$$

where $X_{u,\cdot}$ refers to row u , and $B_{\cdot,j}$ to column j .

$$\begin{aligned} \min_B \quad & ||X - XB||_F^2 + \lambda \cdot ||B||_F^2 \\ \text{s.t.} \quad & \text{diag}(B) = 0 \end{aligned}$$

EASE

$$\begin{aligned} \underset{W}{\text{minimize}} \quad & \frac{1}{2} \|R - RW\|_F^2 + \frac{\beta}{2} \|W\|_F^2 + \lambda \|W\|_1 \\ \text{subject to} \quad & W \geq 0 \\ & \text{diag}(W) = 0. \end{aligned}$$

SLIM

EASE имеет решение в явном виде

Embarrassingly Shallow Autoencoders for Sparse Data*

Harald Steck
Netflix
Los Gatos, California
hsteck@netflix.com

$$\hat{P} \triangleq (X^T X + \lambda I)^{-1},$$

$$\hat{B}_{i,j} = \begin{cases} 0 & \text{if } i = j \\ -\frac{\hat{P}_{ij}}{\hat{P}_{jj}} & \text{otherwise.} \end{cases}$$

Доказательство
можете почитать в
статье

Преимущества EASE

- 1) Имеет решение в явном виде, не требует обучения по эпохам
- 2) Явное решение оптимально в смысле поставленной задачи
- 3) Можно один раз обучить матрицу B , и использовать ее на разных юзерах
- 4) Имеет всего один гиперпараметр
- 5) Устойчив к варьированию гиперпараметра (в отличие от SLIM). В целом 100 – хорошее значение
- 6) Улучшает качество при добавлении редких айтемов (!)
- 7) Если юзер сделал новую интеракцию – можем обновить рекомендации без дообучения
- 8) Может спокойно работать в онлайн при latency 50 мс под нагрузкой 200 rps с ~10к каталогом
- 9) Можно искать похожие айтемы через его матрицу взаимодействий

Результаты EASE

- 1) Наш коллега из Тинькофф занял ~20/2к мест в соревновании по recsys на Kaggle, где EASE была основной моделью, размер каталога ~90к айтемов
- 2) Я с коллегами выиграл (1/~20 место) хакатон по рекомендациям от Ленты, просто обучив EASE
- 3) Мы с коллегами заняли 2/~20 мест в хакатоне Цифровой Прорыв, обучив EASE

Недостатки EASE

- 1) $O(I^3)$ – сложность вычисления обратной матрицы. Убрать непопулярные айтемы. Используйте scipy!
- 1) Не учитывает последовательность данных
- 2) Не работает с негативными действиям от пользователя (просмотр без клика)

Результаты EASE

Revisiting the Performance of iALS on Item Recommendation Benchmarks

Steffen Rendle
Google
Mountain View, USA
srendle@google.com

Li Zhang
Google
Mountain View, USA
liqzhang@google.com

Walid Krichene
Google
Mountain View, USA
walidk@google.com

Yehuda Koren
Google
Haifa, Israel
yehuda@google.com

Table 2: Quality results on the ML20M and MSD benchmark sorted by Recall@20 scores.

Dataset	Method	Recall@20	Recall@50	NDCG@100	Result from
ML20M	RecVAE [25]	0.414	0.553	0.442	[25]
	H+Vamp (Gated) [14]	0.413	0.551	0.445	[14]
	RaCT [18]	0.403	0.543	0.434	[18]
	Mult-VAE [17]	0.395	0.537	0.426	[17]
	LambdaNet [4]	0.395	0.534	0.427	[25]
	iALS	0.395	0.532	0.425	our result
	EASE [26]	0.391	0.521	0.420	[26]
	CDAE [28]	0.391	0.523	0.418	[17]
	Mult-DAE [17]	0.387	0.524	0.419	[17]
	SLIM [19]	0.370	0.495	0.401	[17]
	iALS	0.363	0.502	0.393	prev. result [13]
	iALS	0.360	0.498	0.386	prev. result [17]
	WARP [27]	0.314	0.466	0.341	[25]
MSD	Popularity	0.162	0.235	0.191	[26]
	EASE [26]	0.333	0.428	0.389	[26]
	iALS	0.309	0.415	0.368	our result
	RecVAE [25]	0.276	0.374	0.326	[25]
	RaCT [18]	0.268	0.364	0.319	[18]
	Mult-VAE [17]	0.266	0.364	0.316	[17]
	Mult-DAE [17]	0.266	0.363	0.313	[17]
	LambdaNet [4]	0.259	0.355	0.308	[25]
	iALS	0.211	0.312	0.257	prev. result [17]
	WARP [27]	0.206	0.302	0.249	[25]
	CDAE [28]	0.188	0.283	0.237	[17]
	Popularity	0.043	0.068	0.058	[26]

У EASE есть развитие

- 1) $O(I^3)$ – сложность вычисления обратной матрицы. Есть модификации SARSA, ELSA, там лучше
- 2) Не учитывает последовательность данных. Есть модификация SLIST
- 3) Не работает с негативными действиям от пользователя (просмотр без клика)

Спасибо за
внимание