

Лекция 4. ALS, NCF.



Миша Печатов

План

- ➔ Задача матричной факторизации
- ➔ explicit/implicit feedback
- ➔ ALS
- ➔ Ранжирующие функции
- ➔ NCF




Матричная факторизация

Матричная факторизация

Матричная факторизация

		item				
user		1		1	1	
			1	1		1
			1		1	
		1		1		
		1	1	1		
					1	1
		1	1		1	
		n x m				

Матричная факторизация



Матричная факторизация

		item							factor			
user	1		1	1			=	user	0.1	0.3	0.4	
		1	1		1				0.3	-0.5	-0.2	
		1		1					0.1	-0.2	-0.3	
	1		1						0.7	0.5	-0.4	
	1	1	1						0.5	0.6	0.9	
				1	1				-0.9	-0.7	0.2	
	1	1		1					0.4	0.2	0.6	
n x m							n x k					

		item					
x		0.1	0.3	0.4	0.5	0.6	factor
		0.1	0.2	0.3	0.1	-0.2	
		0.9	-0.7	0.2	0.4	0.2	
		k x m					

$$\sum (r_{i,j} - x_u^T \cdot y_i)^2 + \lambda (\|x_u\|^2 + \|y_i\|^2)$$

Проблемы MF подходов

Проблемы MF подходов

- Холодный старт
- Вычислительная сложность/масштабируемость
- Учитывает только счетчики взаимодействий(рейтинги)
- Небольшое разнообразие

Фидбэк пользователя

Implicit vs explicit

Фидбэк пользователя

Implicit vs explicit

- Клик
- Лайк
- Досмотр видео до конца
- Рейтинг
- Покупка
- Добавление в корзину
- Просмотр поста в ленте
- Добавление в избранное

Фидбэк пользователя

Implicit vs explicit

- Клик
- Лайк
- Досмотр видео до конца
- Рейтинг
- Покупка
- Добавление в корзину
- Просмотр поста в ленте
- Добавление в избранное

Фидбэк пользователя

Implicit vs explicit

- Клик
- Лайк
- Досмотр видео до конца
- Рейтинг
- Покупка
- Добавление в корзину
- Просмотр поста в ленте
- Добавление в избранное

Фидбэк пользователя

Implicit vs explicit

- Клик
- Лайк
- Досмотр видео до конца
- Рейтинг
- Покупка
- Добавление в корзину
- Просмотр поста в ленте
- Добавление в избранное

Свойства **неявного** фидбэка:

1. Отсутствуют негативы
2. Довольно шумный
3. Значение показывает уверенность,
а не предпочтения
4. Нужны специальные метрики для оценки

Alternating Least Squares

ALS

	item				
user	1		1	1	
		1	1		1
		1		1	
	1		1		
	1	1	1		
				1	1
	1	1		1	
n x m					

=

	factor		
user	0.1	0.3	0.4
	0.3	-0.5	-0.2
	0.1	-0.2	-0.3
	0.7	0.5	-0.4
	0.5	0.6	0.9
	-0.9	-0.7	0.2
	0.4	0.2	0.6
n x k			

x

	item				
	0.1	0.3	0.4	0.5	0.6
	0.1	0.2	0.3	0.1	-0.2
	0.9	-0.7	0.2	0.4	0.2
k x m					

$$\sum (r_{i,j} - x_u^T \cdot y_i)^2 + \lambda (\|x_u\|^2 + \|y_i\|^2)$$

ALS

	item				
user	1		1	1	
		1	1		1
		1		1	
	1		1		
	1	1	1		
				1	1
	1	1		1	
n x m					

=

	factor		
user	0.1	0.3	0.4
	0.3	-0.5	-0.2
	0.1	-0.2	-0.3
	0.7	0.5	-0.4
	0.5	0.6	0.9
	-0.9	-0.7	0.2
	0.4	0.2	0.6
n x k			

x

	item				
factor	0.1	0.3	0.4	0.5	0.6
	0.1	0.2	0.3	0.1	-0.2
	0.9	-0.7	0.2	0.4	0.2
k x m					

$$\sum (r_{i,j} - x_u^T \cdot y_i)^2 + \lambda (\|x_u\|^2 + \|y_i\|^2)$$

ALS

		item				
user	1		1	1		
		1	1			1
		1		1		
	1		1			
	1	1	1			
				1	1	
	1	1		1		
		n x m				

=

		factor		
user	1	0.1	0.3	0.4
	2	0.3	-0.5	-0.2
	3	0.1	-0.2	-0.3
	4	0.7	0.5	-0.4
	5	0.5	0.6	0.9
	6	-0.9	-0.7	0.2
	7	0.4	0.2	0.6
		n x k		

x

		item				
	1	0.1	0.3	0.4	0.5	0.6
	2	0.1	0.2	0.3	0.1	-0.2
	3	0.9	-0.7	0.2	0.4	0.2
		k x m				

$$\sum (r_{i,j} - x_u^T \cdot y_i)^2 + \lambda (\|x_u\|^2 + \|y_i\|^2)$$

ALS

	item				
user	1		1	1	
		1	1		1
		1		1	
	1		1		
	1	1	1		
				1	1
	1	1		1	
n x m					

=

	factor		
user	0.11	0.32	0.4
	0.33	-0.5	-0.2
	0.11	-0.2	-0.3
	0.71	0.52	-0.4
	0.57	0.62	0.99
	-0.9	-0.7	0.22
	0.42	0.21	0.67
n x k			

x

	item				
factor	0.1	0.3	0.4	0.5	0.6
	0.1	0.2	0.3	0.1	-0.2
	0.9	-0.7	0.2	0.4	0.2
k x m					

$$\sum (r_{i,j} - x_u^T \cdot y_i)^2 + \lambda (\|x_u\|^2 + \|y_i\|^2)$$

ALS

	item				
user	1		1	1	
		1	1		1
		1		1	
	1		1		
	1	1	1		
				1	1
	1	1		1	
n x m					

=

	factor		
user	0.11	0.32	0.4
	0.33	-0.5	-0.2
	0.11	-0.2	-0.3
	0.71	0.52	-0.4
	0.57	0.62	0.99
	-0.9	-0.7	0.22
	0.42	0.21	0.67
n x k			

x

	item				
	0.1	0.3	0.4	0.5	0.6
	0.1	0.2	0.3	0.1	-0.2
	0.9	-0.7	0.2	0.4	0.2
k x m					
					factor

$$\sum (r_{i,j} - x_u^T \cdot y_i)^2 + \lambda (\|x_u\|^2 + \|y_i\|^2)$$

ALS

	item				
user	1		1	1	
		1	1		1
		1		1	
	1		1		
	1	1	1		
				1	1
	1	1		1	
n x m					

=

	factor		
user	0.11	0.32	0.4
	0.33	-0.5	-0.2
	0.11	-0.2	-0.3
	0.71	0.52	-0.4
	0.57	0.62	0.99
	-0.9	-0.7	0.22
	0.42	0.21	0.67
n x k			

x

	item				
factor	0.12	0.33	0.42	0.58	0.61
	0.13	0.24	0.36	0.12	-0.2
	0.94	-0.7	0.21	0.42	0.26
k x m					

$$\sum (r_{i,j} - x_u^T \cdot y_i)^2 + \lambda (\|x_u\|^2 + \|y_i\|^2)$$

Implicit ALS

Implicit ALS

Collaborative filtering for implicit feedback datasets

[Y Hu](#), [Y Koren](#), [C Volinsky](#)

2008 Eighth IEEE international conference on data mining, 2008 · [ieeexplore.ieee.org](#)

A common task of recommender systems is to improve customer experience through personalized recommendations based on prior implicit feedback. These systems passively track different sorts of user behavior, such as purchase history, watching habits and browsing activity, in order to model user preferences. Unlike the much more extensively researched explicit feedback, we do not have any direct input from the users regarding their preferences. In particular, we lack substantial evidence on which products consumer

РАЗВЕРНУТЬ ▾

☆ Сохранить 99 Цитировать Цитируется: 4343 Похожие статьи Все версии статьи (14)

- Используется в проде во всех крупных компаниях
- Де-факто является индустриальным стандартом
- Отлично параллелится и показывает хорошие метрики

Implicit ALS

$$\min_{x_{\star}, y_{\star}} \sum_{r_{u,i} \text{ is known}} (r_{ui} - x_u^T y_i)^2 + \lambda(\|x_u\|^2 + \|y_i\|^2)$$

Implicit ALS

$$p_{ui} = \begin{cases} 1 & r_{ui} > 0 \\ 0 & r_{ui} = 0 \end{cases}$$

$$\min_{x_{\star}, y_{\star}} \sum_{r_{u,i} \text{ is known}} (r_{ui} - x_u^T y_i)^2 + \lambda(\|x_u\|^2 + \|y_i\|^2)$$

Implicit ALS

$$p_{ui} = \begin{cases} 1 & r_{ui} > 0 \\ 0 & r_{ui} = 0 \end{cases} \quad c_{ui} = 1 + \alpha r_{ui}$$

$$\min_{x_{\star}, y_{\star}} \sum_{r_{u,i} \text{ is known}} (r_{ui} - x_u^T y_i)^2 + \lambda(\|x_u\|^2 + \|y_i\|^2)$$

Implicit ALS

$$p_{ui} = \begin{cases} 1 & r_{ui} > 0 \\ 0 & r_{ui} = 0 \end{cases} \quad c_{ui} = 1 + \alpha r_{ui}$$

$$\min_{x_{\star}, y_{\star}} \sum_{r_{u,i} \text{ is known}} (r_{ui} - x_u^T y_i)^2 + \lambda (\|x_u\|^2 + \|y_i\|^2)$$

$$\min_{x_{\star}, y_{\star}} \sum_{u,i} c_{ui} (p_{ui} - x_u^T y_i)^2 + \lambda \left(\sum_u \|x_u\|^2 + \sum_i \|y_i\|^2 \right)$$

Implicit ALS

		item		
user	1		1	1
		1	1	
		1		1
	1		1	
	1	1	1	
			1	1
	1	1		
		n x m		

=

		factor	
user	0.1	0.3	0.4
	0.3	-0.5	-0.2
	0.1	-0.2	-0.3
	0.7	0.5	-0.4
	0.5	0.6	0.9
	-0.9	-0.7	0.2
	0.4	0.2	0.6
		n x k	

x

item					factor
0.1	0.3	0.4	0.5	0.6	
0.1	0.2	0.3	0.1	-0.2	
0.9	-0.7	0.2	0.4	0.2	
k x m					

$$\min_{x_{\star}, y_{\star}} \sum_{r_{u,i} \text{ is known}} (r_{ui} - x_u^T y_i)^2 + \lambda (\|x_u\|^2 + \|y_i\|^2)$$

Implicit ALS

		item			
user	1		1	1	
		1	1		1
		1		1	
	1		1		
	1	1	1		
				1	1
	1	1		1	
		n x m			

=

		factor		
user	0.1	0.3	0.4	
	0.3	-0.5	-0.2	
	0.1	-0.2	-0.3	
	0.7	0.5	-0.4	
	0.5	0.6	0.9	
	-0.9	-0.7	0.2	
	0.4	0.2	0.6	
		n x k		

x

item					factor
0.1	0.3	0.4	0.5	0.6	
0.1	0.2	0.3	0.1	-0.2	
0.9	-0.7	0.2	0.4	0.2	
k x m					

$$\min_{x_{\star}, y_{\star}} \sum_{r_{u,i} \text{ is known}} (r_{ui} - x_u^T y_i)^2 + \lambda (\|x_u\|^2 + \|y_i\|^2)$$
$$\min_{x_{\star}, y_{\star}} \sum_{u,i} c_{ui} (p_{ui} - x_u^T y_i)^2 + \lambda \left(\sum_u \|x_u\|^2 + \sum_i \|y_i\|^2 \right)$$

Implicit ALS

$$\min_{x_{\star}, y_{\star}} \sum_{u,i} c_{ui} (p_{ui} - x_u^T y_i)^2 + \lambda \left(\sum_u \|x_u\|^2 + \sum_i \|y_i\|^2 \right)$$

Implicit ALS

$$\min_{x_{\star}, y_{\star}} \sum_{u,i} c_{ui} (p_{ui} - x_u^T y_i)^2 + \lambda \left(\sum_u \|x_u\|^2 + \sum_i \|y_i\|^2 \right)$$

Implicit ALS

$$\min_{x_*, y_*} \sum_{u,i} c_{ui} (p_{ui} - x_u^T y_i)^2 + \lambda \left(\sum_u \|x_u\|^2 + \sum_i \|y_i\|^2 \right)$$

$$x_u = (Y^T C^u Y + \lambda I)^{-1} Y^T C^u p(u)$$

Implicit ALS

$$\min_{x_\star, y_\star} \sum_{u,i} c_{ui} (p_{ui} - x_u^T y_i)^2 + \lambda \left(\sum_u \|x_u\|^2 + \sum_i \|y_i\|^2 \right)$$

$$x_u = (Y^T C^u Y + \lambda I)^{-1} Y^T C^u p(u)$$

Implicit ALS

$$\min_{x_\star, y_\star} \sum_{u,i} c_{ui} (p_{ui} - x_u^T y_i)^2 + \lambda \left(\sum_u \|x_u\|^2 + \sum_i \|y_i\|^2 \right)$$

$$x_u = (Y^T C^u Y + \lambda I)^{-1} Y^T C^u p(u)$$

$$y_i = (X^T C^i X + \lambda I)^{-1} X^T C^i p(i)$$

Implicit ALS

$$\min_{x_*, y_*} \sum_{u,i} c_{ui} (p_{ui} - x_u^T y_i)^2 + \lambda \left(\sum_u \|x_u\|^2 + \sum_i \|y_i\|^2 \right)$$

$$x_u = (Y^T C^u Y + \lambda I)^{-1} Y^T C^u p(u)$$

$$y_i = (X^T C^i X + \lambda I)^{-1} X^T C^i p(i)$$

Algorithm 1 The ALS algorithm

```
1: procedure ALS( $R, f, \lambda; X, Y$ )
2:    $X \leftarrow 0, Y \leftarrow \text{random initial guess}$ 
3:   repeat
4:     for row  $u \leftarrow 1, m$  do
5:        $x_u \leftarrow (Y^T Y + \lambda I)^{-1} Y^T r_u$  by solving the linear system
6:        $(Y^T Y + \lambda I) x_u = Y^T r_u$ 
7:     end for
8:     for column  $i \leftarrow 1, n$  do
9:        $y_i \leftarrow (X^T X + \lambda I)^{-1} X^T r_i$  by solving the linear system
10:       $(X^T X + \lambda I) y_i = X^T r_i$ 
11:    end for
12:  until reaching the maximum iterations
13: end procedure
```

Implicit ALS

$$\min_{x_*, y_*} \sum_{u,i} c_{ui} (p_{ui} - x_u^T y_i)^2 + \lambda \left(\sum_u \|x_u\|^2 + \sum_i \|y_i\|^2 \right)$$

$$x_u = (Y^T C^u Y + \lambda I)^{-1} Y^T C^u p(u)$$

$$y_i = (X^T C^i X + \lambda I)^{-1} X^T C^i p(i)$$

Отлично параллелится по юзерам/айтемам

+ можем объяснять рекомендации!

Algorithm 1 The ALS algorithm

```
1: procedure ALS( $R, f, \lambda; X, Y$ )
2:    $X \leftarrow 0, Y \leftarrow \text{random initial guess}$ 
3:   repeat
4:     for row  $u \leftarrow 1, m$  do
5:        $x_u \leftarrow (Y^T Y + \lambda I)^{-1} Y^T r_u$  by solving the linear system
6:        $(Y^T Y + \lambda I) x_u = Y^T r_u$ 
7:     end for
8:     for column  $i \leftarrow 1, n$  do
9:        $y_i \leftarrow (X^T X + \lambda I)^{-1} X^T r_i$  by solving the linear system
10:       $(X^T X + \lambda I) y_i = X^T r_i$ 
11:    end for
12:  until reaching the maximum iterations
13: end procedure
```

Implicit ALS. Объяснение рекомендаций

$$x_u = (Y^T C^u Y + \lambda I)^{-1} Y^T C^u p(u)$$

Implicit ALS. Объяснение рекомендаций

$$x_u = (Y^T C^u Y + \lambda I)^{-1} Y^T C^u p(u)$$

$$\hat{p}_{ui} = y_i^T x_u$$

Implicit ALS. Объяснение рекомендаций

$$x_u = (Y^T C^u Y + \lambda I)^{-1} Y^T C^u p(u)$$

$$\hat{p}_{ui} = y_i^T x_u = y_i^T (Y^T C^u Y + \lambda I)^{-1} Y^T C^u p(u)$$

Implicit ALS. Объяснение рекомендаций

$$x_u = (Y^T C^u Y + \lambda I)^{-1} Y^T C^u p(u)$$

$$\hat{p}_{ui} = y_i^T x_u = y_i^T \underbrace{(Y^T C^u Y + \lambda I)^{-1} Y^T C^u}_{W^u} p(u)$$

Implicit ALS. Объяснение рекомендаций

$$x_u = (Y^T C^u Y + \lambda I)^{-1} Y^T C^u p(u)$$

$$\hat{p}_{ui} = y_i^T x_u = y_i^T \underbrace{(Y^T C^u Y + \lambda I)^{-1} Y^T C^u}_{W^u} p(u)$$

$$s_{ij}^u = y_i^T W^u y_j$$

Implicit ALS. Объяснение рекомендаций

$$x_u = (Y^T C^u Y + \lambda I)^{-1} Y^T C^u p(u)$$

$$\hat{p}_{ui} = y_i^T x_u = y_i^T \underbrace{(Y^T C^u Y + \lambda I)^{-1} Y^T C^u}_{W^u} p(u)$$

$$s_{ij}^u = y_i^T W^u y_j$$

$$\hat{p}_{ui} = \sum_{j: r_{uj} > 0} s_{ij}^u c_{uj}$$

Implicit ALS. One step ALS

Implicit ALS. One step ALS

1		1	1	
	1	1		1
	1		1	
1		1		
1	1	1		
			1	1
1	1		1	

=

0.1	0.3	0.4
0.3	-0.5	-0.2
0.1	-0.2	-0.3
0.7	0.5	-0.4
0.5	0.6	0.9
-0.9	-0.7	0.2
0.4	0.2	0.6

X

0.1	0.3	0.4	0.5	0.6
0.1	0.2	0.3	0.1	-0.2
0.9	-0.7	0.2	0.4	0.2

Implicit ALS. One step ALS

1		1	1	
	1	1		1
	1		1	
1		1		
1	1	1		
			1	1
1	1		1	

=

0.1	0.3	0.4
0.3	-0.5	-0.2
0.1	-0.2	-0.3
0.7	0.5	-0.4
0.5	0.6	0.9
-0.9	-0.7	0.2
0.4	0.2	0.6

X

0.1	0.3	0.4	0.5	0.6
0.1	0.2	0.3	0.1	-0.2
0.9	-0.7	0.2	0.4	0.2

Implicit ALS. One step ALS

1		1	1	
	1	1		1
	1		1	
1		1		
1	1	1		
			1	1
1	1		1	
	1	1		

=

0.1	0.3	0.4
0.3	-0.5	-0.2
0.1	-0.2	-0.3
0.7	0.5	-0.4
0.5	0.6	0.9
-0.9	-0.7	0.2
0.4	0.2	0.6

X

0.1	0.3	0.4	0.5	0.6
0.1	0.2	0.3	0.1	-0.2
0.9	-0.7	0.2	0.4	0.2

Implicit ALS. One step ALS

1		1	1	
	1	1		1
	1		1	
1		1		
1	1	1		
			1	1
1	1		1	
	1	1		

=

0.1	0.3	0.4
0.3	-0.5	-0.2
0.1	-0.2	-0.3
0.7	0.5	-0.4
0.5	0.6	0.9
-0.9	-0.7	0.2
0.4	0.2	0.6

X

0.1	0.3	0.4	0.5	0.6
0.1	0.2	0.3	0.1	-0.2
0.9	-0.7	0.2	0.4	0.2

$$x_u = (Y^T C^u Y + \lambda I)^{-1} Y^T C^u p(u)$$

Implicit ALS. One step ALS

1		1	1	
	1	1		1
	1		1	
1		1		
1	1	1		
			1	1
1	1		1	
	1	1		

=

0.1	0.3	0.4
0.3	-0.5	-0.2
0.1	-0.2	-0.3
0.7	0.5	-0.4
0.5	0.6	0.9
-0.9	-0.7	0.2
0.4	0.2	0.6
0.3	-0.4	0.2

x

0.1	0.3	0.4	0.5	0.6
0.1	0.2	0.3	0.1	-0.2
0.9	-0.7	0.2	0.4	0.2

$$x_u = (Y^T C^u Y + \lambda I)^{-1} Y^T C^u p(u)$$

функции ранжирования

функции ранжирования

функции ранжирования

- pointwise(поточечные)

Функции ранжирования

- pointwise(поточечные)
 - Оцениваем каждый айтем независимо
 - Любой лосс для задачи классификации или регрессии

Функции ранжирования

- `pointwise`(поточечные)
- `pairwise`(попарные)

Функции ранжирования

- pointwise(поточечные)
- pairwise(попарные)
 - Оцениваем пары релевантный vs нерелевантный айтем
 - Штрафуем если у нерелевантного айтема скор больше чем у релевантного
 - BPR, WARP, YettiRank


Функции ранжирования

- `pointwise`(поточечные)
- `pairwise`(попарные)
- `listwise`(списочные)


Функции ранжирования

- pointwise(поточечные)
- pairwise(попарные)
- listwise(списочные)
 - Оптимизируем метрику ранжирования
 - Довольно сложные, поэтому не так часто используются на практике
 - LambdaRank, RankNet


BPR: Bayesian Personalized Ranking from Implicit Feedback



BPR: Bayesian Personalized Ranking from Implicit Feedback



BPR: Bayesian Personalized Ranking from Implicit Feedback



$$D_S := \{(u, i, j) | i \in I_u^+ \wedge j \in I \setminus I_u^+\}$$

$$L_{\text{bpr}} = -\frac{1}{N_S} \sum_{j=1}^{N_S} \log \sigma(r_i - r_j) \quad \sigma(x) := \frac{1}{1 + e^{-x}}$$

WARP:Weighted Approximate-Rank Pairwise

Algorithm 1 K-OS algorithm for picking a positive item.

We are given a probability distribution P of drawing the i^{th} position in a list of size K . This defines the choice of loss function.

Pick a user u at random from the training set.

Pick $i = 1, \dots, K$ positive items $d_i \in \mathcal{D}_u$.

Compute $f_{d_i}(u)$ for each i .

Sort the scores by descending order, let $o(j)$ be the index into d that is in position j in the list.

Pick a position $k \in 1, \dots, K$ using the distribution P .

Perform a learning step using the positive item $d_{o(k)}$.

- Рассматриваем тройки (x, i, j)
- Если отранжировали неправильно, делаем шаг оптимизации
- Чем больше троек без ошибок, тем меньше шаг

Algorithm 2 K-os WARP loss

Initialize model parameters (mean 0, std. deviation $\frac{1}{\sqrt{m}}$).

repeat

Pick a positive item d using Algorithm 1.

Set $N = 0$.

repeat

Pick a random item $\bar{d} \in \mathcal{D} \setminus \mathcal{D}_u$.

$N = N + 1$.

until $f_{\bar{d}}(u) > f_d(u) - 1$ or $N \geq |\mathcal{D} \setminus \mathcal{D}_u|$

if $f_{\bar{d}}(y) > f_d(u) - 1$ **then**

Make a gradient step to minimize:



$$\Phi\left(\frac{|\mathcal{D} \setminus \mathcal{D}_u|}{N}\right) \max(0, 1 + f_{\bar{d}}(u) - f_d(u)).$$

Project weights to enforce constraints, e.g. if $\|V_i\| > C$ then set $V_i \leftarrow (CV_i)/\|V_i\|$.

end if

until validation error does not improve.

WARP vs BPR



- WARP лучше по качеству
- Нужно меньше эпох чтобы сойтись
- Каждая последующая эпоха занимает больше времени, чем предыдущая

Neural Collaborative Filtering

NCF





Figure 1: An example illustrates MF's **limitation**. From data matrix (a), u_4 is most similar to u_1 , followed by u_3 , and lastly u_2 . However in the latent space (b), placing p_4 closest to p_1 makes p_4 closer to p_2 than p_3 , incurring a large ranking loss.


NCF



$$L_{sqr} = \sum_{(u,i) \in \mathcal{Y} \cup \mathcal{Y}^-} w_{ui} (y_{ui} - \hat{y}_{ui})^2,$$

$$\begin{aligned} L &= - \sum_{(u,i) \in \mathcal{Y}} \log \hat{y}_{ui} - \sum_{(u,j) \in \mathcal{Y}^-} \log(1 - \hat{y}_{uj}) \\ &= - \sum_{(u,i) \in \mathcal{Y} \cup \mathcal{Y}^-} y_{ui} \log \hat{y}_{ui} + (1 - y_{ui}) \log(1 - \hat{y}_{ui}). \end{aligned}$$

NCF. Neural Matrix Factorization



NCF. Neural Matrix Factorization




Figure 4: Performance of HR@10 and NDCG@10 *w.r.t.* the number of predictive factors on the two datasets.





Figure 5: Evaluation of Top- K item recommendation where K ranges from 1 to 10 on the two datasets.

LEARNING A DOT PRODUCT WITH MLP IS HARD

Table 1: Comparison from [8] of NeuMF with various baselines and our results. The best results are highlighted in bold, the second best result is underlined.

Method	Movielens		Pinterest		Result from
	HR@10	NDCG@10	HR@10	NDCG@10	
Popularity	0.4535	0.2543	0.2740	0.1409	[8]
SLIM [25, 30]	<u>0.7162</u>	<u>0.4468</u>	0.8679	<u>0.5601</u>	[8]
iALS [20]	0.7111	0.4383	0.8762	0.5590	[8]
NeuMF (MLP+GMF) [17]	0.7093	0.4349	<u>0.8777</u>	0.5576	[8]
Matrix Factorization	0.7294	0.4523	0.8895	0.5794	Fig. 2

LEARNING A DOT PRODUCT WITH MLP IS HARD



Спасибо за внимание