
Курс: Рекомендательные системы

Занятие 5:

Гибридные подходы

Лашинин Олег
11.02.26

План занятия



- Гибридные модели
- Двухуровневая модель

Почему сегодня эта тема?

Сделать двухуровневую модель сложно, но необходимо.

В 2019 году я участвовал в первом соревновании. Мой ALS выдавал 0.027. А мой тимлид занял второе место со скором ~ 0.036 . Он использовал град. бустинг.


Гибридная система

Hybrid recommender systems combine two or more recommendation strategies in different ways to benefit from their complementary advantages



Знаете ли аналоги из обычного ML?

Как можно скомбинировать recsys модели?



Виды систем



Collaborative Filtering

Content-Based Filtering

Demographic Filtering

Knowledge-Based Filtering

Utility-based

Виды систем



Table I: Recommendation Techniques

Technique	Background	Input	Process
Collaborative	Ratings from U of items in I .	Ratings from u of items in I .	Identify users in U similar to u , and extrapolate from their ratings of i .
Content-based	Features of items in I	u 's ratings of items in I	Generate a classifier that fits u 's rating behavior and use it on i .
Demographic	Demographic information about U and their ratings of items in I .	Demographic information about u .	Identify users that are demographically similar to u , and extrapolate from their ratings of i .
Utility-based	Features of items in I .	A utility function over items in I that describes u 's preferences.	Apply the function to the items and determine i 's rank.
Knowledge-based	Features of items in I . Knowledge of how these items meet a user's needs.	A description of u 's needs or interests.	Infer a match between i and u 's need.

Виды систем



Technique	Pluses	Minuses
Collaborative filtering (CF)	A. Can identify cross-genre niches. B. Domain knowledge not needed. C. Adaptive: quality improves over time. D. Implicit feedback sufficient	I. New user ramp-up problem J. New item ramp-up problem K. “Gray sheep” problem L. Quality dependent on large historical data set. M. Stability vs. plasticity problem
Content-based (CN)	B, C, D	I, L, M
Demographic (DM)	A, B, C	I, K, L, M N. Must gather demographic information
Utility-based (UT)	E. No ramp-up required F. Sensitive to changes of preference G. Can include non-product features	O. User must input utility function P. Suggestion ability static (does not learn)
Knowledge-based (KB)	E, F, G H. Can map from user needs to products	P Q. Knowledge engineering required.

Виды гибридных систем

Table III: Hybridization Methods

Hybridization method	Description
Weighted	The scores (or votes) of several recommendation techniques are combined together to produce a single recommendation.
Switching	The system switches between recommendation techniques depending on the current situation.
Mixed	Recommendations from several different recommenders are presented at the same time
Feature combination	Features from different recommendation data sources are thrown together into a single recommendation algorithm.
Cascade	One recommender refines the recommendations given by another.
Feature augmentation	Output from one technique is used as an input feature to another.
Meta-level	The model learned by one recommender is used as input to another.




Figure 6: Distribution of studies per hybridization class



Можете ли придумать примеры из реальной жизни?

Netflix Prize



Виды гибридных систем





I would like to eat at a restaurant that has:

Cuisine

Price

Style

Atmosphere

Occasion

I would like to eat at a restaurant just like:

Chinois on Main

Los Angeles

New Query

Submit



The Los Angeles restaurant you chose is:

Chinois On Main	
2709 Main St. (bet. Rose Ave. & Ocean Park Blvd.), Santa Monica, 310-392-9025	
Pacific New Wave	\$30-\$50
Extraordinary Decor, Extraordinary Service, Near-perfect Food, Hip Place To Be, On the Beach, Great for People Watching, Parties and Occasions, Weekend Brunch, Weekend Lunch, Fabulous Wine Lists	

We recommend:

Yoshi's Cafe	
3257 N. Halsted St. (Belmont Ave.), Chicago, 312-248-6160	
Asian, Japanese, French (New)	\$30-\$50
Extraordinary Decor, Extraordinary Service, Near-perfect Food, Need To Dress, Prix Fixe Menus, Quiet for Conversation, Very Busy - Reservations a Must, Romantic, Good Out of Town Business, Fabulous Wine Lists, Game, Parking/Valet	

less \$\$

nicer

cuisine

traditional

creative

livelier

quieter

For other suggestions, select:

Yoshi's Cafe

[Penny's Noodle Shop](#)

[Emilio's Tapas Bar & Restaurant](#)

[Emilio's Granada](#)

[302 West](#)

[Arun's](#)

[Nick's Fishmarket](#)

[Lulu's](#)

[Trio](#)

[Bossa Nova](#)



Какой тип гибрида?

Примеры из жизни

Хочу Хычин



Хочу Хычин

3.9 (35)

Кафе

Overview

Reviews

About

Directions

Save

Nearby

Send to phone

Share

✓ Dine-in

✓ Takeaway

✓ No-contact delivery

Stremyanny Pereulok, 38, Moscow, 115093

Closed

Opens 10 AM Sat

хочу поест

хочу поест завтра в 6 утра

Места

Подборки

Кофейни

Рестораны

Быстрое питание

Бары

Кал

Молоко

4,8 (4349)

Хорошее место

Круглосуточно · Кафе, кофейня

ул. Большая Дмитровка, 7/5сб, Москва

«Пришли сюда на завтрак в мой День Рождения без резерва и не прогадали ;)...»

Меню

Скидка 20% на основное меню кухни и бара по будням с 12:00 до 18:00

Реклама

Вкусно — и точка

4,4 6126 оценок

Открыто до 00:00 · Быстрое питание

Манежная площадь, 1, стр. 2

«Единственный фастфуд с видом на Кремль»

Меню

Двойная выгода! Два Биг Хита за 329₽

Реклама

Корчма Тарас Бульба

4,6 (7177)

Хорошее место

Открыто до 02:00 · Ресторан, доставка еды и напитков

Моховая ул., 8, стр. 1, Москва

«Отлично, особенно русский борщ вкусный и хреновуха, а борщ под хреновуху, я вам...»

Меню

Ассорти из сала в подарок!

Реклама

Бардак

4,7 (4779)

Хорошее место

До закрытия 22 мин · Кафе

ул. Маросейка, 6-8с1

«Брали с подругой на двоих султан сет, объединение»


Меню

В подборке Где пробовать турецкую кухню в Москве



Какой тип гибрида?

Примеры из жизни



Что важно учесть
тут при
рекомендациях?

Примеры из жизни



Что тут может быть гибридного? Какие тут системы?

Картинки

Видео

Машине

Детьми

Осенью

Сентябре

Зимой

Весной

Апр

About 1,870,000 results (0.33 seconds)

Results for **Респ. Карелия** · [Choose area](#)

Tripadvisor

<https://www.tripadvisor.ru> > ... > Республика Карелия

Достопримечательности в Республике Карелия

Музей-заповедник «Киж» известен далеко за пределами России, хотя бы потому, что ансамбль «Кижский погост» с 1990 года входит в Список объектов всемирного ...

[Горы](#) · [Водопады](#) · [Горный парк "Рускеала"](#) · [Природные и заповедные...](#)

Top sights in Republic of Karelia

Ruskeal'skiye Vodopady

4.7 ★ (10K)

Tourist attraction

Водопад Кивач

4.7 ★ (5.7K)

Ecological park

RUB 250.00

Kizhi Museum

4.8 ★ (2.2K)

Historical place mus...

Valaam Transfiguration...

4.8 ★ (2.5K)

Monastery

More things to do

Примеры из жизни



Что тут может быть гибридного? Какие тут системы?

Шаг #1



ДО 12 МАРТА

ОZON

Каталог

Везде Искать на Ozon

Войти

Заказы

Избранное

Корзина

Рекомендуем для вас

АВТОДЕРЖАТЕЛ

421 Р 1400 Р -62%

АUTOSHOP / Автомобильный держатель для мобильного...

КРЕПЛЕНИЕ НАСТЕННЫЙ ДЕРЖАТЕЛЬ

416 Р 799 Р -48%

TREND LIVE Кронштейн крепежный Крепеж 3 шт.

Универсальная гибкая пластиковая воронка с защелкой...

309 Р 729 Р -57%

Расаат-лукум Восточный дастархан

271 Р 1408 Р -76%

Лукум Восточный Дастархан 500 гр. /восточные сладости /...

ЩЕТКА РУЧНАЯ ДЛЯ ТРУДНОДОСТУПНЫХ МЕСТ

225 Р 300 Р -25%

Щетка ручная для труднодоступных мест, 2 шт.

ПАКЕТ-КРЫШКА НА РЕЗИНКЕ

186 Р 500 Р -63%

Пакет крышка для хранения продуктов, для посуды...

БЕЛАЯ КРАСКА

342 Р 997 Р -66%

Краска для обуви Дон Коттер белая, водостойкая, с...

АНТИДОЖДЬ

598 Р 1330 Р -55%

Антидождь для стекла от 4 месяцев на лобовом / покрыти...

СКРЕБОК

186 Р 1790 Р -90%

Щетка для удаления шерсти животных, катышков, волос...

Пакет крышка для хранения продуктов, для посуды диаметром до 24 см, 100 шт

306 отзывов 3 видео 1 вопрос Добавить к сравнению Поделиться

Код товара: 1419214938

О товаре

Тип Пакет для хранения продуктов
Материал Полиэтилен
Количество в упаковке, шт. 100
Цвет Прозрачный
Артикул paket24CM_100

Перейти к описанию

Имя скрыто 15 февраля
Очень удобные в быту крышечки, давно такими пользуемся, продавца рекомендую!
Отличные крышечки! Очень удобные!

Серия от бренда

ЩЕТКА-ЕРШИК

127 Р 400 Р

ЩЕТКА РУЧНАЯ

230 Р 300 Р

ПЛОСКА ЗАЩИТНАЯ

405 Р 700 Р

СКРЕБОК

194 Р 300 Р

Все товары из серии

Распродажа
Осталось 4231 шт
12 дней осталось

186 Р с Ozon Картой

190 Р 500 Р без Ozon Карты

0 Р сегодня в Ozon Рассрочку

Хочу скидку

В корзине

Перейти

Доставка послеавтра

Часто задаваемые вопросы
Условия доставки Возврат товаров
Способы оплаты Возврат денег

Шаг #2

Рекомендуем для вас

ЭЛАСТИЧНЫЕ ПАКЕТЫ

185 Р

POPULAR BROUN Упаковочный пакет, 27 см, 100 шт

ЩЕТКА РУЧНАЯ

225 Р 300 Р -25%

Щетка ручная для труднодоступных мест, 2 шт.

ЩЕТКА-ЕРШИК

124 Р 400 Р -69%

Ершик для прочистки труб, щетка ручная, 1 шт.

ПИЩЕВЫЕ ШАПОЧКИ

195 Р 750 Р -74%

Пакеты шапочки для хранения продуктов в холодильнике...

СКРЕБОК ДЛЯ ЧИСТКИ

165 Р 400 Р -59%

Скребок для стеклокерамики плит стекла аквариума окон...

МУЛЬТИКОН С АДАПТЕРОМ

245 Р 2000 Р -88%

Мультикон 3+1, насадки на майонез

Набор контейнеров

522 Р 939 Р -44%

Набор пищевых контейнеров Пруфа для хранения с...

Щетка для чистки

187 Р 399 Р -53%

Универсальная щетка с дозатором

СЕТКА ДЛЯ ГЛАЖКИ

122 Р 435 Р -72%

Romanky Сетка, коврик для глажки "Для дома",...

ПРЕСС ДЛЯ ЧЕСНОКА

195 Р 760 Р -74%

Чеснокодавка металлическая пресс для чеснока ручная

Шаг #3

Примеры из жизни



Шаг #3

Avito

Все категории

Поиск по объявлениям

Рекомендации для вас



Торговая площадь, 130 м²
110 000 ₽ в месяц
Семикаракорск
Сегодня 21:45



Игровая приставка Game Stick 128 г6 4K
2 500 ₽
Орехово-Зуево
Сегодня 22:42



Повар с обучением в ресторан
до 42 900 ₽
Березники
Сегодня 22:30



Ботинки зимние Rieker
2 000 ₽
Москва, Шоссе Энтузиастов
Сегодня 23:00



Свободного назначения, 20 м²
12 000 ₽ в месяц
Саратов, р-н Ленинский
Сегодня 22:40



УАЗ 31514 2.4 МТ, 1999,
60 000 км
780 000 ₽
Саки
Сегодня 19:50



TECNO Pova 3, 6/128 ГБ
7 500 ₽
Иваново, р-н Фрунзенский



Аренда автомобиля под доставку
1 000 ₽ за услугу

Avito Авто

Все категории

Поиск по объявлениям

Найти

4.5 17 отзывов о модели

Главная > Транспорт > Автомобили > С пробегом > УАЗ > 31514 > (1985–2013)

УАЗ 31514 2.4 МТ, 1999, 60 000 км

780 000 ₽

или предложите свою цену

Реклама: [рекламщик](#)

Выгодные условия и быстрое одобрение

Подобное

Добавить в избранное

Сравнить

Добавить заметку

Показать телефон

8 918 XXX-XX-XX

Написать сообщение

Отвечает в течение дня

Евгений

Частное лицо

На Авито с 20 февраля 2024

Завершено 2 объявления

Подписаться на продавца

Спросите у продавца

Здравствуй!

Шаг #1



Avito

Все категории

Поиск по объявлениям

Найти


Рекомендации для вас



Chevrolet Blazer 4.3 AT, 1994, 264 000 км
625 000 ₽
Севастополь
Сегодня 16:56



Mitsubishi Galant 2.0 AT, 1995, 300 000 км
310 000 ₽
Саки
Вчера 19:26



BAZ (LADA) 4x4 (Нива) 1.7 МТ, 2006, 150 000 км
345 000 ₽
Симферополь
Сегодня 09:39



Mitsubishi Pajero 2.5 МТ, 1993, 450 000 км
530 000 ₽
Алушта
Сегодня 10:04



Дом 50 м² на участке 15 сот.
700 000 ₽
станция Бороздиновская
Сегодня 22:48



УАЗ Hunter 2.7 МТ, 2007, 150 000 км
500 000 ₽
с. Малиновка
26 февраля 21:22



УАЗ 31512 2.4 МТ, 1992, 10 000 км
350 000 ₽
Бахчисарай
Сегодня 18:52



ЗАЗ 968 Запорожец 1.2 МТ, 1986, 12 000 км
15 000 ₽
с. Елизаветово
25 февраля 22:22



Peugeot Traffic 2.0 МТ



УАЗ 31514 2.4 МТ, 1999



BAZ 3105 Зубр 2.4 МТ



Mitsubishi Pajero 2.5 МТ

Шаг #2



Примеры из жизни



Что тут может быть гибридного? Какие тут системы?

Яндекс  Музыка

Главное • Подкасты и книги Детям Коллекция 


Главное

ВСЁ НАСТРОЕНИЯ И ЖАНРЫ НОВЫЕ РЕЛИЗЫ ЧАРТ ПОДБОРКИ НЕЙРОМУЗЫКА

► **Моя волна**

 Настроить

Премьера



Премьера •
Открывает вам главные новинки

Дежавю



Дежавю
Знакомит с тем, что вы ещё не слушали

Плейлист дня



Плейлист дня
Звучит по-вашему каждый день

Гибридная система





Fig. 4 The RMSE values for the 7 most similar individual recommendation algorithms, averaged out over all users according to a 10-fold evaluation on the test set.



Почему растет ошибка при увеличении числа алгоритмов?

Гибридная система: простой способ «блендинга»

3	1345	13	12	126	26	24	Модель А
3	1	13	10	9	26	55	Модель Б
3	15	1623	643	69	31	13	Модель С



Как объединить?

Гибридная система: простой способ «блендинга»

3	1345	13	12	126	26	24	Модель А
3	1	13	10	9	26	55	Модель Б
3	15	1623	643	69	31	13	Модель С

$$final_rank_i = \sum_{models} \begin{cases} top_k, & i \notin R(M) \\ rank_i^m, & i \in R(M) \end{cases}$$

Ок, если качество моделей сравнимые

Теория голосований



Ranked voting

★ 27 languages ▾

Article [Talk](#)

[Read](#) [Edit](#) [View history](#) [Tools](#) ▾

From Wikipedia, the free encyclopedia

For the voting system often called ranked-choice voting in the United States, see [Instant-runoff voting](#).

Ranked voting is any [voting system](#) that uses voters' [rankings](#) of candidates to choose a single winner or multiple winners. More formally, a ranked vote system depends only on voters' [order of preference](#) of the candidates.

Ranked voting systems vary dramatically in how preferences are tabulated and counted, which gives them [very different properties](#). In [instant-runoff voting](#) (IRV) and the [single transferable vote](#) system (STV), lower preferences are used as contingencies (back-up preferences) and are only applied when all higher-ranked preferences on a ballot have been eliminated or when the

Rank ballot by oval marks Instructions: Fill in the first column oval by your first choice, second column oval by your second choice, etc. <table><tbody><tr><td>1</td><td>2</td><td>3</td><td></td></tr><tr><td>☐</td><td>☐</td><td>☐</td><td>Joe Smith</td></tr><tr><td>☒</td><td>☐</td><td>☐</td><td>Henry Ford</td></tr><tr><td>☐</td><td>☐</td><td>☒</td><td>Jane Doe</td></tr><tr><td>☐</td><td>☐</td><td>☐</td><td>Fred Rubble</td></tr><tr><td>☐</td><td>☒</td><td>☐</td><td>Mary Hill</td></tr></tbody></table>	1	2	3		☐	☐	☐	Joe Smith	☒	☐	☐	Henry Ford	☐	☐	☒	Jane Doe	☐	☐	☐	Fred Rubble	☐	☒	☐	Mary Hill	Rank ballot by written names Instructions: List the candidates in the order of your preference. <table><tbody><tr><td>1.</td><td>Ford</td></tr><tr><td>2.</td><td>Hill</td></tr><tr><td>3.</td><td>Doe</td></tr><tr><td>4.</td><td>Rubble</td></tr><tr><td>5.</td><td>Smith</td></tr></tbody></table>	1.	Ford	2.	Hill	3.	Doe	4.	Rubble	5.	Smith	Rank any number of options in your order of preference. <table><tbody><tr><td>☐</td><td>Joe Smith</td></tr><tr><td>☒</td><td>John Citizen</td></tr><tr><td>☒</td><td>Jane Doe</td></tr><tr><td>☐</td><td>Fred Rubble</td></tr><tr><td>☒</td><td>Mary Hill</td></tr></tbody></table>	☐	Joe Smith	☒	John Citizen	☒	Jane Doe	☐	Fred Rubble	☒	Mary Hill
1	2	3																																												
☐	☐	☐	Joe Smith																																											
☒	☐	☐	Henry Ford																																											
☐	☐	☒	Jane Doe																																											
☐	☐	☐	Fred Rubble																																											
☐	☒	☐	Mary Hill																																											
1.	Ford																																													
2.	Hill																																													
3.	Doe																																													
4.	Rubble																																													
5.	Smith																																													
☐	Joe Smith																																													
☒	John Citizen																																													
☒	Jane Doe																																													
☐	Fred Rubble																																													
☒	Mary Hill																																													
Ovals	Names	Numbers																																												

Various types of ranked voting ballot

Двухуровневая модель: зачем?

- Учесть больше признаков
- Сделать «легкое» и «тяжелое» ранжирование для ускорения (отбор кандидатов)
- Завязаться на фидбек-луп (данные от предыдущих рек. систем)

Двухуровневая модель: признаки

Top picks



Acid



In the Forests of ...



Vrednaya privyuc...



Leto 1941 goda



Conor McGregor...



Cloudy Mountain



Pechen



Only God Forgives



Как вы определяете
фильмы, которые будете
смотреть?

Двухуровневая модель: признаки

На рекомендации с сайта я не ориентируюсь вообще. Как-то раз зашла их посмотреть, и обнаружила, что рекомендуют мне в основном советскую классику, которую я уже видела, но поленилась оценить. Да и собственным-то оценкам у меня нет доверия - вроде бы ставлю по совести, но часто бывает так, что, пересмотрев фильм, я меняю оценку. Добавляю или скидываю до 3 баллов. Это порядочно.

Как еще выбираю? Если речь о сериалах, то, если мне понравился один сезон какого-то сериала, я при случае посмотрю еще, пусть и через пару лет.

Выбираю по темам. Нравнодушна вот к костюмным историческим драмам, за что меня даже отчитывали уже на форуме 😊

Выбираю по режиссеру. Если мне понравились у кого-то два-три фильма, то я рискну посмотреть и другие.

На чьи-то восторги ориентируюсь в меньшей степени, потому что это знакомые мне грабли: все и всюду восторгались "Дневником памяти" - я посмотрела и не поняла, что это было... Это, конечно, крайний пример. Есть все же люди, которым я бесконечно доверяю.

Сюжет и актеры для меня самое важное. Далее визуальная часть. То есть если мне понравится трейлер и кадры. Меньше всего ориентируюсь на бюджет и отзывы критиков. Знаю, что крайне часто расхваливаемые ими фильмы мне казались отвратными и наоборот.

Как я выбираю фильмы?


Если понравится сюжет - смотрю

Если есть актёры, которых я знаю - смотрю

Если жанр ужасы, драма, триллер, комедия - смотрю обязательно


Ну и если трейлер понравился!

Двухуровневая модель: feedback loop



Двухуровневая модель: feedback loop

Петля учета интересов, но зацикливания



Через FL мы учитываем то, что юзер не видел!

Петля улучшения фильтрации

Двухуровневая модель: фидбек луп

Датасет (базис)

User_id	Item_id	Timestamp	label
1	2	124	0
2	3	2512	0
1	1	12	1
3	1	1	1

U/I	item 1	item2	item 3	item 3
User 1	-	1	0	1
User 2	1	0	1	-
User 3	0	1	-	1
User 4	-	1	0	-
User 5	1	0	1	1
User 6	1	1	-	1
User 7	0	1	1	0
User 8	1	-	-	1

Двухуровневая модель: про модели

Датасет (базис)

User_id	Item_id	Timestamp	label
1	2	124	0
2	3	2512	0
1	1	12	1
3	1	1	1

Модели



Все это есть в LightGBM и CatBoost

Стоит рассмотреть:

- 1) **Регрессию**, если вы предсказываете оборот, деньги, в общем любую вещественную переменную
- 2) **Классификацию**, если вам важен LogLoss (точность предсказания вероятности)
- 3) **Ранжирование**, если вам важен только порядок ранжирования (обычно лучше ранжирует, чем классификация!)

Двухуровневая модель: про ранжирование

	Item Features	User Features	User-item scores/rank	1
	Item Features	User Features	User-item scores/rank	0
	Item Features	User Features	User-item scores/rank	0
	Item Features	User Features	User-item scores/rank	1
	Item Features	User Features	User-item scores/rank	1
	Item Features	User Features	User-item scores/rank	0

2) LambdaRank: пара λ -градиент для пары документов

В LambdaRank для пары i, j (где документ i более релевантен, чем j) строят "силу" λ_{ij} , которая влияет на обновление модели:

$$\lambda_{ij} = -\sigma \cdot \frac{|\Delta \text{NDCG}_{ij}|}{1 + \exp(\sigma(s_i - s_j))}$$

где

- s_i, s_j — предсказанные моделью оценки для документов i, j
- σ — коэффициент наклона (гиперпараметр, аналогичный логистической регрессии)
- $|\Delta \text{NDCG}_{ij}|$ — абсолютное изменение NDCG, которое произойдет при обмене i и j в ранжировании. Microsoft

3) Суммарный λ для документа

Для каждого документа сумма всех парных λ определяет **псевдо-градиент** по его оценке:

$$\lambda_i = \sum_{j: y_i > y_j} \lambda_{ij} - \sum_{j: y_i < y_j} \lambda_{ji}$$

где y_i — истинная релевантность документа i .

Это λ служит градиентом в бустинге LightGBM/LambdaMART (оно моделируется деревьями).

everdark.github.io


Юзер фици одинаковы внутри одного юзера,
=> они мало важны для ранжирования!




(a) Electronic mail overload




(b) Using distribution lists



(c) Conventional filtering




(d) Collaborative filtering



(d) Collaborative filtering


Двухуровневая модель: два этапа ранжирования




Очень много айтеров

2 этап ранжирования



Двухуровневая модель: как учить




Двухуровневая модель: проблема с клиентами



Двухуровневая модель: отложенный таргет










Двухуровневая модель: несколько моделей



Частный случай: число кандидатов = число айтемов



	Item Features	User Features	User-item scores/rank	1
	Item Features	User Features	User-item scores/rank	1
	Item Features	User Features	User-item scores/rank	0
	Item Features	User Features	User-item scores/rank	0
	Item Features	User Features	User-item scores/rank	1
	Item Features	User Features	User-item scores/rank	1
	Item Features	User Features	User-item scores/rank	0
	Item Features	User Features	User-item scores/rank	0

Четыре типа фичей для 2х уровневой модели

Item Features

User Features

User-item scores/rank

context

1/0

Давайте обсудим каждый тип

4 типа признаков для 2 уровня

Item Features

User Features

User-item scores/rank

context

1

Все, что
угодно/доступно


- RecSys models
- Статистики
- полуперсональные

- Время
- Гео
- Девайс
- Плейсмент
- Погода



Что самое важное для определения релевантности?

4 типа признаков для 2 уровня



- RecSys models
- Статистики
- полуперсональные

- Время
- Гео
- Девайс
- Плейсмент
- Погода

CTR айтеров!

RecSys модели, которые генерят скоры релевантности (ALS/EASE)

+ явные счетчики

Как надо думать про признаки?



Просмотры




Клики

Три фичи:

Events_user_item_seen
Events_user_item_tap
Events_user_item_conv_from_seen2tap

Как надо думать про признаки?



Просмотры



Клики



Лайки



Много фичей:

events_num_user_item_seen/tap/likes
events_conv_user_item_seen_tap/seen_like/like_tap


Как надо думать про признаки?



Много фичей:

events_num_user_item_seen/tap/likes_30days/7days
events_conv_user_item_seen_tap/seen_like/like_tap_30days/7days


Как надо думать про признаки?



Много фичей:

events_num_user_item_category_seen/tap/likes_30days/7days
 events_conv_user_item_category_seen_tap/seen_like/like_tap_30days/7days

Как надо думать про признаки?



events_num_user_cluster_item_category_seen/tap/likes_30days/7days
 events_conv_user_cluster_item_category_seen_tap/seen_like/like_tap_30days/7days

Как надо думать про признаки?

User

Item

timestamp

Type
(seen/click/purchase)

User features

Item features

Select {user}, {user_cluster}, {item_cluster}, {item}, count(*) as
feature_value

From event_table

Where timestamp > date – window and timestamp < date

Group by {user}, {user_cluster}, {item_cluster}, {item}

Select t1.{key}, t1.feature_value / {t2.feature_value}

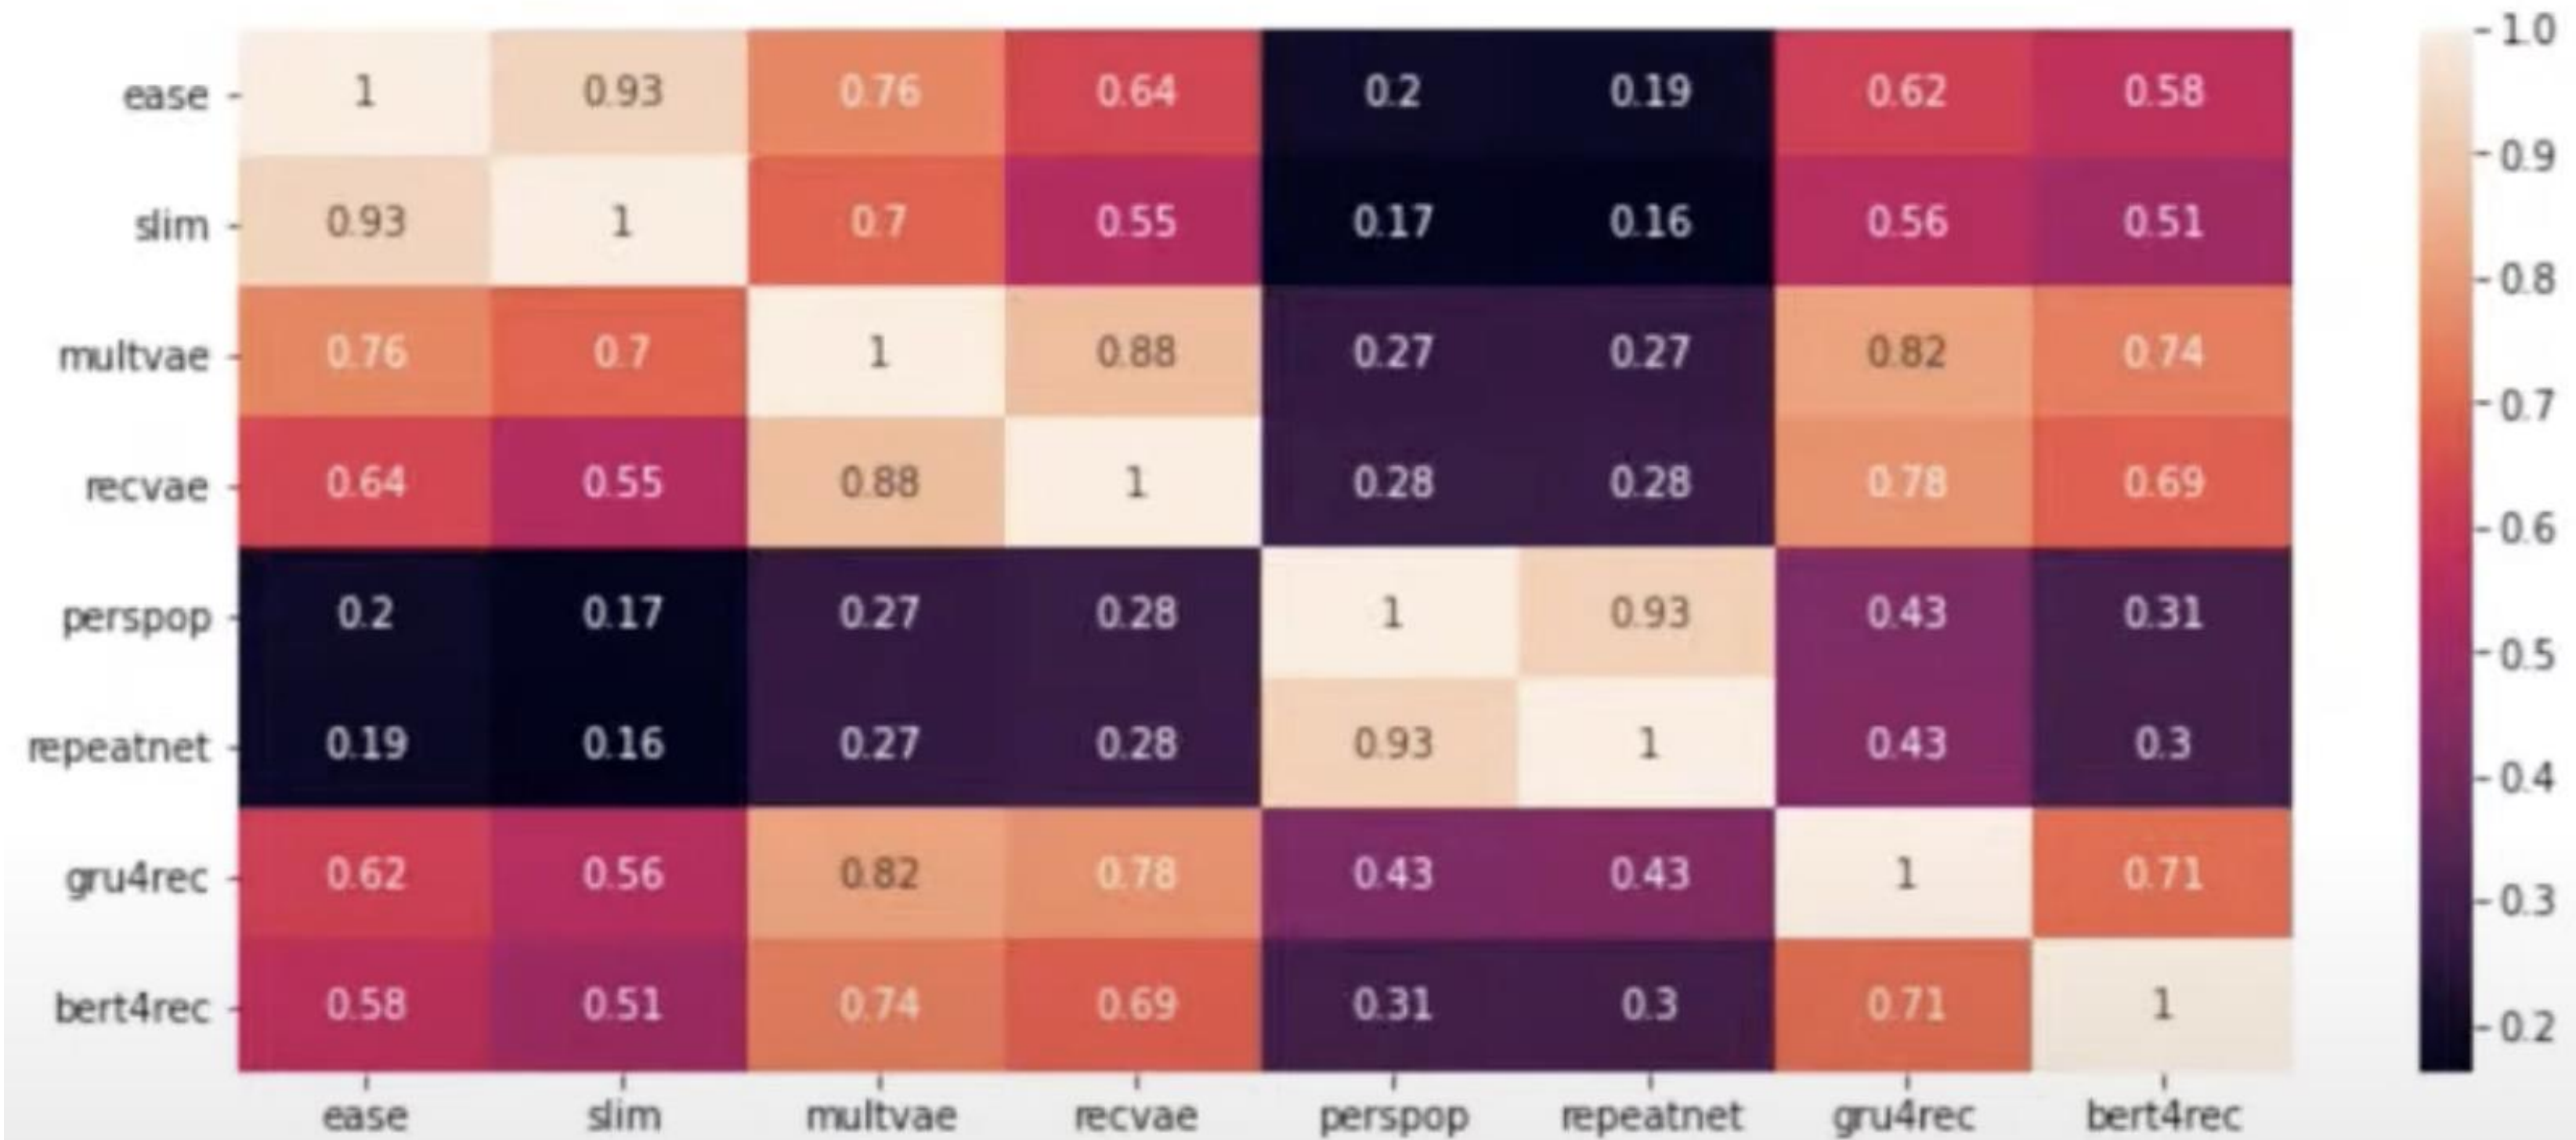
From feature t1

Join feature t1 on t1.{key} = t1.{key}

Слайд про user-item фичи

- 1) Хорошо работают, когда каталог большой и много статистик непустые
- 2) Плохо работают, когда таких фичей мало, мало items и они все разнородные. Тогда user-item скор можно считать через recsys модели (в том числе нейросети)
- 3) User-item category хорошо работают, если разделение по категориям существует в продукте, а если нет – тогда плохо


Корреляция признаков от моделей



Про важность признаков



Интерпретация через SHAP values



Можно накладывать бизнес-ограничения

Item Features

User Features


User-item scores/rank

% кэшбека

1

lightgbm.readthedocs.io/en/latest/Parameters.html

monotone_constraints, default = None, type = multi-int, aliases: mc, monotone_constraint, monotonic_cst




3% кэшбека

5% кэшбека

7% кэшбека




10% кэшбека



Третий уровень: бизнес логика


		Item Features	User Features	User-item scores/rank	1
		Item Features	User Features	User-item scores/rank	1
Не работает уже магазин		Item Features	User Features	User-item scores/rank	0
Товара нет в наличии		Item Features	User Features	User-item scores/rank	0
Клиенту не доступен товар		Item Features	User Features	User-item scores/rank	1
Мы находимся в подборке «новое»		Item Features	User Features	User-item scores/rank	1
		Item Features	User Features	User-item scores/rank	0
		Item Features	User Features	User-item scores/rank	0

Четвертый уровень: может быть что угодно

	Item Features	User Features	User-item scores/rank	1
	Item Features	User Features	User-item scores/rank	0
	Item Features	User Features	User-item scores/rank	0




Наша система имеет 4 стадии



Все это окажется на вашем столе через 30 минут!

Наша система имеет 5 стадий

Feature augmentation | Output from one technique is used as an input feature to another.



●	Item Features	User Features	User-item scores/rank	1
●	Item Features	User Features	User-item scores/rank	1
●	Item Features	User Features	User-item scores/rank	0
●	Item Features	User Features	User-item scores/rank	0

Пример решения x5 Retail Hero

Какие товары клиент вероятно купит в следующий раз — Антон Протопопов

Ранжирование
Важность признаков

- Всего ~80 признаков
- Наибольший вклад вносит признаки из истории транзакций пользователей
- Важность топ 15 признаков

Features	Feature importance, gain
mean_items_in_trans_log_denom	6193468.195
mean_items_in_trans	2497577.883
top_item_cosine50_0_score	1602290.456
last_item_purchase_num_days	409199.997
co_occurrence_co_item_norm_max	329674.253
cosine50_pos	328352.638
mean_items_in_trans_log	293456.464
num_transactions	264616.347
popularity_position	252853.751
cooc_item_sum_score	239649.898
co_occurrence_co_item_norm_sum_weighted	226036.393
all_score	152435.426
mean_num_items	140652.220
tfidf_pos	140111.073
tfidf_score	126763.467

17

Антон Протопопов
X5 RETAIL HERO

**КАКИЕ ТОВАРЫ КЛИЕНТ
ВЕРОЯТНО КУПИТ В
СЛЕДУЮЩИЙ РАЗ?**

ML trainings DATA SOULS

26:22

Ранжирование
Градиентный бустинг

Microsoft
LightGBM

dmlc
XGBoost

CatBoost


1. binary
2. lambdarank
3. rank_xendcg

1. binary:logistic
2. rank:pairwise
3. rank:ndcg
4. rank:map

1. RMSE
2. QueryRMSE
3. PairLogit
4. PairLogitPairwise
5. YetiRank
6. YetiRankPairwise

13

Пример решения Yandex Cup 2021




Признаки по ресторанам


1. Популярность ресторана у туристов.
2. Экспоненциальное сглаживание на количество отзывов.
3. Средний рейтинг
4. Доля отзывов туристов в ресторане по отношению к общему количеству отзывов.
5. Разница между средними рейтингами туристов и местных
6. Количество признаков у ресторана
7. Количество различных аспектов, упомянутых в отзыве

Признаки по пользователю

1. Разница по времени между первым и последним отзывом клиента
2. Максимальная разница по времени между двумя соседними отзывами
3. Средний рейтинг
4. Количество отзывов
5. Количество перемещений между городами
6. Максимальное количество отзывов в один день
7. Количество различных факторов, упомянутых в отзыве



Надо найти пользователей, которые
провзаимодействовали с роликом, с
которым раньше никто не
взаимодействовал

#	Команды (216)		nDCG [?]	Последний	Решений
1	madgnome		0,3853157728	30d	6
2	Maksim Kuzin		0,3836231465	30d	68
3	Elves do RePlay		0,3834455186	30d	165
4	Baseline		0,3808346257	30d	116
5	Онего		0,3773256343	30d	111

Кандидаты: все пользователи, которые хотя бы 1 раз видели ролики автора

Ранжирующая модель: LGBMRanker на признаках user-/user-author

Базис – датасет с нужными ключами для расчета фичей, размеченным таргетом, собранным на определенную дату

Базис в задаче: `author_id – user_id – week – target`

Множество `author_id – user_id` – насэмплированное* множество такое, что эти юзеры хотя бы раз видели автора до `week` неключительно.

Target – $\log_{1p}$ от счетчика суммы действий только с новым контентом** у этого автора этого юзера. 0 – отсутствие действия

* Сэмплирование – некоторый жадный набор юзеров для автора так, чтобы по автору было не больше 10к вхождений (ограничение lgbm)

**Новый контент – те айтемы, которые не встречались в прошлую неделю

Задача для бустинга: отранжировать `user_id` так, чтобы сверху оказались те, у которых target больше

Важные признаки:

- 1) User-author взвешенная сумма label по «дням»
- 2) User-author сумма label только по новым айтемам
- 3) User-author число интеракций по айтому до того, как встретилась интеракция/лайк
- 4) User-author доля label>0 взвешенная по «дням»
- 5) User-author число дней с последнего взаимодействия
- 6) User-author взвешенное число лайков по «дням»
- 7) User-author взвешенная сумма label по place=1
- 8) User взвешенная сумма label по неделям
- 9) User-author число недель с последнего действия
- 10) User-author число действий в этом разрезе с последнего позитивного действия в этом разрезе
- 11) User-author взвешенный таймспент по дням
- 12) User взвешенное число открытых комментариев по «дням» и неделям

Спасибо за
внимание