

Лекция 12.

Интерпретируемость и объяснимость моделей



Миша Печатов

План

- ➔ Что такое объяснимость рекомендаций
- ➔ Зачем нужно объяснять рекомендации
- ➔ Типы подходов
- ➔ Конкретные модели для объяснения



Что такое объяснимость рекомендаций

Объяснимость vs интерпретируемость

Объяснимость vs интерпретируемость

- **Интерпретируемость (Interpretability)** – что в признаках указывает на такой ответ
- **Объяснимость (Explainability)** – почему модель дала такой ответ

Объяснимость vs интерпретируемость

- **Интерпретируемость (Interpretability)** – что в признаках указывает на такой ответ
 - Объясняет как модель получила такой ответ
 - Фокус на фичах модели и процессе принятия решения
 - «Могу ли я заглянуть внутрь модели и понять, как она работает?»
 - Пример: Модель матричной факторизации считается интерпретируемой, если по скрытым факторам можно догадаться, что, например, один из них отвечает за фильмы в жанре "экшен".
- **Объяснимость (Explainability)** – почему модель дала такой ответ

Объяснимость vs интерпретируемость

- **Интерпретируемость (Interpretability)** – что в признаках указывает на такой ответ
 - Объясняет как модель получила такой ответ
 - Фокус на фичах модели и процессе принятия решения
 - «Могу ли я заглянуть внутрь модели и понять, как она работает?»
 - Пример: Модель матричной факторизации считается интерпретируемой, если по скрытым факторам можно догадаться, что, например, один из них отвечает за фильмы в жанре "экшен".
- **Объяснимость (Explainability)** – почему модель дала такой ответ
 - Насколько хорошо модель может предоставить понятное объяснение того, почему был сделан тот или иной вывод
 - Помочь пользователю понять, почему ему рекомендовали конкретный объект
 - «Может ли система объяснить человеку, почему сделала такую рекомендацию?»
 - Пример: Мы рекомендуем этот фильм, потому что вам понравились Начало и Матрица.

Мотивация

Мотивация

- Отладка и дебаг
- Улучшение метрик
- Повышает доверие пользователей
- Улучшает пользовательский опыт
- Повышает прозрачность сложных систем
- Анализ влияния признаков, понимание предпочтений
- Нормативные требования

Как это выглядит

Как это выглядит

ПОТОМУ ЧТО ВЫ ИНВЕСТИРОВАЛИ В Apple

	Starbucks STRB	0,07 \$ +0,01 \$ (1,34%)
	Dodo DO	0,07 \$ +0,01 \$ (1,34%)
	Goods GD	0,07 \$ +0,01 \$ (1,34%)

[Смотреть все](#)

Захватывающее кино >

Смотрят вместе с «Великий уравниатель»



Хитмэн: Агент 47
Подписка



Край
Подписка



Даркнет
Подписка



Вне/себя
Подписка

Покупают вместе

FLYDIGI ОФИЦИАЛЬНЫЙ фирменный магазин MICROSHOP

Комплект сменных стиков с металлическим кольцом для геймпадов FLYDIGI



Стики Flydigi предназначены для моделей: Vader 2, 3 Pro, microshop

[Скидки недели](#)

FLYDIGI ОФИЦИАЛЬНЫЙ фирменный магазин MICROSHOP

ОРИГИНАЛЬНЫЙ КЕЙС для ГЕЙМПАДОВ FLYDIGI



Для хранения и переноски геймпадов FLYDIGI серий APEX, Vader, Direwolf, Dune Fox, microshop

FLYDIGI ОФИЦИАЛЬНЫЙ фирменный магазин MICROSHOP

Зарядная станция Flydigi для геймпадов серий APEX / Vader



[Скидки недели](#)



N+1 N+1 ✓
Вы подписаны · 5 дней назад

Древние люди из зеленой Сахары принадлежали к ранее неизвестно...

Палеогенетики проанализировали ДНК двух древних людей,...

Виды объяснений

Виды объяснений

Model-agnostic

Post-hoc объяснения
рекомендаций

Model-intrinsic

Обучение объяснений
рекомендаций внутри
модели

Методы для объяснения рекомендаций

Подходы в объяснениях

Information/ style of the explanations	Methods for Explainable Recommendation							
	Neighbor- based	Matrix factorization	Topic modeling	Graph- based	Deep learning	Knowledge- based	Rule mining	Post- hoc
Relevant user or item	Herlocker <i>et al.</i> , 2000	Abdollahi and Nasraoui, 2017		Heckel <i>et al.</i> , 2017	Chen <i>et al.</i> , 2018c	Catherine <i>et al.</i> , 2017	Peake and Wang 2018	Cheng <i>et al.</i> , 2019a
User or item features	Vig <i>et al.</i> , 2009	Zhang <i>et al.</i> , 2014a	McAuley and Leskovec, 2013	He <i>et al.</i> , 2015	Seo <i>et al.</i> , 2017	Huang <i>et al.</i> , 2018	Davidson <i>et al.</i> , 2010	McInerney <i>et al.</i> , 2018
Textual sentence explanation		Zhang <i>et al.</i> , 2014a			Li <i>et al.</i> , 2017	Ai <i>et al.</i> , 2018	Balog <i>et al.</i> , 2019	Wang <i>et al.</i> , 2018d
Visual explanation					Chen <i>et al.</i> , 2019b			
Social explanation	Sharma and Cosley, 2013		Ren <i>et al.</i> , 2017	Park <i>et al.</i> , 2018				
Word cluster		Zhang, 2015	Wu and Ester 2015					

Подходы в объяснениях

Подход	Пример объяснения	Типы объяснения
MF, CF, user/item similarity, rule based	Покупателю советуют товар, потому что: 1. он купил такие-то товары (похожие, комплиментарные, встречаемые). Item-based. 2. похожие по истории покупок на него пользователи покупают эти товары / X% пользователей со схожими интересами оценили рекомендуемый товар. User-based. 3. конкретный признак товара важен для пользователя (EFM).	Есть список топ-k товаров, повлиявших на рекомендацию. Список соседей и их оценки. etc.
Content-based models, Knowledge-based graphs	Пользователю рекомендуют Титаник, потому что он посмотрел Forrest Gump, т.е. фильм с таким же свойством - например, жанром драма.	Объяснения через общие признаки по объектам, агрегации на графе по k близким соседям

Подходы в объяснениях

Подход	Пример объяснения	Типы объяснения
NN	Помимо примеров из предыдущих подходов: 1.Пользователю предлагается посетить ресторан, потому что в нем хорошая еда, вкусные стейки (пары (opinion-aspect) из отзывов ресторанов). 2. На основе сходства по общим предпочтениям похожих пользователей, их признаков и поведения (эмбединги) 3. Купите чехол для телефона, так как недавно вы купили Iphone 13.	Через контексты и паттерны, которые нельзя было уловить другими моделями (повторяемость, последовательность, частота, время).

Контентные методы

Контентные методы

Основная идея:

Объяснение строится на сравнении признаков рекомендованного объекта и интересов пользователя.

Контентные методы

Основная идея:

Объяснение строится на сравнении признаков рекомендованного объекта и интересов пользователя.

- У каждого объекта есть атрибуты (жанры, ключевые слова, авторы, характеристики, теги и пр.)
- У пользователя формируется профиль предпочтений на основе его истории взаимодействий
- Если система рекомендует объект, она может объяснить это тем, что объект соответствует профилю

Контентные методы

Основная идея:

Объяснение строится на сравнении признаков рекомендованного объекта и интересов пользователя.

- У каждого объекта есть атрибуты (жанры, ключевые слова, авторы, характеристики, теги и пр.)
- У пользователя формируется профиль предпочтений на основе его истории взаимодействий
- Если система рекомендует объект, она может объяснить это тем, что объект соответствует профилю

Примеры:

Вы читали книги в жанре научной фантастики. Эта книга — тоже научная фантастика.

Контентные методы

Основная идея:

Объяснение строится на сравнении признаков рекомендованного объекта и интересов пользователя.

- У каждого объекта есть атрибуты (жанры, ключевые слова, авторы, характеристики, теги и пр.)
- У пользователя формируется профиль предпочтений на основе его истории взаимодействий
- Если система рекомендует объект, она может объяснить это тем, что объект соответствует профилю

Примеры:

Вы читали книги в жанре научной фантастики. Эта книга — тоже научная фантастика.

Как сделать:

TF-IDF, BERT, doc2vec — для извлечения признаков из текста

cosine similarity / dot product — для оценки схожести

Колаборативные методы

Колаборативные методы

Основная идея:

Объяснение строится не на содержании объектов, а на поведении других пользователей или похожести между объектами

Колаборативные методы

Основная идея:

Объяснение строится не на содержании объектов, а на поведении других пользователей или похожести между объектами

1. User-based (пользователь-пользователь):

- «Пользователи, похожие на вас, также выбрали этот товар.»
- Используются методы коллаборативной фильтрации

2. Item-based (объект-объект):

- «Потому что вы смотрели Интерстеллар, вам может понравиться Контакт (по выбору других пользователей).»
- Применяются item-item similarity матрицы

Колаборативные методы

Основная идея:

Объяснение строится не на содержании объектов, а на поведении других пользователей или похожести между объектами

1. User-based (пользователь-пользователь):

- «Пользователи, похожие на вас, также выбрали этот товар.»
- Используются методы коллаборативной фильтрации

2. Item-based (объект-объект):

- «Потому что вы смотрели Интерстеллар, вам может понравиться Контакт (по выбору других пользователей).»
- Применяются item-item similarity матрицы

Примеры:

Вы поставили высокую оценку фильму Начало. 80% пользователей, которым он понравился, также любят Довод.

Колаборативные методы

Основная идея:

Объяснение строится не на содержании объектов, а на поведении других пользователей или похожести между объектами

1. User-based (пользователь-пользователь):

- «Пользователи, похожие на вас, также выбрали этот товар.»
- Используются методы коллаборативной фильтрации

2. Item-based (объект-объект):

- «Потому что вы смотрели Интерстеллар, вам может понравиться Контакт (по выбору других пользователей).»
- Применяются item-item similarity матрицы

Примеры:

Вы поставили высокую оценку фильму Начало. 80% пользователей, которым он понравился, также любят Довод.

Как сделать:

k-NN, ALS, NMF

Гибридные методы

Гибридные методы

Почему это сложно:

Современные модели (deep learning, графовые сети и т.п.) часто работают как "чёрные ящики" — сложно сразу понять, почему модель рекомендовала тот или иной объект.

Гибридные методы

Почему это сложно:

Современные модели (deep learning, графовые сети и т.п.) часто работают как "чёрные ящики" — сложно сразу понять, почему модель рекомендовала тот или иной объект.

Пост-хок объяснение:

- **LIME**: объяснение на уровне локальной аппроксимации модели
- **SHAP**: распределение вклада признаков в итоговую рекомендацию

Гибридные методы

Почему это сложно:

Современные модели (deep learning, графовые сети и т.п.) часто работают как "чёрные ящики" — сложно сразу понять, почему модель рекомендовала тот или иной объект.

Пост-хок объяснение:

- **LIME**: объяснение на уровне локальной аппроксимации модели
- **SHAP**: распределение вклада признаков в итоговую рекомендацию

Attention-механизмы:

- В self-attention можно отследить, на какие части пользовательской истории модель "обратила внимание"
- Пример: «Рекомендация основана в основном на этих 3 фильмах, которые вы смотрели ранее»

Гибридные методы

Почему это сложно:

Современные модели (deep learning, графовые сети и т.п.) часто работают как "чёрные ящики" — сложно сразу понять, почему модель рекомендовала тот или иной объект.

Пост-хок объяснение:

- **LIME**: объяснение на уровне локальной аппроксимации модели
- **SHAP**: распределение вклада признаков в итоговую рекомендацию

Attention-механизмы:

- В self-attention можно отследить, на какие части пользовательской истории модель "обратила внимание"
- Пример: «Рекомендация основана в основном на этих 3 фильмах, которые вы смотрели ранее»

GNN (Graph Neural Networks):

- Могут использовать пути в графе пользователей и объектов
- Объяснение через наиболее важные связи/узлы

Гибридные методы

Почему это сложно:

Современные модели (deep learning, графовые сети и т.п.) часто работают как "чёрные ящики" — сложно сразу понять, почему модель рекомендовала тот или иной объект.

Пост-хок объяснение:

- **LIME**: объяснение на уровне локальной аппроксимации модели
- **SHAP**: распределение вклада признаков в итоговую рекомендацию

Attention-механизмы:

- В self-attention можно отследить, на какие части пользовательской истории модель "обратила внимание"
- Пример: «Рекомендация основана в основном на этих 3 фильмах, которые вы смотрели ранее»

GNN (Graph Neural Networks):

- Могут использовать пути в графе пользователей и объектов
- Объяснение через наиболее важные связи/узлы

Генерация объяснений на естественном языке

- LLM

Алгоритмы для объяснения рекомендаций


item2item

item2item


- Потому что вам понравился товар X
- На практике очень часто используются i2i кандгены
 - похожее на последний лайк
 - похожее на автора из ваших подписок
 - из того же жанра что вам интересен
- Объяснение можно сделать по типу кандгена, откуда пришел кандидат

PDP(Partial Dependence) + ICE(Individual Conditional Expectation)

PDP + ICE


















PDP + ICE




SHAP



SHAP



SHAP



SHAP



Implicit ALS

Implicit ALS

		item			
user	1		1	1	
		1	1		1
		1		1	
	1		1		
	1	1	1		
				1	1
	1	1		1	
		n x m			

=

		factor		
user	0.1	0.3	0.4	
	0.3	-0.5	-0.2	
	0.1	-0.2	-0.3	
	0.7	0.5	-0.4	
	0.5	0.6	0.9	
	-0.9	-0.7	0.2	
	0.4	0.2	0.6	
		n x k		

x

item					factor
0.1	0.3	0.4	0.5	0.6	
0.1	0.2	0.3	0.1	-0.2	
0.9	-0.7	0.2	0.4	0.2	
k x m					

$$\min_{x_{\star}, y_{\star}} \sum_{r_{u,i} \text{ is known}} (r_{ui} - x_u^T y_i)^2 + \lambda (\|x_u\|^2 + \|y_i\|^2)$$
$$\min_{x_{\star}, y_{\star}} \sum_{u,i} c_{ui} (p_{ui} - x_u^T y_i)^2 + \lambda \left(\sum_u \|x_u\|^2 + \sum_i \|y_i\|^2 \right)$$

Implicit ALS. Объяснение рекомендаций

$$x_u = (Y^T C^u Y + \lambda I)^{-1} Y^T C^u p(u)$$


$$\hat{p}_{ui} = y_i^T x_u = y_i^T \underbrace{(Y^T C^u Y + \lambda I)^{-1} Y^T C^u}_{W^u} p(u)$$

$$s_{ij}^u = y_i^T W^u y_j$$

$$\hat{p}_{ui} = \sum_{j: r_{uj} > 0} s_{ij}^u c_{uj}$$

BertViz

BertViz




Learning Heterogeneous Knowledge Base Embeddings for Explainable Recommendation

Learning Heterogeneous Knowledge Base Embeddings for Explainable Recommendation

- Подход через knowledge graph
- Рекомендуем ipad потому что Боб покупал товары Apple и упоминал iOS

→ *Mention* → *Produced_by* → *Purchase*



LLM

Пользователь смотрел всю трилогию Властелин колец, матрицу, джентельмены и аватар, порекомендуй ему 5 фильмов и объясни эти рекомендации

📖 Memory updated

Вот пять фильмов, которые могут вам понравиться, исходя из того, что вы уже посмотрели:

1. **Интерстеллар (2014)** – Если вам понравилась «Матрица» своей философией и масштабом, «Интерстеллар» с его темами времени, пространства и человеческой природы будет интересен. Режиссёр Кристофер Нолан поднимает вопросы о выживании человечества, а также затрагивает идеи о любви и времени.
2. **Начало (2010)** – Еще один фильм Кристофера Нолана, который, как и «Матрица», исследует концепцию реальности и иллюзии. Это интеллектуальный триллер с интересными визуальными эффектами и нестандартным подходом к времени и восприятию.
3. **Темный рыцарь (2008)** – Если вам понравились экшен-сцены и более мрачная атмосфера в «Матрице» и «Джентльменах», «Темный рыцарь» (второй фильм из трилогии о Бэтмене) будет отличным выбором. Это фильм о морали, психологии и о борьбе между добром и злом.
4. **Гарри Поттер и философский камень (2001)** – Если вам нравится фэнтези, то возвращение в мир магии и приключений в первой части «Гарри Поттера» будет по духу схоже с «Властелином колец». Этот фильм наполнен эпическим размахом и волшебством.
5. **Прометей (2012)** – Если вам понравился «Аватар» своей визуальной красотой и идеей контакта с другими цивилизациями, то «Прометей» от Ридли Скотта исследует более философские вопросы, касающиеся происхождения человечества и встречи с инопланетными формами жизни.



Метрики и методы оценки

Метрики и методы оценки

Не всё, что логично для модели, понятно или убедительно для пользователя

Метрики и методы оценки

Не всё, что логично для модели, понятно или убедительно для пользователя

Как считать влияние объяснений:

Метрики и методы оценки

Не всё, что логично для модели, понятно или убедительно для пользователя

Как считать влияние объяснений:

- A/B тесты
- Косвенные метрики: CTR, время взаимодействия
- Опросы и анкетирование пользователей

Спасибо за внимание