
Курс: Рекомендательные системы

Лекция 16:

Контентные рекомендации на мультимодальных данных

Красильников Денис
13.05.25

Ресар: Зачем нужен контент



Ресар: Зачем нужен контент



1. Позволяет учитывать не только колаборативные сигналы
2. Возможность работать с новыми айтемами
3. Более «глубокий анализ» сущности айтем

Какие бывают данные



«Простые домены»

1. Текст
2. Картинка (одна)
3. Аудио
4. Просто фичи

«Сложные домены»

1. Видео
2. Несколько картинок

Не все модальности равнозначны!




Аудио < Текст < Картинки < Видео



софья
@tsveteniye




лайфхак для всех, кто ненавидит
голосовые





В чем идея мультимодальных рекомендательных систем?

1. Получить эмбединг для каждой модальности
2. Склеить их в один
3. Использовать, как основной эмбединг
4. Повторить для каждого айтема

Опционально: Можно нагенерить фичи из каждой модальности + из общего эмбединга, если используем град бустинг поверх мультимодальных моделей.



В чем идея мультимодальных рекомендательных систем?



Текстовый домен



1. Классика – Bag of Words и TF-IDF
2. Семантические модели – Word2Vec, GloVe
3. SOTA – TransformerBased эмбеддеры – BERT-like и другие



Личный топ для русского языка

- USER-bge-m3
- rubert-tiny2
- multilingual-e5-large

```
from sentence_transformers import SentenceTransformer

input_texts = [
    "Когда был спущен на воду первый миноносец «Спокойный»?",
    "Есть ли нефть в Удмуртии?",
    "Спокойный (эсминец)\nЗачислен в списки ВМФ СССР 19 августа 1952 года.",
    "Нефтепоисковые работы в Удмуртии были начаты сразу после Второй мировой войны"
]

model = SentenceTransformer("deepvk/USER-bge-m3")
embeddings = model.encode(input_texts, normalize_embeddings=True)
```



Картиночный домен

- Низкоуровневые признаки
- Сверточные нейросети (CNN)
- Vision Transformers




Картиночный домен: Что делать когда картинок несколько?

- Усреднять
- Брать только первую
- Оценивать каждую в отдельности (если используете как фичи)
- Обучать эмбеддер поверх этого дела
- Vision Transformers



Vision Language Encoder (VLM)


- CLIP
- Qwen2.5-VL
- SigLIP 2



Аудио домен



- MFCC (Mel-Frequency Cepstral Coefficients)
- Спектрограммы → CNN или трансформеры
- Предобученные аудиоэнкодеры
 - VGGish (Google)
 - YAMNet (YouTube аудио)
 - PANNs (Pretrained Audio Neural Networks)
 - CLAP (Contrastive Language-Audio Pretraining)



Видео домен




Видео сочетает сразу несколько потоков: визуальный (последовательность кадров) + аудио (звуковая дорожка), а иногда и встроенный текст (субтитры). Анализ видео – трудоемкая задача, поэтому часто используют упрощения.

- **Извлечение визуальных признаков из кадров**
- **Аудио и текст**
- **VideoCLIP (Microsoft)**
- **Timesformer / ViViT (Video Vision Transformers)**
- **SlowFast**
- **X3D, I3D, R(2+1)D**
- **CLIP4Clip / Flamingo (мультимодальные модели OpenAI/DeerMind)**

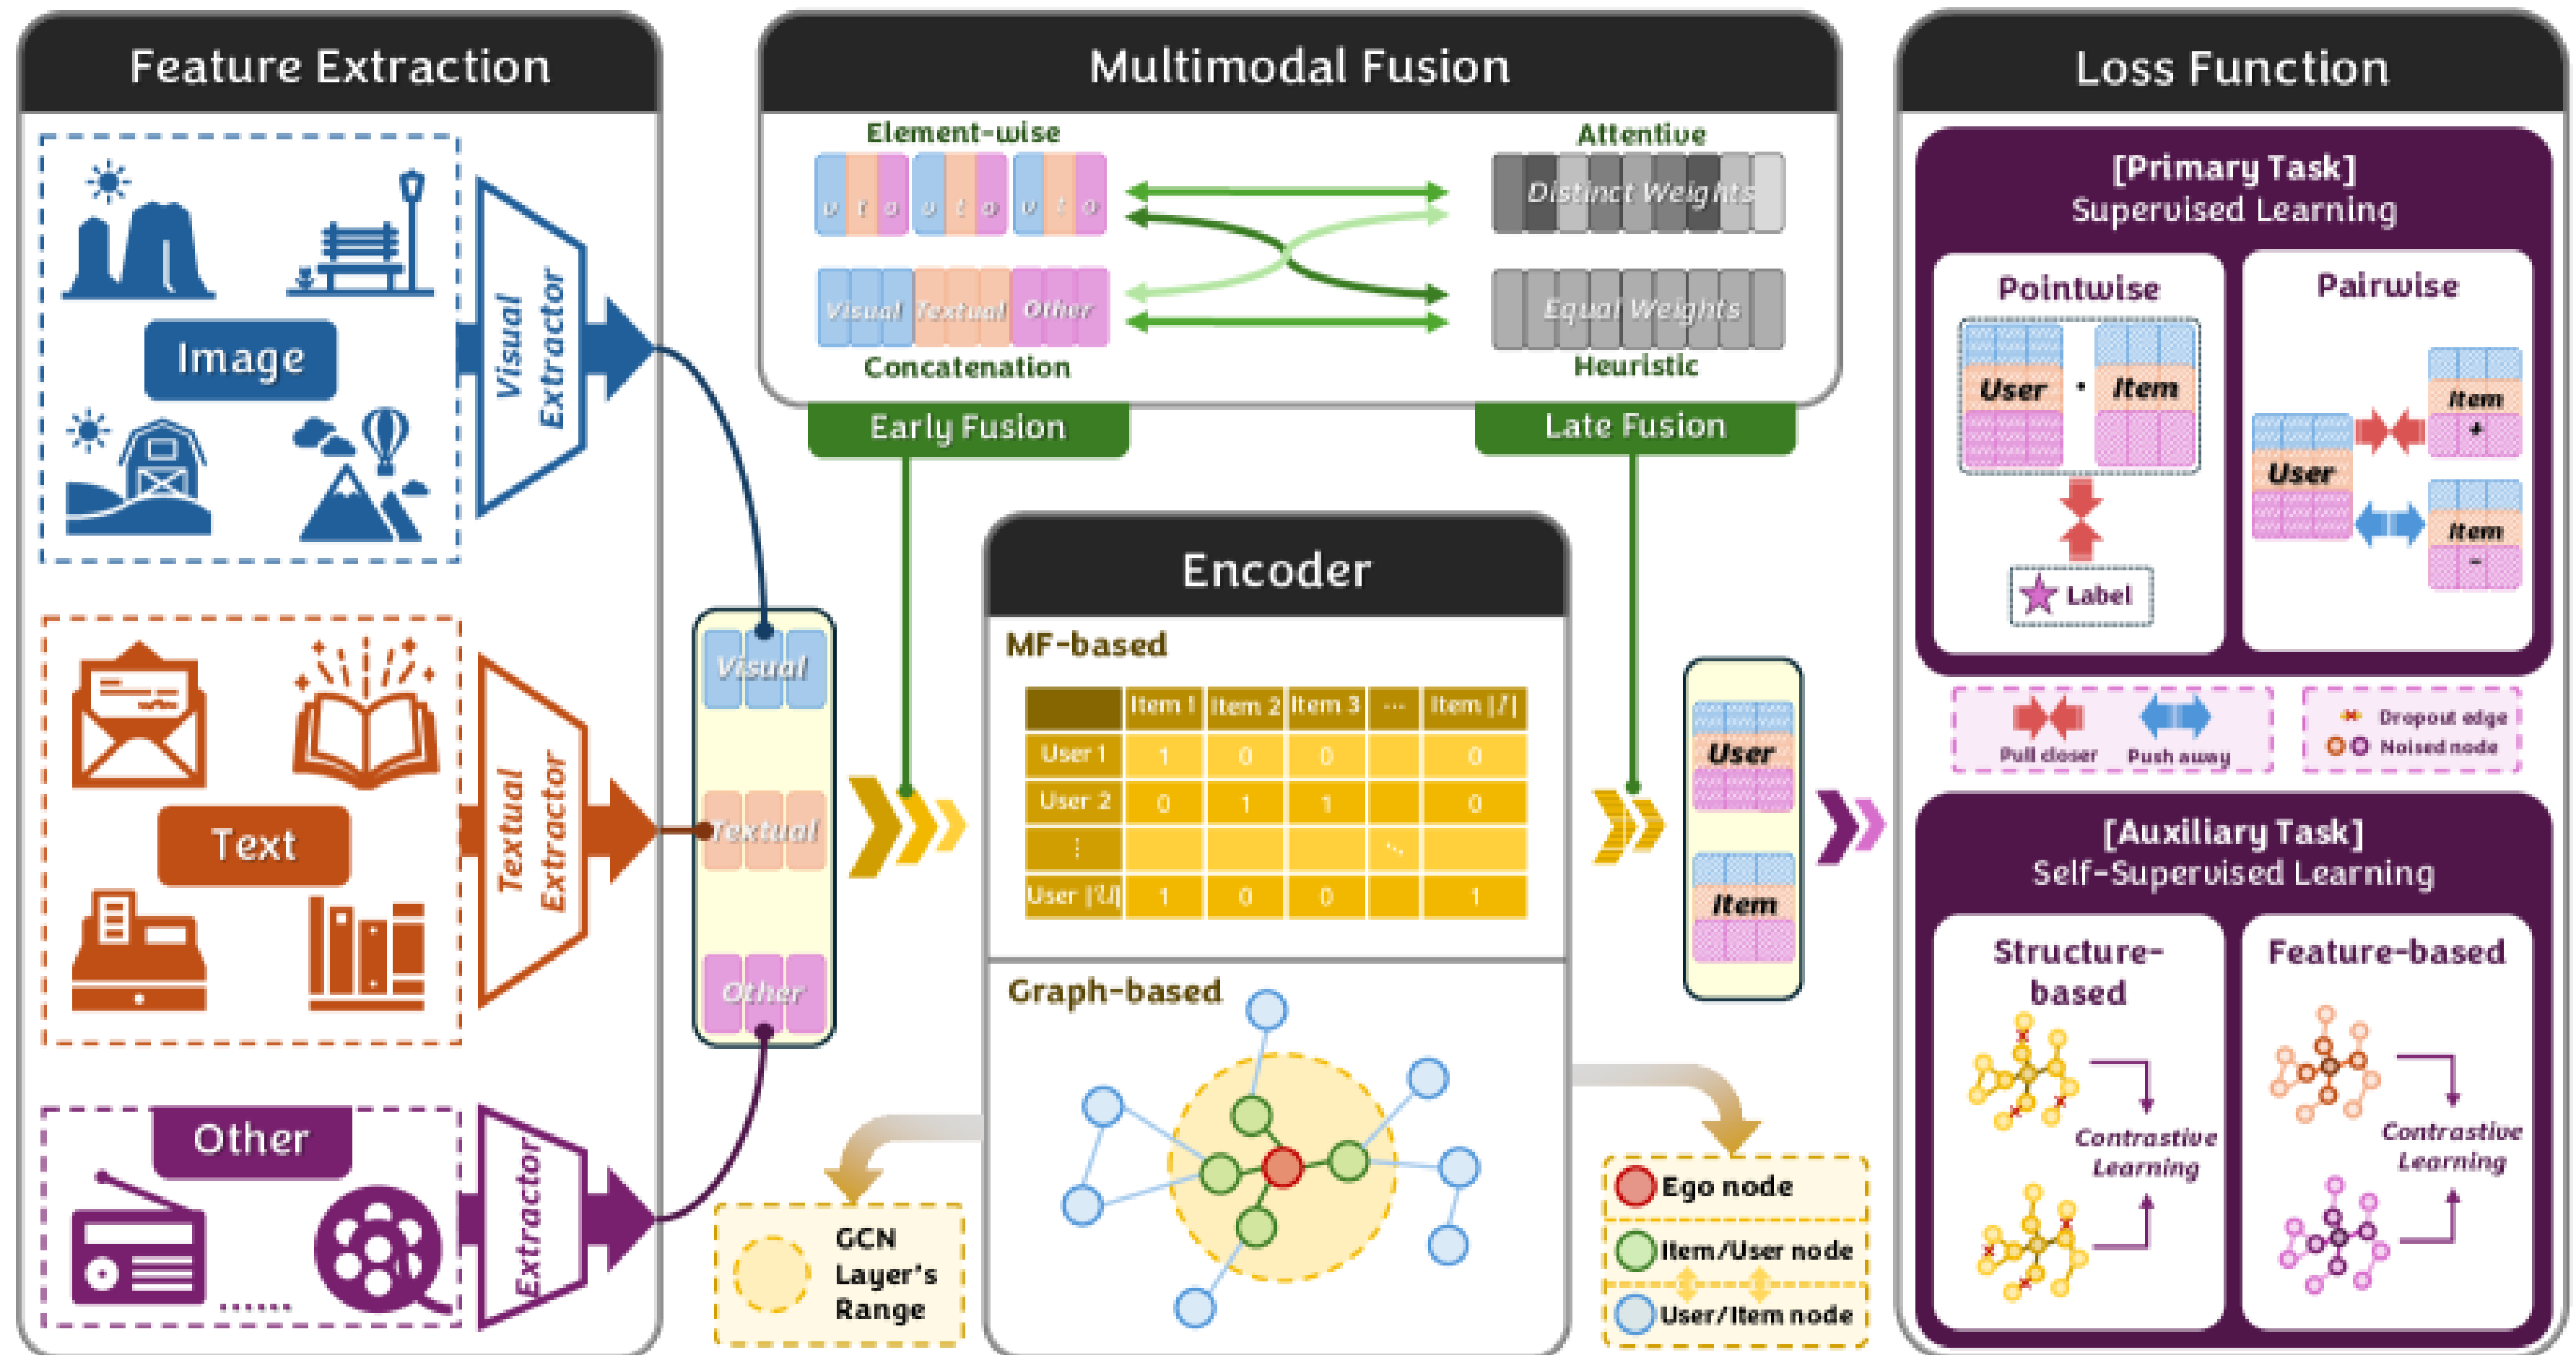


Связывание a.k.a fusion

- Early fusion – сначала объединяем, потом пропускаем через модель
- Late fusion – пропускаем через модель порознь, объединяем в конце (или почти в конце)
- Attentional fusion – выборочное связывание эмбеддингов




Связывание а.k.a fusion




Связывание а.k.a fusion

- Конкатенация
- Сумма
- MLP
- Линейная комбинация
- Attention based связывание




Архитектуры с межмодальным вниманием

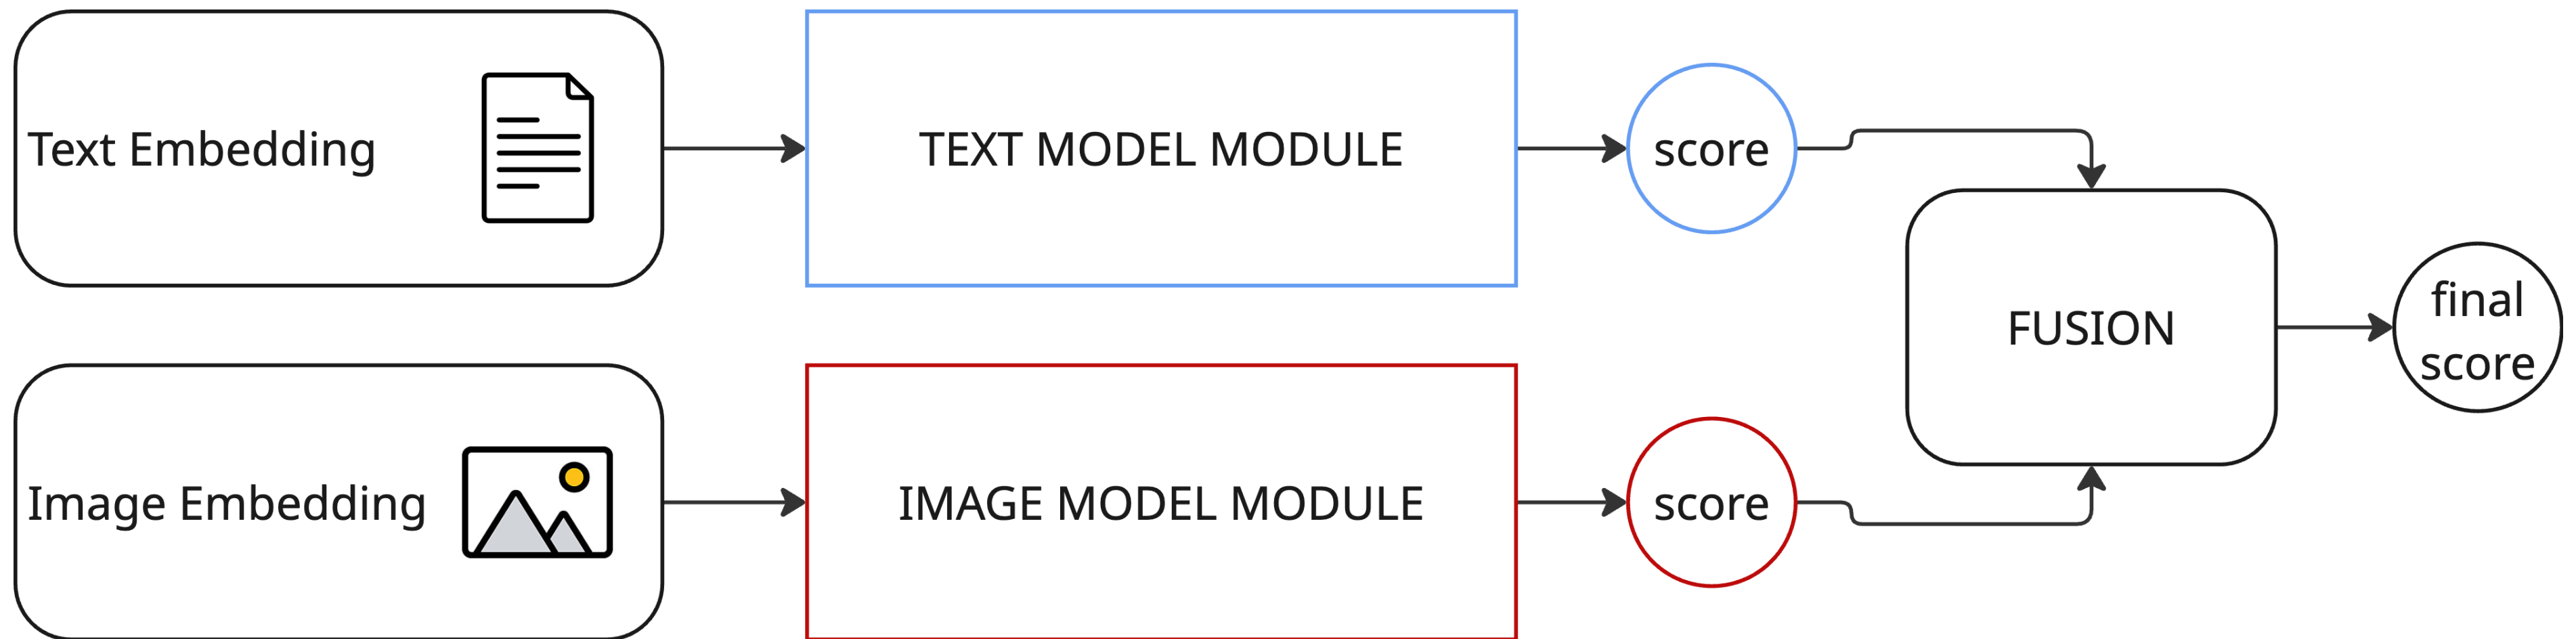
Из статьи [A Multimodal Recommender System Using Deep Learning Techniques Combining Review Texts and Images](#)




Early fusion




Late fusion




А что с пользователем?



А что с пользователем?



Как обработать признаки



Категориальные признаки

- nn.Embeddings a.k.a Look-up table


	Word Embeddings			
<i>cat</i> →	1.2	-0.1	4.3	3.2
<i>mat</i> →	0.4	2.5	-0.9	0.5
<i>on</i> →	2.1	0.3	0.1	0.4
...	...			

Категориальные признаки

- nn.Embeddings a.k.a Look-up table

- Для нескольких признаков:

конкатенация/суммирование



Категориальные признаки



- nn.Embeddings a.k.a Look-up table
- Для нескольких признаков:
конкатенация/суммирование
- При большом числе признаков
можно прибегнуть к хэш таблицам





Figure 1: Embedding methods for two categorical features. We highlight the lookup process for the first value v_1 of each feature. Hash tables randomly share representations within each feature, while Unified Embedding shares representations across features. To implement Unified Embedding with different dimensions (multi-size or variable-length), we perform multiple lookups and concatenate the results.

Из статьи [Unified Embedding: Battle-Tested Feature Representations for Web-Scale ML Systems](#)

Чем опасны обучаемые item_id?



- Нейросети учатся как запоминать наблюдаемые данные (**меморизация**), так и находить обобщенные закономерности (**генерализация**)
- Распределения категориальных признаков имеют тяжелые хвосты (**long-tailed distributions**) – большая часть значений встречается очень редко.
- Для редких значений сложно вывести какие-то общие паттерны (генерализация), но их просто запомнить (меморизация) ... модель начинает переобучаться.



Чем опасны обучаемые item_id?



Эмбеддинги, особенно для редких значений признаков, быстро “меморизируют” → переобучение за 1 эпоху.

Решения:

- Не использовать айдишники :)
- Регуляризация: L2, dropout, max-norm, freq-clipping
- Hashing trick (неявная регуляризация)
- Замораживать эмбеддинги после первой эпохи
- Сбрасывать матрицу эмбеддингов между эпохами





Figure 2: An illustration of testing user-weighted AUC for our industrial CTR prediction model when training for multiple epochs. The model performance falls rapidly at the beginning of the second epoch.

Towards Understanding the Overfitting Phenomenon of Deep Click-Through Rate Prediction Models

Вещественные признаки



Вещественные признаки (численные признаки с непрерывными значениями) нельзя просто засунуть в нейронку, т.к. нейросети чувствительны к:


- 1. Масштабу значений (Scale):**
- 2. Выбросы (Outliers):**
- 3. Распределение признаков:**
- 4. NAN's**

Log1p



Простая и популярная трансформация:

- $x \rightarrow \log x + 1$
- Уменьшает “скошенность” распределений (e.g., логнормальное распределение приводит к нормальному, а мы любим нормальные распределения в нейросетях!)
- “Сглаживает” разницу между значениями




x	1	2	3	10	100	10000
log(x + 1)	0.69	1.1	1.39	2.39	4.61	9.21

Sigmoid Squashing



Альтернатива Log1p – прогон через сигмоиду:

- $x \rightarrow \sigma ax + b$
- Сильно сглаживает выбросы, не требует клиппинга
- Изначально сигмоиды часто использовали в качестве функций активаций
- Важно нормализовывать входы перед сигмоидами, чтобы не было затухающих градиентов (из-за попадающих на “края” сигмоиды значений)
- Можно использовать **несколько сигмоид** с разными параметрами (a, b)



Функция распределения



Заменим значение признака на оценку распределения:


- $x \rightarrow P X \leq x$
- Приводит признак в **равномерное** распределение на $[0, 1]$
- Устраняет скошенность, выбросы
- Реализуется через квантильную аппроксимацию эмпирической функции распределения

Функция распределения




Для выражения **периодических зависимостей**:

- $x \rightarrow [\sin 2\pi c_1 x, \cos 2\pi c_1 x, \dots, \sin 2\pi c_n x, \cos 2\pi c_n x]$
- Коэффициенты c_i могут быть фиксированы или **обучаемы**
- Используют для обработки признаков, связанных с временем
- Что-то похожее делали для позиционных эмбеддингов в оригинальном трансформере



Квантование или бинаризация

- Разбиваем значения на **бины** по квантилям
- Каждому бину соответствует категория (номер бина)
- Это эквивалентно **кусочно-постоянному кодированию**




Квантование или бинаризация



$$x \rightarrow PLE(x)$$

- › Кодировем не только номер бина, но и где внутри него находимся
- › Сохраняем отношение порядка между бинами
- › SOTA-подход




Из статьи [On Embeddings for Numerical Features in Tabular Deep Learning](#)

Оптимизация и эффективность

End-2-end обучение как правило работает довольно плохо по нескольким причинам:

- Данных недостаточно, чтобы обучить тяжелые модели для модальностей
- Сигналы для обучения не всегда имеют прямую связь

Как правило энкодеры замораживают, либо дообучают последние слои




Оптимизация и эффективность



- Заморозка энкодеров
- Дистилляция знаний
- Иерархические модели
- Контрастивное обучение

Контрастивное обучение



Контрастивное обучение







Figure 1: The structure overview of the proposed BM3. Projections f_v and f_t , as well as predictor f_p , are all one-layer MLPs. The parameters of predictor f_p are shared in the Contrastive View Generator (bottom left) for ID embeddings and multi-modal latent representations.


Контрастивное обучение



Контрастивное обучение



Transfer Learning



Dataset	Metrics	DSSM			SASRec				Improv.
		IDRec	BERT _{base}	RoBERTa _{base}	IDRec	BERT _{small}	BERT _{base}	RoBERTa _{base}	
MIND	HR@10	3.58	2.68	3.07	17.71	18.50	18.23	18.68	+5.48%
	NDCG@10	1.69	1.21	1.35	9.52	9.94	9.73	10.02	+5.25%
HM	HR@10	4.93	1.49	1.87	6.84	6.67	6.97	7.24	+5.85%
	NDCG@10	2.93	0.75	0.94	4.01	3.56	3.80	3.98	-0.75%
Bili	HR@10	1.14	0.38	0.57	3.03	2.93	3.18	3.28	+8.25%
	NDCG@10	0.56	0.18	0.27	1.63	1.45	1.59	1.66	+1.84%

Сложности и вызовы



- Сложность извлечения признаков



Сложности и вызовы



- Сложность извлечения признаков
- Гетерогенность и синхронизация модальностей



Сложности и вызовы



- Сложность извлечения признаков
- Гетерогенность и синхронизация модальностей
- Шум и ненадежность данных



Сложности и вызовы



- Сложность извлечения признаков
- Гетерогенность и синхронизация модальностей
- Шум и ненадежность данных
- Разреженность взаимодействий все еще важна



Сложности и вызовы



- Сложность извлечения признаков
- Гетерогенность и синхронизация модальностей
- Шум и ненадежность данных
- Разреженность взаимодействий все еще важна
- Интерпретируемость и объяснения



Сложности и вызовы



- Сложность извлечения признаков
- Гетерогенность и синхронизация модальностей
- Шум и ненадежность данных
- Разреженность взаимодействий все еще важна
- Интерпретируемость и объяснения
- Производительность и масштабируемость



Сложности и вызовы



- Сложность извлечения признаков
- Гетерогенность и синхронизация модальностей
- Шум и ненадежность данных
- Разреженность взаимодействий все еще важна
- Интерпретируемость и объяснения
- Производительность и масштабируемость
- Этические аспекты



How to build it?



1. Всегда идите от простого к сложному

How to build it?



1. Всегда идите от простого к сложному
2. Используйте предобученные модели и эмбединги

How to build it?



1. Всегда идите от простого к сложному
2. Используйте предобученные модели и эмбединги
3. Подгоняйте предобученные модели под свою задачу

How to build it?



1. Всегда идите от простого к сложному
2. Используйте предобученные модели и эмбединги
3. Подгоняйте предобученные модели под свою задачу
4. Нормализация и масштабирование признаков

How to build it?



1. Всегда идите от простого к сложному
2. Используйте предобученные модели и эмбединги
3. Подгоняйте предобученные модели под свою задачу
4. Нормализация и масштабирование признаков
5. Комбинируйте контентные и коллаборативные признаки

How to build it?



1. Всегда идите от простого к сложному
2. Используйте предобученные модели и эмбединги
3. Подгоняйте предобученные модели под свою задачу
4. Нормализация и масштабирование признаков
5. Комбинируйте контентные и коллаборативные признаки
6. Валидация и интерпретация

How to build it?



Что НЕ делать!

1. Игнорирование качества данных

How to build it?



Что НЕ делать!

1. Игнорирование качества данных
2. Перекос в пользу одной модальности

How to build it?



Что НЕ делать!

1. Игнорирование качества данных
2. Перекос в пользу одной модальности
3. Отсутствие стратегии для пропусков

How to build it?



Что НЕ делать!

1. Игнорирование качества данных
2. Перекос в пользу одной модальности
3. Отсутствие стратегии для пропусков
4. Чрезмерно сложная модель на малых данных

- Multimodal Recommender Systems: A Survey
- On Embeddings for Numerical Features in Tabular Deep Learning
- Towards Understanding the Overfitting Phenomenon of Deep Click-Through Rate Prediction Models
- Unified Embedding: Battle-Tested Feature Representations for Web-Scale ML Systems
- A Multimodal Recommender System Using Deep Learning Techniques Combining Review Texts and Images
- DiffCL: A Diffusion-Based Contrastive Learning Framework with Semantic Alignment for Multimodal Recommendations
- Latent Structure Mining with Contrastive Modality Fusion for Multimedia Recommendation
- Bootstrap Latent Representations for Multi-modal Recommendation
- Multimodal Pre-training for Sequential Recommendation via Contrastive Learning
- **Кладезь подходов:** <https://github.com/enоче/MultimodalRecSys>

Спасибо за
внимание