

---

# Курс: Рекомендательные системы

## Занятие 16:

### Доменные и кросс-доменные рекомендации

Лашинин Олег

13.05.26

# Почему сегодня эта тема?

В разных доменах появляются отличия архитектур, а в кросс доменности могут быть хорошие эффекты

# План занятия

- Про кросс-доменные рекомендации
- Про домены:
  - Видео (короткие + длинные)
  - Музыка
  - Банковские продукты
  - E-com non fmcg/fmcg
  - Тревел
  - Social feeds

# Что такое домен?

**Домен данных** – класс (вид) айтемов с определенными свойствами.

В домене могут быть свои специфичные проблемы и подходы.


Примеры доменов: музыка, короткие видео, e-commerce, статьи, транзакции.

Знания по recsys: общие знания + доменозависимые.

Если человек – эксперт в домене, он может быстрее и более качественно собирать recsys системы. Потому что подразумевается, что между доменами хорошо работают похожие подходы.



# Экосистемные данные на примере Т-Банка



История одного клиента = цепочка событий (events) из разных доменов

Домен транзакций: сумма, магазин, mcc-code, категория, время транзакции, расчетный счет, вид транзакции

Покупка акций: название компании, количество акций, цена покупки, комиссия, время покупки


Бронирование отеля: название отеля, место отеля, количество гостей, даты бронирования, сам отель

Билет на самолет: откуда и куда, когда, компания, класс обслуживания, цена покупки

Активация кэшбека: что за категория, какой процент был у категории, когда активировал


Взятие кредита: сумма, процентная ставка, время кредитования, ПВ

# Экосистемные данные на примере Т-Банка




Что можно порекомендовать человеку из сервисов Т-Банка?

- что-то из детских товаров в сервисе Шопинг
- Вклад как банковский продукт
- Туристические товары (в зависимости от города отеля) в сервисе Шопинг
- какие-то концерты в Афише
- поступить в Центральный университет



# Чем больше разных данных, тем лучше



Эффект экосистемы: знаем о клиенте больше, и больше знаний используем для рекомендаций в конечных сервисах.

Каждый сервис – отдельный продукт (бизнес), который имеет N сотрудников, свою линию развития. Но если это в рамках экосистемы, то до этих данных может быть просто дотянуться, а может быть и сложно (зависит от компании).

Еще одна мысль: в данных скорее важна триггерная природа.

- Забронировал отель? Вот тебе билеты на самолет. Вот тебе страховка
- Активировал кэшбек на концерты? Купи в нашем сервисе Афиша
- Взял образовательный кредит? Поступай в центральный университет.

Не любое событие ценно для другого продукта!

# Пример несвязанных данных



Я

kia k5 купить

✕

🔊

📷

⚙️

Поиск

Алиса AI

Картинки

Видео

Карты

Товары

Финансы

Квартиры

Переводчик

Все

Купить: kia k5 купить

Каталог товаров

Kia K5 2020 - купить автомобиль на...

107 000 км, седан

auto.ru

АВТОГРАФФ

2.0 л, Мощность: 150 л.с...

1339 000 ₽

Купить Kia K5 III 2020

53 218 км

avto-graff.ru

Каталог товаров

Kia K5 по выгодной цене

avantaauto.ru

б/у Kia K5, Объем: 2.0 л, ...

1799 000 ₽

Kia K5 2022 с пробегом: выгода д...

Седан

ac-kronos-ms...

АВТОГРАФФ

2.5 л, 194 л.с., Год выпус...

1939 000 ₽

Купить Kia K5 2022 с пробегом

32 438 км

avto-graff.ru

Рекомендации

Новые автомобили со скидками в наличии

Большой выбор моделей, гарантия от официальных дилеров

Выбрать

3 034 000 ₽

Volvo V90 Cross Country I

2018 / 150 264 км

2 149 000 ₽

Mercedes-Benz E-Класс 400 IV (W...

2015 / 178 027 км

55 555 000 ₽

Dodge Charger R\_T II

1970 / 1 009 км

2 500 000 ₽

BMW X4 2011 (F26)

2015 / 116 000 км

3 260 000 ₽

Mercedes-Benz GLB 220 d I (X247)

2020 / 100 300 км

13 000 000 ₽

Mercedes-Benz S-Класс 600 III (W1...

1998 / 150 000 км

3 678 483 ₽

Zeekr 001 100 kWh I Рестайлинг 1

2025 / 5 900 км

2 000 000 ₽

Volvo 850

1997 / 85 000 км

Не учитывается мой интент между сервисами




# Пример того, как отличаются рекомендации и как влияет недостаток данных




## Примеры несвязанных рекомендаций

Здесь покупаю



Здесь не покупаю






# Еще один пример




## Примеры несвязанных рекомендаций

Здесь покупаю



Здесь не покупаю








# Пример того, что рек системы похожие

## Примеры несвязанных рекомендаций

Данные были изначально

Я «помог» системе данными





# Вывод по примерам

Данные могут помочь определить запрос (интент) человека на покупку, поэтому за них могут платить.

Компании могут обмениваться данными, у такого обмена должен быть положительный  $PNL = \text{profit}$  (доп. Доход от данных) –  $\text{loss}$  (стоимость покупки данных).

Еще один пример: вы посмотрели что-то на сайте, и потом вам звонят с рекламным предложением – возможно триггерная система обмена данными.

В рамках экосистемы то же, но легче/дешевле получить данные.



# Теоретический пример про триггеры

Вы покупаете триггер по клиенту, один триггер стоит 5 рублей + его обработка еще 25 рублей (зарплата оператору).

В день вы закупаете 20000 триггеров (600 0000 рублей).

По триггерам в день вы делаете продажи на 1 000 000. Итого на этом процессе каждый день зарабатываете 400 000,  $pnI > 0$ , процесс хороший

# Теоретический пример про триггеры


Вы покупаете триггер по клиенту, один триггер стоит 5 рублей + его обработка еще 25 рублей (зарплата оператору).

В день вы закупаете 20000 триггеров (600 0000 рублей).

По триггерам в день вы делаете продажи на 1 000 000. Итого на этом процессе каждый день зарабатываете 400 000,  $pnI > 0$ , процесс хороший




# Сформулируем +- общий подход



## Алгоритм:

- 1) Собираем данные о юзере в одну цепочку, отсортированную по времени. Включаем свои данные и триггеры
- 2) Формируем для каждого клиента базис:
  - 1) **Client\_id**
  - 2) **Timestamp**
  - 3) **Target**
- 3) Для каждого сэмпла из базиса можем брать некоторые события до timestamp
- 4) Каждый event кодируем определенным образом в эмбединг
- 5) Последовательность эмбедингов прогоняем через transformer layer
- 6) Берем последнее событие и трактуем его как вектор юзера (SASRec-like подход)
- 7) Из вектора юзера строим «проектор» в нужную задачу:
  - 1) Регрессия
  - 2) Классификация
  - 3) Ранжирование
  - 4) Кандидатогенерация (sasrec-like)
  - 5) Uplift-моделирование

# Как нам кодировать события в эмбединги?



История одного клиента = цепочка событий (events) из разных доменов

Домен транзакций: сумма, магазин, mcc-code, категория, время транзакции, расчетный счет, вид транзакции

Покупка акций: название компании, количество акций, цена покупки, комиссия, время покупки


Бронирование отеля: название отеля, место отеля, количество гостей, даты бронирования, сам отель

Билет на самолет: откуда и куда, когда, компания, класс обслуживания, цена покупки

Активация кэшбека: что за категория, какой процент был у категории, когда активировал

Взятие кредита: сумма, процентная ставка, время кредитования, ПВ

# Как нам кодировать события в эмбединги?



Один из подходов: событие – это множество «фичей», каждая фича это:

- числовое значение
- категориальное значение (класс)
- текстовое значение
- некоторый эмбединг.

«Некоторый эмбединг» открывает пространство для маневра, так как это может быть все что угодно. Например, эмбединг видео, эмбединг от LLM, картиночный эмбединг и тд.




# Как нам кодировать события в эмбединги?

Время


## Детальнее про PLE и BPE

Два способа кодирования числовых и текстовых признаков в эмбединги




Оба подхода переводят разные типы признаков в общий embedding space

# Как нам кодировать события в эмбединги?






# Про «голову» для рекомендаций на выходе




## Голова

«Ранжирование»






# Про «голову» для рекомендаций на выходе



## Голова

Отбор кандидатов




# Доклад про наш подход



Heteroseqs: как устроен фреймворк для трансформерной персонализации / Андрей Бабкин

177 просмотров · 6 месяцев назад

# В этот фреймворк укладывается большинство задач на трансформеры по юзерам



## Алгоритм:





- 1) Собираем данные о юзере в одну цепочку, отсортированную по времени. Включаем свои данные и триггеры
- 2) Формируем для каждого клиента базис:
  - 1) **Client\_id**
  - 2) **Timestamp**
  - 3) **Target**
- 3) Для каждого сэмпла из базиса можем брать некоторые события до timestamp
- 4) Каждый event кодируем определенным образом в эмбединг
- 5) Последовательность эмбедингов прогоняем через transformer layer
- 6) Берем последнее событие и трактуем его как вектор юзера (SASRec-like подход)
- 7) Из вектора юзера строим «проектор» в нужную задачу:
  - 1) Регрессия
  - 2) Классификация
  - 3) Ранжирование
  - 4) Кандидатогенерация (sasrec-like)
  - 5) Uplift-моделирование



# Про кросс-маркетные рекомендации продуктов




Ивент -> Купил квас в одном магазине -> он появился в рекомендациях в 4 разных магазинах других



# Почему тут не сработают классические подходы?




Разные несвязанные item\_id, но очень похожие



Трансформер понимает примерно, что человек купил в одном ретейлере молоко, и его возможно надо рекомендовать в другом ретейлере




# Почему тут не сработают классические подходы?



Пример схемы реализации фреймворка для конкретных кросс-маркетных рекомендаций



# End-2-end обучение или что-то фризим?



Наш опыт сводится к тому, что если данных достаточно, то текстовые эмбединги можно выучить с нуля (end-2-end).

Однако картиночные/видео/аудио эмбединги с нуля учить плохо, лучше использовать замороженные веса

# Какие есть гиперпараметры у подхода?

- 1) Множество источников событий по юзеру (что берем, а что бесполезно?)
- 2) Глубина событий, которые учитываем по юзеру (как ее ограничить?) по времени и по количеству ивентов?
- 3) Формирование базиса (=задача для ML), за какой период времени он собирается? Это **ДРУГОЕ с п. 2!**
- 4) Какой трансформер используем? Возможно: BERT/ModenBERT/HSTU/и другие
- 5) Какие параметры собираем по событиям, а какие бесполезны?

# Проблема «вымывания» истории юзера

Пусть длина контекста максимальная 512.

У юзера

- 400 транзакций по карте (не в сервисе)
- 400 кликов на товары
- 100 покупок товаров

Если взять последние 512 событий, то будет

- 50 покупок + 256 кликов + 206 покупок по карте.


Мы потеряем 50 покупок и 194 клика на товары. Это может быть важнее, чем 206 покупок по карте!

Тогда может быть выгоднее с точки зрения качества взять 100 покупок + 400 кликов + еще 12 транзакций по карте. То есть брать все события до порога в определенном приоритетном порядке.

В этом будет больше нужной доменной информации. Но конкретный алгоритм придется подбирать экспертно.




# Сможем ли SASRec, который учтет видео-контент?



| Модель                     | Тип эмбединга                                                                                                | Когда брать                                                                    |
|----------------------------|--------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------|
| VideoPrism                 | video encoder, можно использовать для retrieval/classification/captioning через frozen video representations | сильный общий video embedding baseline; хороший кандидат №1 для коротких видео |
| InternVideo / InternVideo2 | video foundation model, video-text + recognition                                                             | если нужен мощный general-purpose video representation и есть GPU              |
| LanguageBind               | общее пространство: video/audio/image/depth/text и др.                                                       | если важно video-text similarity и кросс-модальность                           |
| ImageBind                  | общее пространство: image/video, text, audio, depth, thermal, IMU                                            | если в коротких видео важен звук; но модель в первую очередь research-use      |

+ item\_id используем по видео

# А если у нас есть еще музыкальный контент?



| Модель                     | Тип эмбединга                                                                                                | Когда брать                                                                    |
|----------------------------|--------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------|
| VideoPrism                 | video encoder, можно использовать для retrieval/classification/captioning через frozen video representations | сильный общий video embedding baseline; хороший кандидат №1 для коротких видео |
| InternVideo / InternVideo2 | video foundation model, video-text + recognition                                                             | если нужен мощный general-purpose video representation и есть GPU              |
| LanguageBind               | общее пространство: video/audio/image/depth/text и др.                                                       | если важно video-text similarity и кросс-модальность                           |
| ImageBind                  | общее пространство: image/video, text, audio, depth, thermal, IMU                                            | если в коротких видео важен звук; но модель в первую очередь research-use      |

| Модель                  | Тип эмбединга                                         | Когда брать                                                                  |
|-------------------------|-------------------------------------------------------|------------------------------------------------------------------------------|
| MERT / MERT-v1-330M     | music-only SSL, frame/track embeddings                | главный baseline для music audio embeddings                                  |
| MuQ / MuQ-MuLan         | MuQ: music SSL; MuQ-MuLan: music-text joint embedding | если нужен современный SOTA-like music encoder или текстовый поиск по музыке |
| LAION-CLAP / CLAP Music | audio-text joint embedding                            | text-to-music search, zero-shot теги, mood/genre retrieval                   |
| Microsoft CLAP          | audio-text embedding                                  | general audio+music retrieval, zero-shot classification                      |
| Essentia Discogs-EffNet | music similarity / style embeddings                   | очень практично для похожих треков, жанров, catalog similarity               |

+ item\_id используем по видео и муз. трекам

# Саммари по подходу

- 1) Абстрактно обозначаем, что такое ML задача (базис), event (событие у клиента), бэкбон модель (трансформер) и голова под задачу
- 2) Обозначаем, как мы кодируем каждое свойство события и агрегацию по свойствам: умеем работать как с числами и категориями, так и с эмбедингами
- 3) Собираем нужные цепочки событий и обучаем их под нужные головы. Подбираем нужные нам кросс-доменные данные, которые положительно влияют на метрики



# Часть про домены



| Домен                   | Компании<br>зарубежом            | Компании в РФ                                  | Важна<br>новизна? | UGC/BGC | Метрики                                                  |
|-------------------------|----------------------------------|------------------------------------------------|-------------------|---------|----------------------------------------------------------|
| Музыка                  | Spotify, Apple, Deezer           | Яндекс Музыка, Звук, VK                        | И да и нет        | Ugc/bgc | Retention, время прослушивания                           |
| Длинные видео           | Youtube                          | BK. Видео, Rutube,<br>Яндекс+<br>Okko, Kion... | Скорее да         | ugc     | Retention, время просмотров, кликабельность              |
| Короткие видео (shorts) | Titktok, Kuaishou                | BK. Видео                                      | Точно да          | ugc     | Retention, время просмотров, кликабельность              |
| Картинки                | Pinterest                        | Яндекс картинки                                | Скорее да         | ugc     | Клики, добавления в избранное, retention                 |
| Social feeds            | LinkedIN, X                      | BK                                             | Да                | ugc     | Глубина скрола, engagement юзеров в ленту                |
| E-com non-fmcg          | Amazon, Taobao,<br>eBay          | Ozon/WB                                        | Скорее да         | bgc     | Средние чеки, покупки, конверсии в заказ                 |
| E-com fmcg              | Instacart, Walmart               | Я. Лавка, Самокат, BB                          | Скорее нет        | bgc     | Средние чеки, покупки, конверсии в заказ                 |
| Локации                 | Foursquare, Yelp,<br>Tripadvisor | Яндекс. Карты                                  | Скорее да         | bgc     | Клики/визиты/продажи показов                             |
| Банковские продукты     | Revolut, Bank of<br>America      | Все крупные банки                              | Скорее да         | bgc     | Pnl/NPV с утилизаций продуктов                           |
| Книги                   | Goodreads                        | KION Строки, Яндекс<br>книги, Литрес           | Скорее да         | bgc     | Дочитывания до конца, взаимодействия с<br>рекомендациями |
| Объявления              | OLX, eBay                        | Avito                                          | Да                | ugc     | Контакты с продавцами, покупки                           |
| Тревел                  | Booking                          | Островок, Яндекс.<br>Путешествия               | Скорее да         | bgc     | Конечные покупки (заказы)                                |

# Часть про домены

| Домен                   | Много ли айтемов | Обновляемость каталога | Бизнес правила по доступности айтемов                           | Является ли recsys core частью продукта? | Устаревание каталога |
|-------------------------|------------------|------------------------|-----------------------------------------------------------------|------------------------------------------|----------------------|
| Музыка                  | Много            | Средняя                | Скорее нет                                                      | Скорее да                                | Медленное            |
| Длинные видео           | Очень много      | Высокая                | Скорее нет, но может закончиться лицензия + контент по подписке | Скорее да                                | Среднее              |
| Короткие видео (shorts) | Очень много      | Высокая                | Скорее нет                                                      | Скорее да                                | Быстрое              |
| Картинки                | Очень много      | Высокая                | Скорее нет                                                      | Зависит от продукта                      | Среднее              |
| Social feeds            | Очень много      | Очень высокая          | Может быть немного                                              | Да                                       | Быстрое              |
| E-com non-fmcg          | Много            | Средняя                | Да, товары на складе кончаются + зона доставки товаров          | Нет (поиск)                              | Среднее              |
| E-com fmcg              | Немного          | Слабая                 | Да, товары на складе кончаются + зона доставки товаров          | Нет (поиск)                              | Медленное            |
| Локации                 | Много            | Слабая                 | Да, часть айтемов может быть закрыта                            | Скорее нет (поиск)                       | Медленное            |
| Банковские продукты     | Мало             | Очень слабая           | Да, не все продукты доступным всем людям                        | Скорее нет (другие каналы продаж)        | Медленное            |
| Книги                   | Много            | Средняя                | Скорее нет, но может быть контент по подписке                   | Засисит от продукта                      | Медленное            |
| Объявления              | Очень много      | Очень высокая          | Скорее нет                                                      | Скорее нет (поиск)                       | Быстрое              |
| Тревел                  | Немного          | Слабая                 | Да, могут кончится билеты или распроданы номера отеля           | Скорее нет (поиск)                       | Медленное            |

# Особенности домена видео

- 1) Один айтем – много времени юзера, важно не ошибиться, но бесплатный
- 2) Может быть связка с автором, а там может быть высокая повторяемость
- 3) Важно дискаверить интересы юзера. В случае youtube поиск довольно неиспользуемый, и рекомендации доминируют за счет качества
- 4) Контент очень динамичный, нужно быстро уметь рекомендовать новые видео любимого автора
- 5) Сильный implicit сигнал, сложнее учитывать удовлетворение юзера от контента.
- 6) У сериалов есть явная цепочка серий для next-item



# Видео рекомендации



Describe What You See with  
MLLMs to Enhance Video  
Recommendations, Spotify  
Research, 2025

Очень свежая линия: использовать MLLM, чтобы описывать видео/аудио текстом,  
затем подавать это в two-tower/SASRec. Важно для лекции: long-form видео трудно  
понимать только через id, а MLLM-описания помогают закрывать semantic gap.

Spotify Research

The Multimodal Large Language Model ability for video content recommendations (Video 9183)

The video is a dynamic and action-packed gameplay session from a mobile fighting game based on the popular anime series Naruto. The core content revolves around intense combat sequences featuring iconic characters like Minato Namikaze (Wave Shadow), Obito Uchiha, and Kakashi Hatake.

[...]

The video begins with “2000 years later”, suggesting [...] and a title card that sets the stage for an exciting battle involving these characters. The text suggests a humorous or light-hearted tone, possibly indicating a live stream or recorded gameplay session.

[...]

showcases various battles between these characters. [...] Obito uses his Sharingan eye to perform powerful ninjutsu attacks, creating explosive effects and dealing significant damage.

[...]

It provides an entertaining and engaging experience [...]

- World knowledge**  
General information about the game and characters (e.g. Sharingan attack's ability of the character Obito)
- Detailed contextualized descriptions**  
Specific details about the gameplay and the tone of the video (it is a live stream and it is humorous)
- OCR / Visual recognition**  
Text extracted from the video and visual elements recognized


Table 1: Performance of various modalities features on two widely used representative models: the two-towers and SAS-Rec. The results show that MLLM-generated descriptions improve the performance in these recommendation systems.

| Representation                           | HR@10         | HR@30         | nDCG@10       | nDCG@30       |
|------------------------------------------|---------------|---------------|---------------|---------------|
| Two-Towers (Youtube) [4]                 |               |               |               |               |
| Metadata                                 | 0.0414        | 0.0721        | 0.0214        | 0.0286        |
| Audio                                    | 0.0253        | 0.0439        | 0.0130        | 0.0173        |
| Video                                    | 0.0393        | 0.0729        | 0.0201        | 0.0280        |
| Metadata + video                         | 0.0428        | 0.0775        | 0.0222        | 0.0304        |
| MLLM audio                               | 0.0405        | 0.0742        | 0.0214        | 0.0294        |
| MLLM video                               | <b>0.0489</b> | <b>0.0879</b> | <b>0.0264</b> | <b>0.355</b>  |
| SASRec [10] (Generative recommendations) |               |               |               |               |
| Metadata                                 | 0.0460        | 0.0791        | 0.0249        | 0.0326        |
| Audio                                    | 0.0338        | 0.0555        | 0.0186        | 0.0237        |
| Video                                    | 0.0456        | 0.0829        | 0.0245        | 0.0332        |
| Metadata + video                         | 0.0462        | 0.0813        | 0.0246        | 0.0329        |
| MLLM audio                               | 0.0454        | 0.0816        | 0.0245        | 0.0330        |
| MLLM video                               | <b>0.0482</b> | <b>0.0877</b> | <b>0.0261</b> | <b>0.0353</b> |



# Видео рекомендации

## Recommending What Video to Watch Next: A Multitask Ranking System



# Видео рекомендации

## Deep Neural Networks for YouTube Recommendations

Paul Covington, Jay Adams, Emre Sargin  
Google  
Mountain View, CA  
{pcovington, jka, msargin}@google.com




Figure 3: Deep candidate generation model architecture showing embedded sparse features concatenated with dense features. Embeddings are averaged before concatenation to transform variable sized bags of sparse IDs into fixed-width vectors suitable for input to the hidden layers. All hidden layers are fully connected. In training, a cross-entropy loss is minimized with gradient descent on the output of the sampled softmax. At serving, an approximate nearest neighbor lookup is performed to generate hundreds of candidate video recommendations.



# Видео рекомендации

## Deep Neural Networks for YouTube Recommendations

Paul Covington, Jay Adams, Emre Sargin  
Google  
Mountain View, CA  
{pcovington, jka, msargin}@google.com




Figure 3: Deep candidate generation model architecture showing embedded sparse features concatenated with dense features. Embeddings are averaged before concatenation to transform variable sized bags of sparse IDs into fixed-width vectors suitable for input to the hidden layers. All hidden layers are fully connected. In training, a cross-entropy loss is minimized with gradient descent on the output of the sampled softmax. At serving, an approximate nearest neighbor lookup is performed to generate hundreds of candidate video recommendations.

Кандидатогенерация




Figure 7: Deep ranking network architecture depicting embedded categorical features (both univalent and multivalent) with shared embeddings and powers of normalized continuous features. All layers are fully connected. In practice, hundreds of features are fed into the network.

Ранжирование

# Видео рекомендации



## MTS Kion Implicit Contextualised Sequential Dataset for Movie Recommendation

Aleksandr Petrov  
a.petrov.1@research.gla.ac.uk  
University of Glasgow  
Glasgow, United Kingdom

Daria Tikhonovich  
daria.m.tikhonovich@gmail.com  
MTS  
Moscow, Russia

Ildar Safilo  
irsafilo@gmail.com  
MTS, Higher School of Economics  
Moscow, Russia

Dmitry Ignatov  
Higher School of Economics  
Moscow, Russia

Table 1: Quantitative characteristics of movie datasets

| Dataset Name  | Users          | Items         | Interactions     | Avg. Sequence Length | Sparsity     |
|---------------|----------------|---------------|------------------|----------------------|--------------|
| Netflix       | 480,189        | 17,770        | 100,480,507      | 209.25               | 98.82%       |
| Movielens-25M | 162,541        | 59,047        | 25,000,095       | 153.80               | 99.73%       |
| <b>Kion</b>   | <b>962,179</b> | <b>15,706</b> | <b>5,476,251</b> | <b>5.69</b>          | <b>99.9%</b> |

Table 2: Qualitative characteristics of movie datasets

| Dataset Name                  | Netflix             | Movielens-25M                     | Kion                                                                                                                                         |
|-------------------------------|---------------------|-----------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------|
| Type                          | Explicit (Ratings)  | Explicit (Rating)                 | Implicit (Interactions)                                                                                                                      |
| Interaction registration time | After watching      | After watching                    | At watching                                                                                                                                  |
| Interaction features          | Date, Rating        | Date, Rating                      | Date, Duration, Watched Percent                                                                                                              |
| User features                 | None                | None                              | Age, Income, Kids                                                                                                                            |
| Item features                 | Release Year, Title | Release Year, Title, Genres, Tags | Content Type, Title, Original Title, Release Year, Genres, Countries, For Kids, Age Rating, Studios, Directors, Actors, Description, Keyword |



# Видео рекомендации




denis-19 8 ноя 2024 в 11:03

## «VK Видео» запустил новую систему рекомендаций

1 мин 3К

Искусственный интеллект, Работа с видео\*, Машинное обучение\*, Облачные сервисы\*



Видеосервис «VK Видео» запустил новую систему рекомендаций. В компании сообщили Хабру, что обновлённый вариант построен на основе гибридной модели рекомендаций, лучше понимает интересы аудитории и предлагает более релевантный контент. Система анализирует содержание контента: жанр, динамику, качество видео, А также сигналы от пользователей, включая просмотры, лайки, комментарии, досматриваемость роликов и время, когда видео смотрят чаще всего.

HighLoad++

РАСПИСАНИЕ (PDF)

ДОКЛАДЫ

ДОКЛАДЧИКАМ

ЕЩЁ

Главная → Список тезисов

## Как KION формирует в Realtime персональные рекомендации и витрины

МТ

Архитектура

Python

Бэкэнд / другое

Рекомендации / ML

3 декабря, 15:50, Зал «О2. Пекин+Шанхай»



8K+

Охват за 30 дней

Подписаться

Okko

4,6 Оценка работодателя

61,48 Рейтинг

62 393 Подписчики



devpony 3 июн 2019 в 11:37

## Рекомендации в Okko: как заработать сотни миллионов, перемножив пару матриц

20 мин 36К

Блог компании Okko, Python\*, Алгоритмы\*, Искусственный интеллект, Машинное обучение\*



# Видео рекомендации




## LLMs for User Interest Exploration in Large-scale Recommendation Systems


Jianling Wang\*  
Google DeepMind  
Mountain View, CA, USA  
jianlingw@google.com

Haokai Lu\*  
Google DeepMind  
Mountain View, CA, USA  
haokai@google.com


Yifan Liu  
Google  
Mountain View, CA, USA  
yifanliu@google.com



(a) Control Generation Capability & Alignment Learning



(b) Novelty (x-axis) and Quality (y-axis) Comparison



(c) Improvement of UCI@N

Figure 4: (a) Model Finetuning Process. (b) and (c) Comparison between different recommenders in live experiments.

### Prompt

The short-form videos I watched most recently are in the following clusters:

**Cluster 1:** {*Bus, Truck, Road, Commercial vehicle, Bus Simulator Indonesia, Om Telolet Om, Accident, Motor vehicle, Hino Motors, Tour bus service*}

**Cluster 2:** {*Coconut, Banana, Fruit, Durian, Fruit, Oil palms, Mango, Jackfruit, Durian, Papaya*}.

Each cluster is described with salient phrases or entity names. With less than 30 words, generate a new and different short-form video cluster I will watch next with highly specific salient phrases or entity names, with a prefix that says "New cluster: "

### Label

New cluster: Sharks, Underwater environment, Underwater diving, Dolphin, Orca, Mermaid, Penguins, Whale, Fish, Ocean

Figure 2: Prompt for Novel Interest Prediction when  $K = 2$ .

# Видео рекомендации

В случае UGC контента важно растить авторов новых, чтобы их было больше и было хорошее покрытие по контенту.

Представьте два видеосервиса, на одном много релевантного контента для вас, на втором мало, какой сервис выберете?

А чтобы контента было много, надо растить авторов



В этом соревновании надо было угадать юзеров, которые провзаимодействуют с новым айтемом автора.

Контент нового айтема мало помогал в решении победителей!

# Видео рекомендации

В случае UGC контента важно растить авторов новых, чтобы их было больше и было хорошее покрытие по контенту.

Представьте два видеосервиса, на одном много релевантного контента для вас, на втором мало, какой сервис выберете?

А чтобы контента было много, надо растить авторов



В этом соревновании надо было угадать юзеров, которые провзаимодействуют с новым айтемом автора.

Контент нового айтема мало помогал в решении победителей!




# Видео рекомендации

 denis-19 17 ноя 2025 в 13:07

## VK внедрила в свои продукты технологии рекомендаций на базе ИИ для более точной персонализации контента

🕒 2 мин 👁 4.7K

Искусственный интеллект, Машинное обучение\*, Социальные сети, Контент и копирайтинг\*



VK [сообщила](#) о внедрении в продукты холдинга технологии глубокого понимания контента Discovery. В компании пояснили, что мультимодальная языковая модель (MMLM) интерпретирует сюжеты, кросс-форматная контентная модель понимает смысл контента, а рекомендательная система автоматически распознаёт персонажей на видео. Помимо «VK Видео» и внутренних задач поиска и аналитики, технологии ИИ будут использоваться в других продуктах VK с пользовательским (UGC) контентом — от коротких видео до музыки.

# Музыкальные рекомендации

**TABLE 1** | Overview of discussed research articles.

| Article                                  | Year | Network type      | Input data                                    | CF | CBF | Seq. |
|------------------------------------------|------|-------------------|-----------------------------------------------|----|-----|------|
| Mcfee and Lanckriet <a href="#">[21]</a> | 2011 | Markov chains     | Timbre, tags, familiarity                     |    | ✓   | ✓    |
| Chen et al. <a href="#">[22]</a>         | 2012 | Markov embeddings | Playlists                                     | ✓  |     | ✓    |
| van den Oord et al. <a href="#">[23]</a> | 2013 | CNN               | Spectrograms                                  | ✓  | ✓   |      |
| Wang and Wang <a href="#">[24]</a>       | 2014 | DBN               | Spectrograms                                  | ✓  | ✓   |      |
| Liang et al. <a href="#">[25]</a>        | 2015 | MLP               | MFCC                                          | ✓  | ✓   |      |
| Oramas et al. <a href="#">[26]</a>       | 2017 | MLP, CNN          | Biographies, spectrograms                     |    | ✓   |      |
| Sachdeva et al. <a href="#">[27]</a>     | 2018 | ANN, MLP, GRU     | Sessions, tags                                |    | ✓   | ✓    |
| Vall et al. <a href="#">[28]</a>         | 2018 | RNN               | Playlists                                     | ✓  |     | ✓    |
| Vall et al. <a href="#">[29]</a>         | 2019 | CNN               | Playlists, spectrograms, tags, listening logs |    | ✓   | ✓    |
| Lin et al. <a href="#">[30]</a>          | 2019 | ANN, RNN, GRU     | Playlists, graphs, lyrics, album cover images |    | ✓   | ✓    |

Column CF and CBF indicate whether the proposed solution uses collaborative filtering or content-based filtering (or both). Column Seq. identifies solutions that leverage sequential information in the training or prediction step.

# Музыкальные рекомендации



## Scaling Recommender Transformers to One Billion Parameters

Kirill Khrylchenko\*  
HSE University  
Moscow, Russia  
elightelol@gmail.com

Sergei Makeev  
Yandex  
Moscow, Russia  
neuralsrg@gmail.com

Artem Matveev  
Yandex, HSE University  
Moscow, Russia  
matfu21@ya.ru

Vladimir Baikalov\*  
ITMO University  
Saint-Petersburg, Russia  
nonameuntitled159@gmail.com




Figure 1: An overview of the pre-training architecture, which takes the user’s context-item-feedback history as input to a transformer. Two parallel heads produce next-item predictions and feedback predictions, respectively.

Table 3: ARGUS model scaling: from 3.2M to 1B parameters. Results are reported for pre-training and fine-tuning tasks. Parameter counts include encoder weights only.

| Encoder |               |         | Pre-train                                   |                 |                                                 | Ranking Fine-tune<br>(pair accuracy uplift) |         |
|---------|---------------|---------|---------------------------------------------|-----------------|-------------------------------------------------|---------------------------------------------|---------|
| Model   | Configuration | #Params | Feedback Prediction<br>(normalized entropy) |                 | Next-Item<br>Prediction<br>(normalized entropy) | Standalone                                  | Feature |
|         |               |         | Consumption                                 | Engagement      |                                                 |                                             |         |
| Mini    | L4 H256       | 3.2M    | 0.5830 (-0.00%)                             | 0.5855 (-0.00%) | 0.4777 (-0.00%)                                 | -7.49%                                      | +1.35%  |
| Small   | L6 H512       | 18.9M   | 0.5756 (-1.28%)                             | 0.5707 (-2.51%) | 0.4691 (-3.81%)                                 | -6.29%                                      | +1.82%  |
| Medium  | L10 H1024     | 126.0M  | 0.5690 (-2.41%)                             | 0.5556 (-5.10%) | 0.4502 (-7.68%)                                 | -5.33%                                      | +2.32%  |
| Large   | L20 H2048     | 1.007B  | 0.5631 (-3.43%)                             | 0.5436 (-7.15%) | 0.4372 (-10.36%)                                | -4.78%                                      | +2.66%  |
| HSTU    | L24 H1024     | 176.0M  | 0.5684 (-2.51%)                             | 0.5553 (-5.15%) | 0.4488 (-7.99%)                                 | -5.39%                                      | +2.34%  |

Table 6: Incremental online gains (A/B tests) from successive transformer-based models on our music streaming platform. “TLT” is total listening time, and “like likelihood” is the probability that a user presses “like” for a recommended item. Each row’s improvement is measured relative to the previous deployments, so gains are cumulative.

| Deployment         | Context Length | Encoder       |         | TLT    | Like Likelihood |
|--------------------|----------------|---------------|---------|--------|-----------------|
|                    |                | Configuration | #Params |        |                 |
| Offline V1         | 512            | L6 H512       | 18.9M   | +0.52% | +1.11%          |
| Offline V2         | 1024           | L6 H512       | 18.9M   | +1.00% | +0.73%          |
| Offline V3         | 1024           | L6 H512       | 18.9M   | +0.73% | +5.00%          |
| Real-time V1       | 1024           | L4 H256       | 3.2M    | +0.32% | +1.38%          |
| Offline V4 (ARGUS) | 8192           | L10 H1024     | 126.0M  | +2.26% | +6.37%          |



# Музыкальные рекомендации



## Yambda-5B — A Large-Scale Multi-modal Dataset for Ranking And Retrieval

|                                                          |                                                        |                                                             |
|----------------------------------------------------------|--------------------------------------------------------|-------------------------------------------------------------|
| Alexander Ploshkin<br>ploshkin@yandex-team.ru<br>Yandex  | Vladislav Tytskiy<br>tytskiy@yandex-team.ru<br>Yandex  | Alexey Pismenny<br>pismenny-alex@yandex-team.ru<br>Yandex   |
| Vladimir Baikarov<br>deadinside@yandex-team.ru<br>Yandex | Evgeny Taychinov<br>taychinov@yandex-team.ru<br>Yandex | Artem Permiakov<br>artpermiakov@yandex-team.ru<br>Yandex    |
| Daniil Burlakov<br>burlada@yandex.ru                     | Eugene Krofto<br>singleton@yandex-team.ru<br>Yandex    | Nikolay Savushkin<br>penguin-diver@yandex-team.ru<br>Yandex |

Table 3: Different Sizes of the Dataset

| Dataset     | Users     | Items     | Listens       | Likes      | Dislikes   |
|-------------|-----------|-----------|---------------|------------|------------|
| Yambda-50M  | 10,000    | 934,057   | 46,467,212    | 881,456    | 107,776    |
| Yambda-500M | 100,000   | 3,004,578 | 466,512,103   | 9,033,960  | 1,128,113  |
| Yambda-5B   | 1,000,000 | 9,390,623 | 4,649,567,411 | 89,334,605 | 11,579,143 |

Table 4: Dataset File Structure

| File                        | Schema                                                                                  |
|-----------------------------|-----------------------------------------------------------------------------------------|
| artist_item_mapping.parquet | artist_id, item_id                                                                      |
| album_item_mapping.parquet  | album_id, item_id                                                                       |
| embeddings.parquet          | item_id, embed, normalized_embed                                                        |
| {size}/listens.parquet      | uid, item_id, timestamp, is_organic, played_ratio_pct, track_length_seconds             |
| {size}/likes.parquet        | uid, item_id, timestamp, is_organic                                                     |
| {size}/dislikes.parquet     | uid, item_id, timestamp, is_organic                                                     |
| {size}/unlikes.parquet      | uid, item_id, timestamp, is_organic                                                     |
| {size}/undislikes.parquet   | uid, item_id, timestamp, is_organic                                                     |
| {size}/multi_event.parquet  | uid, item_id, timestamp, is_organic, played_ratio_pct, track_length_seconds, event_type |

Table 2: Recommendation-Driven Events Ratio

| Event     | Total         | Recommendation | Ratio  |
|-----------|---------------|----------------|--------|
| Listen    | 4,649,567,411 | 2,266,400,808  | 48.74% |
| Like      | 89,334,605    | 37,789,576     | 42.30% |
| Dislike   | 11,579,143    | 5,612,434      | 48.47% |
| Unlike    | 32,944,520    | 1,651,117      | 5.01%  |
| Undislike | 2,434,208     | 239,135        | 9.82%  |

Table 6: Evaluation Results on Listen<sub>+</sub>

| Dataset     | Model    | NDCG@10       | NDCG@100      | Recall@10     | Recall@100    | Coverage@10   | Coverage@100  |
|-------------|----------|---------------|---------------|---------------|---------------|---------------|---------------|
| Yambda-50M  | Random   | 0.0000        | 0.0000        | 0.0000        | 0.0002        | <b>0.1363</b> | <b>0.7692</b> |
|             | MostPop  | 0.0186        | 0.0249        | 0.0064        | 0.0321        | 0.0000        | 0.0002        |
|             | DecayPop | 0.0260        | 0.0323        | 0.0122        | 0.0479        | 0.0000        | 0.0002        |
|             | ItemKNN  | <b>0.0781</b> | <b>0.0934</b> | <b>0.0373</b> | <b>0.1297</b> | 0.0180        | 0.0874        |
|             | iALS     | 0.0407        | 0.0642        | 0.0128        | 0.0808        | 0.0044        | 0.0156        |
|             | BPR      | 0.0389        | 0.0641        | 0.0139        | 0.0836        | 0.0257        | 0.0999        |
|             | SANSA    | 0.0069        | 0.0095        | 0.0031        | 0.0137        | 0.0114        | 0.0730        |
|             | SASRec   | 0.0748        | 0.0764        | 0.0325        | 0.1026        | 0.0130        | 0.0310        |
| Yambda-500M | Random   | 0.0000        | 0.0000        | 0.0000        | 0.0000        | <b>0.3896</b> | <b>0.9928</b> |
|             | MostPop  | 0.0173        | 0.0237        | 0.0060        | 0.0309        | 0.0000        | 0.0001        |
|             | DecayPop | 0.0267        | 0.0340        | 0.0127        | 0.0505        | 0.0000        | 0.0001        |
|             | ItemKNN  | 0.0708        | 0.0771        | 0.0320        | 0.1049        | 0.0257        | 0.0917        |
|             | iALS     | 0.0384        | 0.0621        | 0.0131        | 0.0811        | 0.0022        | 0.0067        |
|             | BPR      | 0.0400        | 0.0652        | 0.0137        | 0.0861        | 0.0244        | 0.0758        |
|             | SANSA    | —             | —             | —             | —             | —             | —             |
|             | SASRec   | <b>0.0754</b> | <b>0.0884</b> | <b>0.0336</b> | <b>0.1240</b> | 0.0347        | 0.0824        |
| Yambda-5B   | Random   | 0.0000        | 0.0000        | 0.0000        | 0.0000        | <b>0.8207</b> | <b>1.0000</b> |
|             | MostPop  | 0.0175        | 0.0239        | 0.0062        | 0.0313        | 0.0000        | 0.0000        |
|             | DecayPop | 0.0271        | 0.0348        | 0.0130        | 0.0509        | 0.0000        | 0.0000        |
|             | ItemKNN  | —             | —             | —             | —             | —             | —             |
|             | iALS     | 0.0388        | 0.0628        | 0.0132        | 0.0816        | 0.0010        | 0.0027        |
|             | BPR      | 0.0408        | 0.0664        | 0.0141        | 0.0870        | 0.0179        | 0.0508        |
|             | SANSA    | —             | —             | —             | —             | —             | —             |
|             | SASRec   | <b>0.0647</b> | <b>0.0847</b> | <b>0.0289</b> | <b>0.1214</b> | 0.0212        | 0.0456        |



# Музыкальные рекомендации

## Yambda-5B — A Large-Scale Multi-modal Dataset for Ranking And Retrieval

|                                                          |                                                        |                                                             |
|----------------------------------------------------------|--------------------------------------------------------|-------------------------------------------------------------|
| Alexander Ploshkin<br>ploshkin@yandex-team.ru<br>Yandex  | Vladislav Tytskiy<br>tytskiy@yandex-team.ru<br>Yandex  | Alexey Pismenny<br>pismenny-alex@yandex-team.ru<br>Yandex   |
| Vladimir Baikarov<br>deadinside@yandex-team.ru<br>Yandex | Evgeny Taychinov<br>taychinov@yandex-team.ru<br>Yandex | Artem Permiakov<br>artpermiakov@yandex-team.ru<br>Yandex    |
| Daniil Burlakov<br>burlada@yandex.ru                     | Eugene Krofto<br>singleton@yandex-team.ru<br>Yandex    | Nikolay Savushkin<br>penguin-diver@yandex-team.ru<br>Yandex |


Table 3: Different Sizes of the Dataset

| Dataset     | Users     | Items     | Listens       | Likes      | Dislikes   |
|-------------|-----------|-----------|---------------|------------|------------|
| Yambda-50M  | 10,000    | 934,057   | 46,467,212    | 881,456    | 107,776    |
| Yambda-500M | 100,000   | 3,004,578 | 466,512,103   | 9,033,960  | 1,128,113  |
| Yambda-5B   | 1,000,000 | 9,390,623 | 4,649,567,411 | 89,334,605 | 11,579,143 |

Table 4: Dataset File Structure

| File                        | Schema                                                                                  |
|-----------------------------|-----------------------------------------------------------------------------------------|
| artist_item_mapping.parquet | artist_id, item_id                                                                      |
| album_item_mapping.parquet  | album_id, item_id                                                                       |
| embeddings.parquet          | item_id, embed, normalized_embed                                                        |
| {size}/listens.parquet      | uid, item_id, timestamp, is_organic, played_ratio_pct, track_length_seconds             |
| {size}/likes.parquet        | uid, item_id, timestamp, is_organic                                                     |
| {size}/dislikes.parquet     | uid, item_id, timestamp, is_organic                                                     |
| {size}/unlikes.parquet      | uid, item_id, timestamp, is_organic                                                     |
| {size}/undislikes.parquet   | uid, item_id, timestamp, is_organic                                                     |
| {size}/multi_event.parquet  | uid, item_id, timestamp, is_organic, played_ratio_pct, track_length_seconds, event_type |

Схема такая:



## Какие аугментации используют


Они специально делают музыкальные аугментации для raw audio: random crop, инверсия полярности, Gaussian noise, изменение gain, high-pass/low-pass фильтр, delay, pitch shift и reverb. Важная идея: модель не должна запоминать поверхностную форму волны, а должна выучить устойчивые музыкальные признаки — тембр, ритмику, гармоническую структуру, жанровые/инструментальные паттерны. [arXiv](#)

## Архитектура

В качестве encoder используется **SampleCNN** — 1D CNN по waveform. На вход подается примерно 2.67 секунды аудио: 59 049 samples при 22 050 Hz. Encoder выдаёт **512-мерный вектор** `h`. Затем поверх него ставится projection head, который переводит `h` в **128-мерный** `z`, и уже на `z` считается contrastive loss. [arXiv](#)

# Особенности домена музыки


- 1) есть понятная контентная составляющая
- 2) Есть также хорошие «категоризаторы» – жанр, исполнитель, язык
- 3) Важен контекст – тип поверхности, девайс, время суток и день недели, настройки рекомендаций
- 4) Может также применяться доступность ограниченная айтемов



Контекст




# Банковские продукты: особенности



- 1) Продуктов не так много
- 2) Все продукты связаны с денежной составляющей: сколько получает клиент, сколько получает банк
- 3) Утилизация продуктов проходит редко. Человек ~1 раз в жизни берет ипотеку.
- 4) Каждый продукт – это отдельная бизнес линия с 30-10000 сотрудников, возникает сильный конфликт интересов за внимание юзера
- 5) Потребление для пользователя может что-то стоить (он конкретно тратит деньги)
- 6) Не все пользователи одинаково «хороши» для продукта (некоторые клиенты невыгодны для продукта)
- 7) Есть очень разреженный и отложенный таргет по времени. То есть человек принимает решение про утилизацию через 30 дней после первого показа
- 8) Есть ограниченная возможность у пользователя на утилизации. Например, вряд ли пользователь одновременно возьмет кредит наличными, кредитную карту, кредит под залог недвижимости и ипотеку. Возникает каннибализация.
- 9) Есть много пользователей, по которым крайне мало данных «в домене», то есть модели типа ALS крайне мало полезны (на пользователя уникально может быть мало утилизированных продуктов)
- 10) Хотя тут и мало айтемов и редкие утилизации, задача может принести больше денег, чем более интересные recsys задачи

# Банковские продукты: единая модель персонализации



Источники цифровых следов:



- Профиль человека (фичи)
- Транзакции
- Клик-стрим СбербанкОнлайн
- Использование продуктов банка (события)
- История коммуникаций (события)
- ...

Каждое событие в источнике имеет свой набор полей:

|                |             |           |           |          |
|----------------|-------------|-----------|-----------|----------|
| f <sub>1</sub> | MCC         | Action ID | Item ID   | Item ID  |
| f <sub>2</sub> | Amount      | Page ID   | Action ID | Channel  |
| f <sub>3</sub> | Merchant ID | ...       | ...       | Response |
| f <sub>4</sub> | ...         |           |           | ...      |
| ...            |             |           |           |          |

## Архитектура модели: Sequence Engineering

Embedding = Token + Field + Positional





# Банковские продукты: единая модель персонализации



## Конфигурация

- Бизнес сценарий: активные коммуникации по предложению банковских продуктов в нескольких каналах (4 продукта)
- Запуск на [N] миллионов пользователей в несколько волн в течении 2-х месяцев
- Инференс модели в batch-режиме на каждую волну

+0.011%  
(uplift)    Рост CR в  
покупку продукта


1.4%    Рост NPV<sup>1</sup> активных  
коммуникаций

|        | ИСТОЧНИКИ                     | Product A             | Product B                    | Product C                    | Product D                    |           |
|--------|-------------------------------|-----------------------|------------------------------|------------------------------|------------------------------|-----------|
| (база) | Фичи и транзакции             | 0.7998                | 0.7863                       | 0.9062                       | 0.6951                       | } ROC AUC |
| +      | Использование продуктов банка | 0.7976                | 0.7885                       | 0.9081                       | 0.7121                       |           |
| +      | История коммуникаций          | 0.8032                | 0.7892                       | 0.9072                       | 0.7164                       |           |
| +      | Действия в приложении         | 0.8020 <span>—</span> | <b>0.8139</b> <span>↑</span> | <b>0.9131</b> <span>↑</span> | <b>0.7509</b> <span>↑</span> |           |



Банковские продукты: фундаментальная модель от Revolut





Region uk

Plan metal

Balance 6,012.54

Currency gbp

Age 25-35

Device iphone18,2

...

Evaluation Point

Timestamp

20-11-02 12:19:54

Created 20-11-02 12:19:54

Type card\_payment

Direction out

Amount 14.99

Currency gbp

Fee 0.00

Description metal plan

MCC 6012

...

log-seconds to the last event

18.95

day week mth

hour day day

12 1 2

Keys

Type Direction Amount Currency Fee Description MCC

6148 5729 9153 11847 9740 8964 739

Values

category category number category number text category

card\_payment out 14.99 gbp 0.00 metal plan 6012

category category number category number text category


card\_payment out 14.99 gbp 0.00 metal plan 6012

perc\_24 perc\_0 met al plan

27021 2892 7688 2259 7645 736 2687 1146 26965

Figure 3: **Tokenisation overview.** A raw event record is decomposed into a temporal coordinate, semantic types (keys), and values. Keys are always represented by one token, while values use type-specific tokenisation: numerical values are bucketised by percentile, categorical values map to a single token, and textual values are split into subword tokens. Some keys therefore expand to multiple value tokens, e.g., Description → met, al, plan. Time is encoded both as log-seconds to the last event and as calendar and time features derived from the timestamp. Profile state is encoded similarly to an event record.

# Банковские продукты: фундаментальная модель от Revolut



| Task             | Metric    | Baseline (ref.) | PRAGMA   |
|------------------|-----------|-----------------|----------|
| Credit scoring   | PR-AUC    | —               | +130.2 % |
|                  | ROC-AUC   | —               | +12.4 %  |
| Comm. engagement | PR-AUC    | —               | +79.4 %  |
|                  | ROC-AUC   | —               | +20.4 %  |
| External fraud   | Precision | —               | +16.7 %  |
|                  | Recall    | —               | +64.7 %  |
| Product rec.     | mAP       | —               | +40.5 %  |
| Recurrent txns   | $F_1$     | —               | +5.8 %   |
| Lifetime value   | PR-AUC    | —               | +1.8 %   |
|                  | ROC-AUC   | —               | +2.6 %   |

# Банковские продукты: фундаментальная модель от Revolut



| Task             | Metric  | PRAGMA-M       |         |
|------------------|---------|----------------|---------|
|                  |         | Scratch (ref.) | LoRA    |
| Comm. engagement | PR-AUC  | –              | +18.6 % |
|                  | ROC-AUC | –              | +5.0 %  |
| Credit scoring   | PR-AUC  | –              | +13.0 % |
|                  | ROC-AUC | –              | +1.6 %  |
| Product rec.     | mAP     | –              | +10.3 % |
| Recurrent txns   | $F_1$   | –              | +0.6 %  |
| Lifetime value   | PR-AUC  | –              | +0.4 %  |
|                  | ROC-AUC | –              | +0.3 %  |

Table 4: **Performance comparison of LoRA fine-tuning against task-specific models trained from scratch.** Relative performance is computed as (LoRA/Scratch – 1). LoRA consistently matches or exceeds the performance of full-parameter training from scratch.

| Model    | Params | Width              |                  | Depth   |       |         |       |
|----------|--------|--------------------|------------------|---------|-------|---------|-------|
|          |        | $d_{\text{model}}$ | $d_{\text{ffn}}$ | Profile | Event | History | Heads |
| PRAGMA-S | 10 M   | 192                | 768              | 1       | 5     | 2       | 3     |
| PRAGMA-M | 100 M  | 512                | 2048             | 3       | 16    | 6       | 8     |
| PRAGMA-L | 1 B    | 1024               | 4096             | 9       | 45    | 18      | 16    |

| Task             | Metric    | PRAGMA   |         |         |
|------------------|-----------|----------|---------|---------|
|                  |           | S (ref.) | M       | L       |
| External fraud   | Precision | –        | +12.0 % | +16.4 % |
|                  | Recall    | –        | +24.8 % | +23.5 % |
| Product rec.     | mAP       | –        | +18.9 % | +27.0 % |
| Credit scoring   | PR-AUC    | –        | +16.3 % | +35.2 % |
|                  | ROC-AUC   | –        | +3.6 %  | +5.8 %  |
| Lifetime value   | PR-AUC    | –        | +1.5 %  | +3.0 %  |
|                  | ROC-AUC   | –        | +1.7 %  | +3.4 %  |
| Comm. engagement | PR-AUC    | –        | +0.1 %  | +1.6 %  |
|                  | ROC-AUC   | –        | –1.8 %  | +0.7 %  |
| Recurrent txns   | $F_1$     | –        | +0.6 %  | +0.4 %  |

Table 3: **Model performance scales with parameter count.** The performance is relative to PRAGMA-S fine-tuned with LoRA and computed as (model/PRAGMA-S – 1).



# Есот рекомендации (non-fmcg)

- 1) Классические ALS/SASRec и графовые модели для рекомендаций
- 2) В академии много статей на Amazon датасетах по отзывам на товары, на них выпускаются важные recsys архитектуры
- 3) Товары могут иметь хорошую категоризацию, плюс числовые и текстовые описания, но каких-то более сложных доменов – нет
- 4) Каннибализация между поиском и recsys. Более релевантные рекомендации отбирают трафик у поиска, но в тотал метриках может не быть прироста
- 5) Поиск зачастую более релевантный, чем рекомендации, потому что в поиске люди пишут то, что они хотят
- 6) Может быть сильно выражена проблема между субъективной релевантностью и тем, что выучивает модель
- 7) Модели скорее триггерные, чем предвосхищают интент. Если вы купите холодильник в маркетплейсе, вам будет он еще долго рекомендоваться.
- 8) В каталогах много однотипных товаров, нужна диверсификация. Если в каталоге 1000 холодильников и юзеру нужны холодильники, то без доп. Правил ему порекомендуется 1000 холодильников подряд

# Есот рекомендации (fmcsг)

- 1) Задача интуитивно делится на предсказание повторных айтеров и новых айтеров для пользователя.
- 2) Каталог обновляется медленно, как устаревают айтеры, так и появляются новые
- 3) Важны зоны доставки товаров, не все товары можно доставить во все места
- 4) Корзины считаются неупорядоченными элементами, то есть порядок добавления товаров туда зачастую игнорируются
- 5) Точности предсказания повторных товаров не позволяют предсобрать корзину за пользователя, то есть мы никогда не уверены в том, что человек точно купит какой-то товар
- 6) Зачастую в разных магазинах есть одни и те же товары с разными item\_id, можно использовать либо текстовые представления для автоматического понимания этого, либо решать задачу матчинга. То есть строить единый каталог. Однако это сложная задача с почти гарантированной потерей точности
- 7) Юзеры в разных магазинах могут покупать разные айтеры, и популярности одинаковых айтеров могут варьироваться в зависимости от магазина. Пример – в одном магазине покупают овощи, в другом почти не покупают.

# Travel рекомендации (ранжирование)

**Что рекомендуем:** отели, направления, билеты, POI, маршруты, похожие объекты.

**Главные отличия домена:**

- **Низкая повторяемость item-level покупок:** пользователь редко бронирует один и тот же отель/поездку.
- **Контекст важнее user history:** даты, город, состав поездки, бюджет, device, фильтры, сезон.
- **Динамический inventory:** цена, наличие, правила отмены и доступность постоянно меняются.
- **Long decision journey:** пользователь может искать неделями до бронирования.
- **Marketplace constraints:** надо учитывать не только пользователя, но и host/hotel/supplier, маржу, availability, fairness.
- **География и маршруты:** расстояние, время в пути, часы работы, выполнимость itinerary.



# Social Feeds

## Методы:

- **Graph-based retrieval:** social graph, follow graph, user-user / user-author / item-item связи;
- **Multimodal content embeddings:** текст, картинки, видео, hashtags, topics, author features.
- **Multi-task ranking:** одновременно predict click, like, comment, share, dwell time, hide/report, follow.
- **Sequential / Transformer rankers:** учитывают историю feed-взаимодействий и текущую session intent.
- **Reranking:** diversity, freshness, fatigue control, exploration, баланс авторов и тем.

## Ключевые отличия от классических рекомендаций:

- Контент быстро устаревает → нужны real-time / near-real-time features.
- Сильный social graph: важен не только item, но и автор, связь с автором, сообщество.
- Много конфликтующих целей: engagement, retention, safety, creator health, diversity.
- Негативы шумные: “не кликнул” ≠ “не нравится” из-за position/exposure bias.
- Feed — двусторонняя платформа: нужно подбирать не только контент пользователю, но и аудиторию авторам.

Спасибо за  
внимание