



Курс: Рекомендательные системы

Занятие 17:

А/В тестирование рекомендательной
системы

План

- Оценка вспомогательных метрик качества рекомендаций (novelty, diversity, serendipity, coverage).
- Онлайн и оффлайн метрики, поиск проху метрик.
- Мониторинг стабильности и деградации модели. Проблема feedback loop
- Про АБ-тесты в рекомендательных системах. Использование многоруких бандитов как альтернативы А/В тестов
- Проблемы АБ-тестов в рекомендациях

Почему сегодня эта тема?

Чтобы развивать систему, нужно уметь сравнивать одну версию системы с другой

Дополнительные метрики оценки качества

Разбирали до этого:

Precision@k

Recall@k

MAP@k

NDCG@k

MRR

Новые:

Diversity

Novelty

Coverage

Serendipity

Не нужны ground truth примеры!

Diversity

Diversity показывает **разнообразие** рекомендаций

Разные виды разнообразия:

- Внутри одного списка рекомендация (**Intra-list**)
- Между списками рекомендаций пользователей (**Intra-user**)
- Между рекомендациями для одного юзера по времени (изменчивость рекомендаций)

Diversity

Diversity показывает **разнообразие** рекомендаций

$$\textit{Intra-list diversity} = \frac{1}{N} \sum_{i=1}^N \frac{\sum_{i \in R} \sum_{j \in R \setminus \{i\}} \text{dist}(i, j)}{|R|(|R| - 1)}$$

Smyth and McClave [2001]

Где R – список рекомендаций, $|R| > 1$.

Считаем среднее парное расстояние между айтемами в списке.

Требуются признаки/эмбеддинги/векторы рейтингов по айтемам для расчета.

Diversity

Diversity показывает **разнообразие** рекомендаций

$$\textit{Inter-list diversity} = \frac{\sum_{i,j,\{u_i,u_j\} \in I} (\textit{cosine_distance}(R_{u_i}, R_{u_j}))}{|I|}$$

$$\forall i < j, \{u_i, u_j\} \in I$$

Считаем среднее значение степени похожести между списками рекомендаций разных юзеров.

Diversity

Diversity показывает **разнообразие** рекомендаций

Недостатки метрики:

- Нет гарантии, что значение метрики скоррелировано с восприятием пользователей о разнообразии рекомендаций при виде списка

Diversity

Diversity показывает **разнообразие** рекомендаций

Недостатки метрики:

- Нет гарантии, что значение метрики скоррелировано с восприятием пользователей о разнообразии рекомендаций при виде списка
- Значение сильно зависит от выбора метрики схожести и собранного вектора айтемов

Diversity

Diversity показывает **разнообразие** рекомендаций

Недостатки метрики:

- Нет гарантии, что значение метрики скоррелировано с восприятием пользователей о разнообразии рекомендаций при виде списка
- Значение сильно зависит от выбора метрики схожести и собранного вектора айтемов
- Как и другие метрики, чувствительна к длине списка рекомендаций

Diversity

Diversity показывает **разнообразие** рекомендаций

Недостатки метрики:

- Нет гарантии, что значение метрики скоррелировано с восприятием пользователей о разнообразии рекомендаций при виде списка
- Значение сильно зависит от выбора метрики схожести и собранного вектора айтемов
- Как и другие метрики, чувствительна к длине списка рекомендаций
- Желательно сравнение с дополнительными бенчмарками. Например, сравнение распределения рандомного сэмплирования (квотирования) разных категорий айтемов против распределения из модели

Diversity & Accuracy trade-off

Чем выше разнообразие – тем ниже релевантность

Нюансы:

- Если у пользователя богатый профиль предпочтений, т.е. много типов/категорий и самих айтемов ему релевантны.
- Не всем пользователям нужно максимизировать разнообразие, т.к. у них могут быть узкие интересы, высокая частота повторяемости одинаковых айтемов и низкий discovery (exploration).

Diversity & Accuracy trade-off


MMR selects items iteratively by solving the following greedy optimization problem:

$$i^* = \arg \max_{i \in C \setminus D} \left(\lambda \cdot \text{Rel}(i, q) - (1 - \lambda) \cdot \max_{j \in D} \text{Sim}(i, j) \right)$$

At each step, the selected item i^* is added to D , and the process repeats until $k = |D|$ items are chosen. Where:

- q : The query.
- C : The set of candidate items.
- D : The set of already-selected items (initially $D = \emptyset$).
- $\text{Rel}(i, q)$: Relevance score of item i to query q .
- $\text{Sim}(i, j)$: Similarity score between item i and selected item j .
- $\lambda \in [0, 1]$: Relevance-diversity trade-off parameter.

Diversity & Accuracy trade-off



Serendipity

Показывает, насколько рекомендации понравились, хотя пользователь сам такие айтемы не искал. Эффект. **сюрприза и угадывания релевантности**

Айтем будет обладать таким свойством, если:

- Алгоритм (классификатор) выдает нейтральный скор релевантности [laquinta et al. 2008]
- Релевантный, но имеет большое расстояние от пользователя [Adamopoulos and Tuzhilin 2014]
- Дальность пары user-item в графе [Onuma et al. 2009]
- и др.

$$Serendipity(R, u) = \frac{|R_{unexp} \cap R_{useful}|}{|R|}$$

$$R_{unexp} = R \setminus PM_u$$

Novelty

Показывает степень **новизны** релевантных рекомендаций.

Типы интерпретаций:

- Ранее пользователь не знал об айтеме (следствие right-tail popularity distribution)
- Пользователь мог знать об айтеме, но с ним не было взаимодействий
- Айтем отличается от тех, с которыми были взаимодействия раньше

Novelty

Показывает степень **новизны** рекомендаций.

$1 - p(i)$ - дополнение к популярности товара в наборе данных

$p(i) = \frac{|\{u \in U, r_{ui} \neq \emptyset\}|}{|U|}$ - доля пользователей, кто оценил айтем i

$-\log p(i)$ - возможная модификация (self-information) для большего веса редким айтемам

$$Novelty(R) = \frac{\sum_{i \in R} -\log_2 p(i)}{|R|}$$

Novelty

Показывает степень **новизны** релевантных рекомендаций.

Нюансы метрики:

- Не всегда хотим ее максимизировать (зависит от домена рекомендаций – повторы покупок e-commerce или свежий развлекательный контент)
- Неполнота данных о предыдущей истории пользователя (данных нет, но пользователь уже взаимодействовал с ним)
- Неперсонализированная метрика
- Возможны более простые техники подсчета и персонализированно $|R_{\text{not_used}}| / |R_{\text{used}}|$ - пример

Coverage

Показывает степень **покрытия** айтемов в рекомендациях среди всего каталога айтемов.

$$Coverage = \frac{|\cup_{u \in U} R_u|}{|I|}$$

R_u - множество рекомендаций пользователя

Coverage

Показывает степень **покрытия** айтемов в рекомендациях среди всего каталога айтемов.

Нюансы метрики:

- Если обрезаем хвост распределения на препроцессинге для обучения модели, появляется вариация для знаменателя: множество всех айтемов исходного каталога или множество всех айтемов input данных обучения модели

Coverage

Показывает степень **покрытия** айтемов в рекомендациях среди всего каталога айтемов.

Нюансы метрики:

- Если обрезаем хвост распределения на препроцессинге для обучения модели, появляется вариация для знаменателя: множество всех айтемов исходного каталога или множество всех айтемов input данных обучения модели
- Тоже не факт, что стремимся максимизировать его из-за trade-off с точностью

Coverage

Показывает степень **покрытия** айтемов в рекомендациях среди всего каталога айтемов.

Нюансы метрики:

- Если обрезаем хвост распределения на препроцессинге для обучения модели, появляется вариация для знаменателя: множество всех айтемов исходного каталога или множество всех айтемов input данных обучения модели
- Тоже не факт, что стремимся максимизировать его из-за trade-off с точностью
- В отличие от других метрик, не имеет большого смысла считать персонализированно

Расчет расширенной панели метрик

Разбирали до этого:

Precision@k

Recall@k

MAP@k

NDCG@k

MRR



Новые:

Diversity


Novelty

Coverage

Serendipity

Расчет расширенной панели метрик

RECALL@10_new	0.157	0.180	0.196	0.200	0.199	0.192	0.209	0.198	0.181	0.173
RECALL@25_new	0.255	0.317	0.330	0.339	0.320	0.322	0.345	0.339	0.307	0.302
RECALL@50_new	0.374	0.446	0.446	0.462	0.454	0.447	0.473	0.461	0.420	0.420
PRECISION@10_new	0.041	0.046	0.048	0.049	0.048	0.046	0.049	0.049	0.043	0.041
PRECISION@25_new	0.027	0.032	0.033	0.034	0.032	0.032	0.034	0.033	0.030	0.030
PRECISION@50_new	0.019	0.023	0.023	0.023	0.023	0.023	0.024	0.023	0.021	0.021
NOVELTY@10_new	0.273	0.299	0.352	0.331	0.369	0.345	0.338	0.372	0.334	0.342
NOVELTY@25_new	0.301	0.327	0.380	0.362	0.386	0.375	0.369	0.392	0.361	0.370
NOVELTY@50_new	0.327	0.353	0.406	0.387	0.406	0.401	0.396	0.412	0.385	0.395
MNAP@10_new	0.062	0.075	0.077	0.079	0.082	0.073	0.082	0.085	0.069	0.067
MNAP@25_new	0.070	0.086	0.089	0.090	0.092	0.083	0.093	0.097	0.079	0.078
MNAP@50_new	0.075	0.092	0.094	0.096	0.098	0.089	0.099	0.102	0.084	0.083
MIL_D@10_new	0.535	0.700	0.880	0.797	0.912	0.803	0.819	0.884	0.781	0.778



То, что было в логах



Клики



Рекомендации от модели:





Фидбек от пользователя новый:




Или:

Рекомендации от модели:





В чем отличие оффлайн от онлайн метрик?



В чем отличие оффлайн от онлайн метрик?

В оффлайне считаем на исторических данных

В онлайн применяем модель

Бизнес метрики:

- 1) Timespent – время использования сервиса клиентом
- 2) GMV – оборот клиента, если речь про покупки
- 3) CTR – click through rate – доля кликов (других действий) от просмотров (или чего-то другого)
- 4) Средний чек – тут понятно
- 5) Конверсия в заказ/выкуп/переход куда-либо
- 6) Retention-Xd – доля людей, которые вернулись в сервис через какой-то промежуток
- 7) Выручка компании с чего-то (показа рекламы, продажи товаров)
- 8) Средняя длина скрола – как далеко клиенты листали ленту
- 9) Количество лайков/дизлайков/скрытий/шеринга айтемов
- 10) Время сбора корзины
- 11) Доля просмотра ленты рекомендаций от всего времени в сервисе
- 12) Доля доступных айтемов к рекомендациям (или доля фильтрации)

Популярные бизнес-метрики для онлайн оценки

- Time Spent. Пример – ранжирование социальной сети.
- Conversion to action (СТА). Пример – конверсия в сделку по ценной бумаге.
- CTR. Пример – рекомендация креатива персонализированной баннерной рекламы.
- Retention. Пример – рекомендации музыки.

Бизнес метрики:

- 1) можно посчитать и без АБ-теста, а просто по сегменту людей
- 2) скорее всего важнее оффлайн метрик, так как конечные. Первичнее оффлайн метрик в смысле приоритета оптимизации
- 3) могут не коррелировать с оффлайн метриками
- 4) требуют определенного времени на «созревание» теста
- 5) без применения модели, но «по модели» практически нельзя посчитать
- 6) могут зависеть от домена и даже продукта

**Валидация в RecSys
для корреляции
с A/B: что работает
в контентных
рекомендациях**



**Дарья Тихонович
(МТС Диджитал)**



Debiasing: целый набор метрик ранжирует модели так, как это сделали A/B-тесты

15 вариантом *iqr_coef*
27 вариантов метрик

=> ~400 *debiased*-метрик

43 *debiased*-метрики имеют единичную ранговую корреляцию с конверсией в покупку

47

metric	iqr_coef	ab_corr
ndcg_12	-1.00	1.0
mrr_3	-1.00	1.0
hit_rate_12	-0.50	1.0
map_3_by_all	-0.25	1.0
map_3_by_k	-0.25	1.0
map_3_by_all	-1.00	1.0
pauc_12	-1.00	1.0
pap_12	-1.00	1.0
pauc_3	-1.00	1.0
pap_3	-1.00	1.0
map_3_by_k	-1.00	1.0
ndcg_12	-0.25	1.0
precision_12	-0.50	1.0
mrr_12	-1.00	1.0
precision_12	-0.25	1.0

AiConf 2024

Выбираем целевую debiased-метрику для офлайн-валидации

51

- ➡ Отобрали топ метрик с единичной ранговой корреляцией на разных степенях даунсемплинга
- ➡ Отобрали топ debiased-метрик по корреляции Пирсона с конверсией в покупку (наш максимум 0.88)
- ➡ Выбрали варианты, которые попали в пересечение двух топов
- ➡ Выбрали финальную метрику по корреляции Пирсона

precision_12	4
hit_rate_12	4
pap_3	3
pauc_3	3
recall_12	3
ndcg_12	3
map_3_by_all	3
hit_rate_3	2
precision_3	2
recall_3	2
mrr_12	2
mrr_3	2
ndcg_3	2
map_3_by_k	2
map_12_by_k	2
map_12_by_all	2
pap_12	1
pauc_12	1

iqr_coef	metric	pearson_corr_ab
-0.25	map_3_by_k	0.882
-0.25	pauc_3	0.877
-0.25	pap_3	0.877
-0.50	map_3_by_k	0.877
-0.25	mrr_3	0.877
-0.50	pauc_3	0.876
-0.50	pap_3	0.876
-0.50	mrr_3	0.875
0.00	map_3_by_k	0.875
0.00	mrr_3	0.874
0.00	pauc_3	0.873
0.00	pap_3	0.873
-0.25	map_3_by_all	0.873
-0.50	map_3_by_all	0.872
-0.25	ndcg_3	0.872

Итоговая метрика

52

PartialAUC@3 с iqr_coef = -0.25

Корреляция Пирсона с конверсией в покупку: 0.877

Ранговая корреляция с конверсией в покупку: 1

План:

больше моделей в A/B → больше
ретроанализа результатов → точнее
выбор метрики через анализ корреляций

Проблема оценки связи оффлайн метрик и онлайн метрик


Бизнес-метрики


- Time Spent
- Conversion to action (CTA)
- CTR
- Retention


Таргет модели


- Длительность просмотра
- Вероятность транзакции
- Вероятность клика
- ?


Хороша ли корреляция для оценки онлайн & офлайн?












Feedback loop


+



Система учится исправлять свои ошибки:

Она показывает то, что считает релевантным, но то, что им не оказывается, падает вниз. А на место упавших айтемов встают другие

-



1) Система может забыть, что «такое плохо»

При релевантных рекомендациях в ранкере может быть мало хороших негативных сэмплов

2) Система может не знать другие интересы юзера

Если юзеру показывают только про котиков, мы собираем данные только о котиках, и дальше снова их рекомендуем

Мониторинг стабильности

- 1) Рекомендации показываются за приемлемое время и всем
- 2) Мониторинг бизнес метрик или метрик ранжирования

Если метрики падают или растут несильно в течение времени,

Это может ничего не говорить про модель.




Если метрики сильно упали или выросли – это может свидетельствовать о проблемах


Как работает А/Б Тестирование






a/b testing



multivariate testing





Похожие клиенты видят разные рекомендации.
В одном средний чек X , в другом $X+5$ рублей
 $\Rightarrow$ по этой метрике система 2 лучше

Но насколько случайный такой результат?

- В нашем примере система 2 показывает средний чек выше на 5 рублей.
 - Но: разница может быть вызвана не реальным улучшением, а случайными колебаниями данных.
-
- **Статистическая значимость** — факт того, что разница между результатами двух групп (например, средний чек X и $X+5$) обусловлена не случайностью, а реальным эффектом изменений.
 - Если результат статистически значим, мы можем быть уверены, что система 2 действительно лучше, а не просто «повезло» на данных.

Как это работает?

- Формулируется нулевая гипотеза H_0 : «Между группами нет разницы».
- Считается р-значение — это вероятность получить наблюдаемый или ещё более крайний результат при условии, что нулевая гипотеза H_0 верна. Если р-значение $< 0,05$ (5%), разница считается статистически значимой

Вывод для бизнеса

- Статзначимость = уверенность, что новая система действительно лучше, а не просто «выиграла» из-за случайности.
- Помогает принимать решения на основе фактов, а не догадок.

Для t-критерия Стьюдента:

1. Рассчитать t-статистику по формуле:

$$t = \frac{\bar{X}_1 - \bar{X}_2}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}}$$

где:

- $\bar{X}_1, \bar{X}_2$ — средние выборок,
- s_1^2, s_2^2 — дисперсии,
- n_1, n_2 — размеры выборок.

2. Определить число степеней свободы (df):

- Для независимых выборок:


$$df = n_1 + n_2 - 2$$

- Для парного t-теста:

$$df = n - 1 \quad (\text{где } n \text{ — число пар}).$$

3. Найти p-значение для полученного t и df :

- Используя **таблицы t-распределения** (устаревший метод).
- Через **статистическое ПО** (Python, R, Excel).
- Через **онлайн-калькуляторы**.



По бизнес метрикам могут быть разнонаправленные эффекты:

Средний чек				Количество покупок на юзера			Итоговые деньги
	Упал	Не поменялся	Вырос	Упало	Не поменялось	Выросло	
Случай 1							Упали
Случай 2							Упали
Случай 3							???
Случай 4							Упали
Случай 5							Const
Случай 6							Выросли
Случай 7							???
Случай 8							Выросли
Случай 9							Выросли



По бизнес метрикам могут быть разнонаправленные эффекты:





Средний чек упал, но выросла конверсия => привлекли больше людей, но на мелкие заказы

Средний чек **вырос**, но упала конверсия => возможно наоборот отвалились мелкие заказы,
но не факт, что рекомендации «честно» растянут средний чек

Стратегии

ε - greedy	Upper Confidence Bound	Thompson Sampling
Выбираем arm по наибольшему $\bar{x}$	$\bar{x}_j + \sqrt{\frac{2 \ln n}{n_j}}$	$arm = \arg \max_j reward_j params$

Total Strategy Regret



- 1) Непонятно, сколько нужно «крутить» АБ-тест из-за нелинейности эффектов, обновления данных
- 2) Есть две проблемы даталиков между АБ группами
- 3) Результат теста может зависеть от контента в тестовый период времени
- 4) Вечность вечного контроля – палка о двух концах

как рассчитать длительность аб теста

AllImagesVideosShort videosShoppingWebNewsMore

Tools

Рассчитать длительность тестирования можно по формуле: **выборка / трафик = количество дней**. Допустим, минимальный размер выборки для статистически значимых результатов теста — 10000 уникальных посетителей. У сайта в среднем 1000 посетителей в день.

skillsetter.io

https://skillsetter.io › blog › AB-test-questions

A/B-тестирование: что это, зачем нужно и как проводить

About featured snippetsFeedback

mindbox.ru

https://mindbox.ru › tools › ab-tes... · Translate this page

Калькулятор достоверности A/B-тестирования - Mindbox

Калькулятор достоверности АВ-тестов · Рассчитать размер выборки · Подвести итоги теста · Как правильно проводить АВ-тесты · Рекомендуем по теме.

Habr

https://habr.com › plarium › articles · Translate this page

Проведение A/B-тестирования: пошаговый разбор / Хабр

Nov 6, 2020 — Совокупность этих параметров позволяет рассчитать необходимый объем выборки в каждой группе и длительность теста. В онлайн-калькуляторе ...

thisisdata.ru

https://thisisdata.ru › blog › chek-l...

Чек-лист по правильному A/B-тестированию - Все про ...

Jun 9, 2023 — Продолжительность тестирования можно рассчитать по формуле: **выборка / трафик = количество дней**. Допустим, минимальный объем выборки для статист ...

Нужен ли A/B-тест?

Запуск теста

Проверка теста после запуска

Есть теория, которая рассчитывает длину АБ теста:

- 1) Считаем размер эффекта, который ожидаем получить
- 2) Считаем размер трафика, который нужен
- 3) Линейно прикидываем, когда мы этот трафик получим

До теста

Рассчитать размер выборки

Проверьте, сколько людей должно участвовать в эксперименте для достоверных результатов. Подходит для тестирования open rate, click rate, конверсии в заказ.

Количество вариантов

— 2 +

Средний показатель

2 %

Ожидаемый абсолютный прирост

0.5 %

Достоверность

95%

Мощность

80%

Размер выборки, количество человек

Всего: 24,615

В каждом варианте: 12,307

54


Есть теория, которая рассчитывает длину АБ теста:

- 1) Считаем размер эффекта, который ожидаем получить
- 2) Считаем размер трафика, который нужен
- 3) Линейно прикидываем, когда мы этот трафик получим

До теста

Рассчитать размер выборки

Проверьте, сколько людей должно участвовать в эксперименте для достоверных результатов. Подходит для тестирования open rate, click rate, конверсии в заказ.




Размер выборки, количество человек

Всего:	В каждом варианте:
24,615	12,307

Две проблемы:


- 1) Если юзеры в процессе теста начнут чаще возвращаться в сервис – через сколько это проявится, чтобы мы это заметили? Месяц, год?
А) если мы используем RL и долгосрочную оптимизацию
- 2) Через сколько дней спадет эффект «новизны» от новых рекомендаций?






Схема, как данные разделяются, а потом снова смешиваются между группами

Непонятно, как посчитать ценность эксплорейшена




Схема, как данные разделяются, а потом снова смешиваются между группами


Можно разбить датасеты для обучения, но...



В тесте вы тестируете подмешивание видео в ленту
Задача, не уронить метрики просмотра постов:



Видео:




Обычные посты:



Тест успешный, вы ничего не уронили по метрикам постов

Лента через месяц раскатки:




Верен ли вывод, что метрики постов не роняются
при подмешивании видео?
Почему ленту могли заполнить видосы?



Начало выделения вечного контроля

Видят персональные
рекомендации



Видят неперсональные
рекомендации

Меряем качество RecSys

Меряем качество RecSys
+ накопительный эффект

Но в каком соотношении это?

- + дателики между группами!
- + при переразбивании групп будет эффект уменьшаться