
Курс: Рекомендательные системы

Занятие 17:

Текстовые модели в рекомендациях (text/ Conversational/LLM)

Почему сегодня эта тема?



LLM доминирует много где и активно внедряется в
рекомендации

План занятия

- Про текстовые item модели
- Conversational RecSys
- LLM как recommender, ключевая проблема
- Semantic ids
- LLM
 - Эмбеддинги от LLM
 - Раннее использование LLM4RecSys
 - OneRec
 - Фундаментальные модели

12i модели на основе текстов

Суп куриный Шеф Пере...

fasttext

Суп гороховый Шеф Пе... Суп Харчо Шеф Перекр... Шницель куриный Суп рассольник Шеф П... Суп гороховый с копч... Харчо Шеф Перекрёсто... Харчо Шеф Перекрёсто... Суп гороховый с копч... Борщ Шеф Перекрёсток... Суп куриный с домашн...

e5-grocery

Суп куриный с домашн... Суп гороховый Шеф Пе... Суп куриный с лапшой... Суп-пюре сырный Шеф ... Суп с картофелем и ф... Суп Харчо Шеф Перекр... Суп норвежский Шеф П... Суп гороховый с копч... Суп гороховый с копч... Суп сырный с копчёно...

clip-illarion-image-only

Суп куриный с лапшой... Лепёшка с сыром из т... Суп рассольник Шеф П... Лепёшка сырная Каша "Шеф Перекресто... Лепёшка с сыром и зе... Фрикасе куриное с гр... Лепёшка сырная с зел... Лепёшка с чесноком и... Салат Морковь по-кор...

clip-apple-image-only

Суп куриный с лапшой... Лапша соба с овощами... Лапша Удон с овощами... Щи с курицей Шеф Пер... Удон с курицей и ово... Суп грибной с перлов... Суп грибной с лапшой... Рассольник с курицей... Уха с сёмгой Шеф Пер... Лапша рисовая Шеф Пе...

blended_model_50_50

Суп куриный с лапшой... Суп куриный с домашн... Суп гороховый Шеф Пе... Суп с картофелем и ф... Суп грибной с перлов... Суп Харчо Шеф Перекр... Суп гороховый с копч... Суп-пюре из тыквы Ше... Вок с курицей Шеф Пе... Суп норвежский Шеф П...

Берем хорошую текстовую предобученную модельку

➔ Кодируем весь каталог

➔ Ищем похожие вектора для любого товара

Beeformer




Figure 1: Training with the beeFormer framework: A sentence Transformer model (up) act as a an encoder to generate item embeddings represented by the matrix A . Then ELSA act as a decoder (down) in a training step on interactions to obtain gradients used to optimize the Transformer model.

Table 4: Results for time-split setup on the Amazon Books dataset. Names of our models trained with beeFormer are in *italics*, the best-performing models are represented in **bold**, and the best baseline for each scenario is underlined. The standard error of all values is below 0.00005 (evaluated via bootstrap resampling).

Scenario Method	Model	R@20	R@50	N@100
zero-shot CBF	all-mpnet-base-v2	0.0218	0.0336	0.0193
	nomic-embed-text-v1.5	0.0387	<u>0.0560</u>	<u>0.0320</u>
	bge-m3	<u>0.0398</u>	0.0546	0.0313
	<i>Llama-goodbooks-mpnet</i>	0.0649	0.0931	0.0515
	<i>Llama-goodlens-mpnet</i>	0.0617	0.0891	0.0492
supervised CF	KNN	0.0370	0.0562	0.0303
	ALS MF	0.0344	0.0580	0.0313
	ELSA	0.0367	0.0628	0.0346
	SANSA	<u>0.0421</u>	<u>0.0678</u>	<u>0.0362</u>
CBF	<i>Llama-amazbooks-mpnet</i>	0.0706	0.1045	0.0571

Beeformer



Model card Files and versions xet Community

Deploy Copy to bucket NEW Use this model

Edit model card

Llama-goodbooks-mpnet

This is a sentence-transformers model: It maps sentences & paragraphs to a 768 dimensional dense vector space and it is designed to use in recommender systems for content-base filtering and as a side information for cold-start recommendation.

Usage (Sentence-Transformers)

Using this model becomes easy when you have sentence-transformers installed:

```
pip install -U sentence-transformers
```

Then you can use the model like this:

```
from sentence_transformers import SentenceTransformer
sentences = ["This is an example product description", "Each product description :
model = SentenceTransformer('beeformer/Llama-goodbooks-mpnet')
embeddings = model.encode(sentences)
print(embeddings)
```



Safetensors Model size 0.1B params Tensor type F32 Files info

Inference Providers NEW

Sentence Similarity

This model isn't deployed by any Inference Provider. Ask for provider support

Model tree for beeformer/Llama-goodbooks-mpnet



Paper for beeformer/Llama-goodbooks-mpnet

beeFormer: Bridging the Gap Between Semantic and Interaction Similarity in Recom...
Paper • 2409.10309 • Published Sep 16, 2024 • 4

Models 4

Sort: Recently updated


beeformer/Llama-goodbooks-mpnet
Sentence Similarity • 0.1B • Updated Sep 17, 2024 • 11

beeformer/Llama-movielens-mpnet
Sentence Similarity • 0.1B • Updated Sep 17, 2024 • 18


beeformer/Llama-goodlens-mpnet
Sentence Similarity • 0.1B • Updated Sep 17, 2024 • 4

beeformer/Llama-amazbooks-mpnet
Sentence Similarity • 0.1B • Updated Sep 17, 2024 • 1

Conversational recsys до ChatGPT



D. Jannach. ADVISOR SUITE – A knowledge-based sales advisory system. In ECAI '04, pages 720–724, 2004.



Number of papers on CRS per year found in "A Survey on Conversational Recommender Systems". ACM Computing Surveys, 2021

Conversational recsys до ChatGPT

Compare

Would you like to compare

Apt 34: room in a house, 600 frs, 15 square meters, private bathroom, private kitchen, 15 minutes to your work place

with other apartments for

☐ Better Type ☐ Cheaper Price ☒ Bigger Area

☐ Better Bathroom ☐ Better Kitchen ☐ Closer Distance

You are willing to compromise on the following attributes:

☐ Type of Apartment ☐ Price ☐ Area

☐ Bathroom ☒ Kitchen ☒ Distance

To find similar products with better values than this one

 **Canon PowerShot S2 IS Digital Camera**
\$424.15
Canon, 5.3 M pixels, 12x optical zoom, 16 MB memory, 1.8 in screen size, 2.97 in thickness, 404.7 g weight. [detail](#)

would you like to improve some values?

	Keep	Improve	Take any suggestion
Manufacturer	☒ Canon	☐ Sony	☐
Price	☐ \$424.15	☒ less expensive ☐ less expensive ☐ \$100 cheaper ☐ \$200 cheaper ☐ \$300 cheaper	☐
Resolution	☒ 5.3 M pixels	☐	☐
Optical Zoom	☒ 12x	☐	☐
Removable Flash Memory	☒ 16 MB	☐ more memory	☐
LCD Screen Size	☒ 1.8 in	☐ larger	☐
Thickness	☒ 2.97 in	☐ thinner	☐
Weight	☒ 404.7 g	☐ lighter	☐

QWIKSHOP.COM

HOME : ABOUT THIS PROJECT : CONTACT

➤ Digital Cameras

Shop for : Digital Cameras Computers Holidays



Product Found: Canon EOS 30

6.3 Megapixel CMOS sensor
7-point wide-area AF
High-performance DIGIC processor
100-1600 ISO speed range
Compatible with all Canon EF lenses and EX Speedlites
PictBridge, Canon Direct Print and Bubble Jet Direct compatible - no PC required

Adjust your preferences to find the right camera for you

Manufacturer	X	Canon	X
Optical Zoom	↓	7x	↑
Memory (MB)	↓	512	↑
Weight (Grams)	↓	780	↑
Resolution	↓	6.2 M Pixels	↑
Size	X	Large	X
Case	X	Magnesium	X
Price	↓	995	↑

We have more matching cameras with the following:

1. Less Memory and Lower Resolution and Cheaper	EXPLAIN	PICK
2. Different Manufacturer and Less Zoom and Lighter	EXPLAIN	PICK
3. Lighter and Smaller and Different Case	EXPLAIN	PICK

Explain:


1. Less Memory and Lower Resolution and Cheaper

This Critique covers **153** other Digital Cameras

Less Memory
Current Value: 512 MB
Critique: Less Than
Remaining: (0 to 256 MB)

Lower Resolution
Current Value: 6.2 M Pixels
Critique: Less Than
Remaining: (1.4 to 5.9 M Pixels)

Cheaper
Current Value: 995 €
Critique: Less Than
Remaining: (75€ to 960€)




(a)

(b)

(c)

McCarthy, K., Reilly, J., McGinty, L., and Smyth, B.: Experiments in Dynamic Critiquing. In Proceedings of the Tenth International Conference on Intelligent User Interfaces, 175-182, New York: ACM Press, 2005.

Conversational recsys до ChatGPT



R. Li, S. E. Kahou, H. Schulz, V. Michalski, L. Charlin, and C. Pal. Towards deep conversational recommendations. In NIPS '18, pages 9725–9735, 2018.

Conversational recsys до ChatGPT

Can you find me a **mobile phone** on Amazon?

Sure, what **operating system** do you prefer?

I want an **Android** one.

OK, and any preference on **screen size**?

Better larger than **5 inches**.

Do you have requirements on **storage capacity**?

I want it to be at least **64 Gigabytes**.

And any preference on **phone color**?

Not particularly.

Sure, then what about the following choices?



I don't like them very much...

OK, do you have any preference on the **brand**?

Better be **Samsung or Huawei**.

Any requirement on **price**?

Should be **within 700 dollars**.

OK, then what about these ones?



Great, I want the first one, can you order it for me?

Sure, I have placed the order for you, enjoy!

Image from Zhang et al. Towards conversational search and recommendation: System ask, user respond. CIKM 2018.





Image from Moon, Seungwhan, et al. Opendialkg: Explainable conversational reasoning with attention-based walks over knowledge graphs. ACL. 2019.

Conversational recsys до ChatGPT

Different Types of Utterances in Conversations



Conversational recsys до ChatGPT

Paradigm 1: System is Active, User is Passive (SAUP)

Typical Form: System Ask User Respond (SAUR)

- System asks questions about (attributes of) items to narrow down the recommended candidates.

Input:

- Dialogue history

Output:

- Next utterance = **question to ask user**
- Item(s) recommended to user

User responds to the question

Can you find me a *mobile phone* on Amazon?
 Sure, what **operating system** do you prefer?
 I want an **Android** one.
 OK, and any preference on **screen size**?
 Better larger than **5 inches**.
 Do you have requirements on **storage capacity**?
 I want it to be at least **64 Gigabytes**.
 And any preference on **phone color**?
 Not particularly.
 Sure, then what about the following choices?
 (Images of six different mobile phones)
 I don't like them very much...
 OK, do you have any preference on the **brand**?
 Better be **Samsung or Huawei**.
 Any requirement on **price**?
 Should be **within 700 dollars**.
 OK, then what about these ones?
 (Images of six different mobile phones)
 Great, I want the first one, can you order it for me?
 Sure, I have placed the order for you, enjoy!

System asks a question

Conversational recsys до ChatGPT

Paradigm 2: System is Active, User Engages (SAUE)

Typical Form: SAUR + Chitchat



- System asks questions about (attributes of) items and also chats with user.

Input:

- Dialogue history

Output:

- Next utterance = **question + chitchat**
- Item(s) recommended to user



Conversational recsys до ChatGPT

Paradigm 3: System is Active, User is Active (SAUA)

Typical Form: SAUR + Chitchat + User Ask System Respond

- Users actively ask questions and participate in the recommendation process.

Input:

- Dialogue history

Output:

- Next utterance = **question or response to user's question**
- Item(s) recommended to user

Goal planning: QA about <Stolen life>, chitchat about Xun Zhou, recommending the movie <The message>, recommending <Don't cry, Nanking!>	
1.User: 你知道电影『生死劫』的主演是谁吗? (Who is the star of the movie <stolen life>?)	user asks
2.Bot: 是周迅哦。 (It is Xun Zhou.)	
3.User: 是我女神演的呀! (She is my goddess.)	
4.Bot: 你真有眼光啊, 周迅是中国电视金鹰奖最受欢迎女演员呢。 (You have good taste. Zhou Xun is the most popular actress in the Golden Eagle Award of China TV.)	
5.User: 是呢, 我特别喜欢她的, 她的演技也很厉害。 (I like her very much. She's very good at acting.)	
6.Bot: 她还获得过亚洲电影大奖最佳女演员的, 演技是得到过国际认可的。 (She also won the best actress of the Asian Film Awards. Her acting is internationally recognized.)	
7.User: 嗯嗯, 反正她真的很优秀。 (Anyway, she's really good.)	
8.Bot: 那你要看看她演的《风声》吗? 该片具有精炼的人物, 波谲云诡的情节。很好看哦! (Do you want to see her movie <The message>? It has refined characters and capricious plots.)	
9.User: 可我现在更喜欢『刘若英』的电影! (But now I prefer Rene Liu's films!)	
10.Bot: 那刘若英的《南京1937》你可以看看, 电影所展现的是一个导演对战争、对民族、对人性的思考。 (You can see the movie <Don't cry, Nanking>. It shows the director's thinking on war, nation, and human nature.)	
11.User: 历史片吗? (It is historical film?)	user asks
12.Bot: 历史战争片。 (Yes. It is historical war film.)	
13.User: 那我肯定要看看了。 (I will watch it!)	
14.Bot: 嗯, 你肯定会喜欢的。 (Sure, you will like it!)	
15.User: 嗯, 谢谢你呀, 下次聊吧! (Thank you! See you later!)	
16.Bot: 好的, 再见! (OK! Bye!)	


Conversational recsys до ChatGPT: собираем данные

- Assumption: Each user review is converted to a conversation. Aspects that appear earlier in the review should appear earlier in the conversation.

★★★★☆ Worthy wifi e-reader for everyday reader.

Reviewed in the United States on December 26, 2010

Library with thousands of books, magazine that comes free, **built-in free wireless data network**, plus Wi-Fi connectivity (no PC needed); separate capacitive color touch-screen pad for navigation, and a virtual keyboard for notes and annotations; **2GB of internal memory (capable of storing 1,500 electronic books) as well as a microSD expansion slot for additional memory**; font style and size are adjustable; displays image files and plays MP3 music files; compatible with Windows and Mac machines; **battery is removable and user-replaceable**; allows free browsing of full-text books while within Barnes & Noble stores; you can lend certain e-books for up to 14 days free of charge; EPUB format compatibility lets you read free Google Books and loaner e-books from your local library; page turn speeds are faster with firmware upgrade.



Conversation initiated by user ID=AQGUDK0MSQ95L

U: Can you find me a tablet on Amazon?

S: Sure, any requirement on the network?

U: Built-in free wireless data network.

S: Any preference on the memory?

U: 2GB of internal memory as well as a microSD expansion slot for additional memory.

S: Any preference on the battery?

U: Battery is removable and user-replaceable.

Result: Product ID=1400532620.

Conversational recsys до ChatGPT: учим трансформер P5



RecSys '22, September 18–23, 2022, Seattle, WA, USA

Shijie Geng, Shuchang Liu, Zuohui Fu, Yingqiang Ge, Yongfeng Zhang




Figure 1: P5 pretrains on an encoder–decoder Transformer model that takes in textual inputs and produces target responses. We trained P5 on a multitask collection of personalized prompts. After multitask prompt-based pretraining on recommendation datasets, P5 achieves the capability of zero-shot generalization to unseen personalized prompts and new items.

Conversational recsys до ChatGPT: учим трансформер

P5



RecSys '22, September 18–23, 2022, Seattle, WA, USA

Shijie Geng, Shuchang Liu, Zuohui Fu, Yingqiang Ge, Yongfeng Zhang




Figure 3: An illustration of the P5 architecture. For the example prompt input “What star rating do you think user_23 will give item_7391?”, P5 adopts an encoder–decoder framework: first encodes the input with a bidirectional text encoder, and then generates the answer through a text decoder autoregressively. In contrast to task-specific recommendation models, our P5 relies on multitask prompt-based pretraining on a large-scale personalized prompt collection, which makes P5 able to adapt to different task families and even generalize to novel personalized prompts.

Next-token prediction

$$\mathcal{L}_{\theta}^{\text{P5}} = - \sum_{j=1}^{|y|} \log P_{\theta} (y_j \mid y_{<j}, \mathbf{x})$$

Conversational recsys до ChatGPT: учим трансформер

P5



Table 3: Performance comparison on sequential recommendation.

Methods	Sports				Beauty				Toys			
	HR@5	NDCG@5	HR@10	NDCG@10	HR@5	NDCG@5	HR@10	NDCG@10	HR@5	NDCG@5	HR@10	NDCG@10
Caser	0.0116	0.0072	0.0194	0.0097	0.0205	0.0131	0.0347	0.0176	0.0166	0.0107	0.0270	0.0141
HGN	0.0189	0.0120	0.0313	0.0159	0.0325	0.0206	0.0512	0.0266	0.0321	0.0221	0.0497	0.0277
GRU4Rec	0.0129	0.0086	0.0204	0.0110	0.0164	0.0099	0.0283	0.0137	0.0097	0.0059	0.0176	0.0084
BERT4Rec	0.0115	0.0075	0.0191	0.0099	0.0203	0.0124	0.0347	0.0170	0.0116	0.0071	0.0203	0.0099
FDSA	0.0182	0.0122	0.0288	0.0156	0.0267	0.0163	0.0407	0.0208	0.0228	0.0140	0.0381	0.0189
SASRec	0.0233	0.0154	0.0350	0.0192	0.0387	0.0249	0.0605	0.0318	0.0463	0.0306	0.0675	0.0374
S ³ -Rec	0.0251	0.0161	0.0385	0.0204	0.0387	0.0244	0.0647	0.0327	0.0443	0.0294	0.0700	0.0376
P5-S (2-3)	0.0272	0.0169	0.0361	0.0198	<u>0.0503</u>	<u>0.0370</u>	<u>0.0659</u>	<u>0.0421</u>	0.0648	0.0567	0.0709	0.0587
P5-B (2-3)	<u>0.0364</u>	<u>0.0296</u>	<u>0.0431</u>	<u>0.0318</u>	0.0508	0.0379	0.0664	0.0429	0.0608	0.0507	0.0688	0.0534
P5-S (2-13)	0.0258	0.0159	0.0346	0.0188	0.0490	0.0358	0.0646	0.0409	<u>0.0647</u>	<u>0.0566</u>	<u>0.0705</u>	<u>0.0585</u>
P5-B (2-13)	0.0387	0.0312	0.0460	0.0336	0.0493	0.0367	0.0645	0.0416	0.0587	0.0486	0.0675	0.0536

Conversational recsys до ChatGPT: учим трансформер

P5



<u>Toys -> Beauty</u>		
Case 1	Input: Based on the word color , help user_4549 write a 5-star explanation for this new product : \n title : Bain De Terre Serum Anti-Frizz Recovery Complex 1.7 oz. \n price : 3.86 \n brand : Bain de Terre	Target Output: I have color treated fine hair but lots of it P5's Output: The colors are bright
Case 2	Input: Based on the word shampoo , help user_1491 write a 1-star explanation for this new product : \n title : CLEAR SCALP & HAIR BEAUTY Volumizing Root Boost Nourishing Shampoo, 12.9 Fluid Ounce \n price : 1.66 \n brand : Clear	Target Output: I tried the shampoo and it hardly foams up P5's Output: Not worth the price
<u>Beauty -> Sports</u>		
Case 3	Input: Based on the word tool , help user_3877 write a 5-star explanation for this new product : \n title : SOG Specialty Knives & Tools TF6-CP Trident Knife with Straight Edge Assisted Folding 3.75-Inch Steel Tanto Shape Blade and GRN Handle, Satin Finish \n price : 57.6 \n brand : SOG Specialty Knives	Target Output: this is an excellent tool P5's Output: This is a great tool tool
Case 4	Input: Based on the word saw , help user_326 write a 2-star explanation for this new product : \n title : Rome's #1705 Square Pie Iron with Steel and Wood Handles \n price : 20.26 \n brand : Rome Industries	Target Output: After looking closely we saw 2 of the rivots that are supposed to hold it on were missing P5's Output: I saw no visible improvement
<u>Sports -> Toys</u>		
Case 5	Input: Based on the word game , help user_29782 write a 3-star explanation for this new product : \n title : Deal Breaker Coaster Card Game \n price : 13.95 \n brand : Zobmondo!!	Target Output: I think this game could prove interesting if played while drinking P5's Output: I'm a big fan of this game and it is a great game
Case 6	Input: Based on the word cars , help user_2121 write a 5-star explanation for this new product : \n title : Ridemakerz Marvel Universe Spiderman and Venom Xtreme Customz Swap Set \n price : 14.89 \n brand : RIDEMAKERZ	Target Output: These are great looking little plastic cars P5's Output: I have several cars and this one is the best

Figure 4: Example cases of zero-shot domain **transfer** on **Z-6** task. We demonstrate three **transfer** directions: *Toys to Beauty*, *Beauty to Sports*, and *Sports to Toys*.

Conversational recsys после выхода ChatGPT

CIKM '23, October 21–25, 2023, Birmingham, United Kingdom

He, et al.




Figure 1: Large Language Models (LLMs) as Zero-Shot Conversational Recommenders (CRS). We introduce a simple prompting strategy to define the task description T , format requirement F and conversation context S for a LLM, denoted as $\mathcal{F}$, we then post-process the generative results into ranked item lists with processor Φ .

Conversational recsys после выхода ChatGPT





Figure 4: A workflow of pre-training LLMs for recommender systems in terms of two representative methods: *Masked Language Modeling* which randomly masks tokens or spans in the sequence and requires LLMs to generate the masked tokens or spans based on the remaining context, and *Next Token Prediction* which requires prediction for the next token based on the given context.


Search vs RecSys (оба IR – Information Retrieval)



	Плюсы	Минусы
RecSys	- Персонализация by design	- не знает, что надо сейчас юзеру (учитывает это с опозданием)
Search	- Знает, что надо сейчас юзеру	- сложно персонализировать



Мне нужно мыло, конверсия в добавление у мыла будет больше (читай – у поиска). А в рекомендациях мыло так и не появится (хотя оно мне нужно)



Поисковые сервисы заточены под конкретные интенты



OZON

Каталог

Везде

Олег

Ozon fresh

Ozon Банк

Билеты, отели

Для бизнеса

Одежда

Электроника

Дом и сад

Товары за 1₽

Сертификаты

По вашему запросу товаров сейчас нет. Но мы нашли похожие

Категория

Книги

Кружки и чашки

Виниловые пластинки

Наклейки и знаки автомобильные

Распродажа

Доставка

Неважно

До 3 дней

До 7 дней

Цена

6

2446

до 250 ₽

250-1000 ₽

1000-2000 ₽

Популярные

БОМБОРА

МАССИМО ВАККЕТТА

расскажи мне что-нибудь хорошее

247 ₽ ~~1000 ₽~~ -75%

5 шт осталось

Бомбора

Расскажи мне что-нибудь хорошее. История о маленьких...

5.0 1 отзыв

Послезавтра

330 мл

Давайте мне что-нибудь выпить

0% до 140 дней

Распродажа

310 ₽ ~~2990 ₽~~ -89%

4 и 1 ₽

Кружка Давайте мне что-нибудь выпить, прикол, подарок, 1 шт, 330 мл

22 мая

18+

Скажи мне что-нибудь хорошее

6 ₽ ~~8 ₽~~ -25%

Стало дешевле

Скажи мне что-нибудь хорошее | Козырев Вячеслав | Электронна...

5.0 9 отзывов

Перейти

LLM как рекоммендер



порекомендуй мне товары на ужин в магазине самокат и составь корзину на 1000 рублей



Соберу практичную корзину именно под ужин, но цены и наличие в «Самокате» сильно зависят от города и адреса. Проверю актуальные публичные ориентиры и дам вариант, который легко заменить аналогами в приложении.

Думал на протяжении 45s >

Я бы собрал **ужин на 2–3 порции: курица + рис с овощами + яблоки на десерт**. По публичным ценовым ориентирам Самоката это укладывается примерно в **984 Р**, но в приложении цена может немного отличаться по адресу.

Товар	Зачем	Ориентир
Мякоть бедра цыплёнка в маринаде, 400 г	основное блюдо	292 Р
Рис, упаковка	гарнир	91 Р
Замороженные овощи	в рис / гарнир	135 Р
Лук репчатый, 1 кг	вкус к рису/курице	59 Р
Куриные яйца, 10 шт.	добавить в рис как fried rice	89 Р
Твёрдый сыр, 190 г	посыпать горячий рис/овощи	189 Р
Яблоки, 1 кг	десерт	129 Р
Итого		≈984 Р

+

Спросите ChatGPT

Расширенное ▾

Готовая рекомендательная система поверх целого сервиса, которая идеально закрывает мой запрос

LLM как search + recsys

Если LLM

- может искать реальные товары и показывать мне их (search)
- может опираться на мой предыдущий опыт (recsys),

Тогда она идеально закрывает мою потребность в персонализации и реализации моего текущего интента.

Чего не делают ни search, ни recsys по отдельности

ChatGPT и персонализация



расскажи факты которые ты знаешь обо мне

⚙️ Общее

🔔 Уведомления

👤 Персонализация

Про 3D-печать и DIY

У тебя есть **FlashForge Adventurer 5M**.

Ты новичок в 3D-печати, но уже активно экспериментируешь. Ты печатал Benchy, интересовался STL/G-code, Orca Slicer / FlashPrint / Cura / Prusa Slicer.

Про генеративные модели для рекомендаций

Ты экспериментируешь с **GPT-2-style decoder-only** моделями для генерации следующей корзины.

Ты сталкивался с типичными проблемами:

- right-padding warning для decoder-only моделей;
- CUDA OOM даже на больших GPU;
- проблемы с `max_prompt_length`, `max_new_tokens`, `num_generations` в GRPO;
- желание логировать reward/metrics в ClearML;
- необходимость не перезаписывать SFT checkpoint при GRPO.

ChatGPT и персонализированные рекомендации

а сделай мне рекомендации товаров на озон по моим интересам

Да, я бы собрал тебе подборку не по “популярному на Ozon”, а по твоим реальным интересам: **3D-печать / DIY, ремонт стен, рабочее место для ML/кодинга, моделирование.**

Что я бы купил в первую очередь

1. Для 3D-печати и Adventurer 5M

1. Сушилка для филамента / dry box

Для PLA это не всегда must-have, но у тебя уже есть 3D-принтер и эксперименты с печатью, поэтому это одна из самых полезных покупок “на вырост”: PLA, PETG, ABS, Nylon — многие сушилки на Ozon прямо указывают поддержку этих пластиков и диаметр 1.75 мм. Озон +1

2. Набор винтов, гаек и шайб M2/M3/M4

Прямо под твои проекты: вентилятор, корпуса, крепления, мини-модели, подставки. На Ozon есть наборы для 3D-принтера M2/M3/M4 на сотни штук. Озон +1

3. Латунные закладные гайки M3 для впавления

Очень полезно, если ты хочешь делать не просто “фигурки”, а функциональные детали: корпуса, ручки, крепления, детали вентилятора. Озон +1

4. Набор DC-моторов 5V для DIY-вентилятора

Ты как раз хотел маленький карманный вентилятор на USB/powerbank. На Ozon есть маленькие DC 5V моторы для USB-вентиляторов; это лучше совпадает с твоей идеей, чем уходить в 12V-схемы. Озон +1

5. USB-кабель 2-pin 5V с выключателем

Для безопасного прототипа вентилятора: powerbank → USB-кабель → мотор. На Ozon есть DIY USB 5V кабели с оголенными проводами и варианты с выключателем. Озон +1

3. Для рабочего места / ML / кодинга

9. Logitech MX Master 3S

Для долгой работы за компьютером это один из самых логичных апгрейдов: хорошая эргономика, горизонтальный скролл, много кнопок. На Ozon есть категория MX Master 3S и карточки с высоким числом отзывов. Озон +2

10. Keychron K3 / K3 Pro

Тебе под ML/кодинг и тексты лучше смотреть компактную низкопрофильную механику: меньше места на столе, приятнее долго печатать. На Ozon есть Keychron K3/K3 Pro, включая беспроводные низкопрофильные варианты. Озон +2

4. Для 3D-моделирования

11. Книга “Fusion 360. 3D-моделирование для мейкеров”

Это прям в твой профиль: ты хочешь не просто печатать готовые STL, а моделировать свои детали. На Ozon карточки этой книги описывают эскизы, моделирование, редактирование моделей и DIY-проекты с пошаговыми инструкциями. Озон +2

Есть разные абстракции айтемов

- 1) Преступление и наказание – конкретное произведение. **LLM рекомендует обычно этот уровень абстракции**
- 2) Издательство, серия – реализация произведения группы книг, объединенных некоторыми схожими особенностями (год печати, дизайн) – **item_id, recsys рекомендует этот уровень, люди покупают этот уровень абстракции**
- 3) Конкретная напечатанная физическая книга. **То, что получает пользователь в конечном итоге, но на этом уровне юзеры не дифференцируют экземпляры**

Есть разные абстракции айтемов

- 1) Батон – конкретное понятие из еды. LLM рекомендует обычно этот уровень абстракции
- 2) Батон БРЕНД 400 г – реализация идеи батона конкретным брендом – `item_id`, recsys рекомендует этот уровень, люди покупают этот уровень абстракции
- 3) Конкретный батон, которые пользователь съест. То, что получает пользователь в конечном итоге, но на этом уровне юзеры не дифференцируют экземпляры

Иногда это не применимо

В какие города съездить в путешествие?

- LLM рекомендация: В Мурманск – это конкретный город, без более низкого уровня детализации

Достаточно ли в домене рекомендаций 1 уровня?

- 1) Преступление и наказание – конкретное произведение. **LLM рекомендует обычно этот уровень абстракции**
- 2) Издательство, серия – реализация произведения группы книг, объединенных некоторыми схожими
- 3) Конкретная карточка товара (селлер) `item_id`

Если юзеру важно сужения выбора до 1 уровня, то LLM – круто!
Если юзеру также важен уровень №3, нужно LLM + матчинг с 1 уровня на 3 уровень!

Важная проблема LLM4RecSys


LLM хорошо рекомендует смысл,
но конкретный item_id крайне
плохо. Эту проблему пытаются
побороть в статьях разными

способами.

У разных item_id:

- разная цена
- разная популярность
- разный рейтинг
- разные даты доставки
- разные скидки

Хороший recsys-ранкер все это учитывает, но современные
LLM нет, и не могут это делать без доступа к внутренним
данным



LLMs for User Interest Exploration in Large-scale Recommendation Systems

Jianling Wang*

Google DeepMind

jianlingw@google.com

Haokai Lu*

Google DeepMind

haokai@google.com

Yifan Liu

Google

yifanliu@google.com

He Ma

Google

htm@google.com

Yueqi Wang

Google

yueqiw@google.com

Yang Gu

Google

greeness@google.com

Shuzhou Zhang

Google

shuzhouz@google.com

Ningren Han

Google

peterhan@google.com

Shuchao Bi

Google

shuchaobi@google.com

Lexi Baugher

Google

baugher@google.com

Ed H. Chi

Google DeepMind

edchi@google.com

Minmin Chen

Google DeepMind

minminc@google.com

Что сделали?




Figure 1: LLM-powered hybrid hierarchical planning diagram for user interest exploration.

Что сделали?

Prompt

The short-form videos I watched most recently are in the following clusters:

Cluster 1: {*Bus, Truck, Road, Commercial vehicle, Bus Simulator Indonesia, Om Telolet Om, Accident, Motor vehicle, Hino Motors, Tour bus service*}

Cluster 2: {*Coconut, Banana, Fruit, Durian, Fruit, Oil palms, Mango, Jackfruit, Durian, Papaya*}.



Each cluster is described with salient phrases or entity names. With less than 30 words, generate **a new and different short-form video cluster** I will watch next with highly specific salient phrases or entity names, with a prefix that says "New cluster: "

Label

New cluster: Sharks, Underwater environment, Underwater diving, Dolphin, Orca, Mermaid, Penguins, Whale, Fish, Ocean

Figure 2: Prompt for Novel Interest Prediction when $K = 2$.

Нужно выделить видео в 4-х уровневую кластеризацию



Что дальше?


ance representation granularity and computation efficiency. In our experiment, the level-2 clustering produced 761 clusters. We can therefore enumerate all $761 * 761 = 579,121$ cluster pairs and perform a batch inference with LLM to obtain novel interests for each cluster pair under just a few hours. These novel interests, together

Что дальше? В онлайне:

История пользователя

Сейчас

t



²30-day user history are used in sampling, and items with high-quality interactions are more likely to be sampled.

Как из кластера получить айтемы?

- Можно отправить запрос в поиск
- В поиске обычно немного персонализации 😊
- Давайте ограничим `recsys` на айтемы из этого кластера

Supervised fine-tuning (SFT)


$[(C_1, C_2), C_L]$ 250K сэмплов
качественных собрали

- 1) Интерес C_L успешно получен
- 2) Он точно отличен от C_1 и C_2


Дальше: берем топ-10 встречаемых пар C_1, C_2 для каждого C_L

Получили $761 * 10$ сэмплов


Supervised fine-tuning (SFT)



Results




(b) Novelty (x-axis) and Quality (y-axis) Comparison




(c) Improvement of UCI@N

Results



(a) Overall Watch Time



(b) Number of Users watch ≥ 10 min

Figure 5: The proposed method drives user growth.

Выводы по этой статье

- 1) Начали с малого применения LLM и смогли
- 2) Выиграли АБ тест
- 3) LLM не подвержено feedback loop, привнесла новые знания
- 4) LLM применили в оффлайне

Semantic ids: с чего все началось

Recommender Systems with Generative Retrieval

Shashank Rajput* University of Wisconsin-Madison	Nikhil Mehta* Google DeepMind	Anima Singh Google DeepMind	
Raghunandan Keshavan Google	Trung Vu Google	Lukasz Heldt Google	Lichan Hong Google DeepMind
Yi Tay Google DeepMind	Vinh Q. Tran Google	Jonah Samost Google	Maciej Kula Google DeepMind
Ed H. Chi Google DeepMind	Maheswaran Sathiamoorthy Google DeepMind		





Figure 1: Overview of the *Transformer Index for GEnerative Recommenders* (TIGER) framework. With TIGER, sequential recommendation is expressed as a generative retrieval task by representing each item as a tuple of discrete semantic tokens.


Semantic ids: идея TIGER ключевая



(a) Semantic ID generation for items using quantization of content embeddings. (b) Transformer based encoder-decoder setup for building the sequence-to-sequence model used for generative retrieval.


Figure 2: An overview of the modeling approach used in TIGER.

Semantic ids: как получить через RQ-VAE



Semantic ids: как получить через Kmeans?

RQ-KMeans (Open One Rec): как это работает




Ключевые идеи

- Residual Quantization (RQ): представляем вектор как сумму m кодовых векторов:
$$x \approx c_{i_1}^1 + c_{i_2}^2 + \dots + c_{i_m}^m$$
- Каждый уровень кодирует остаток после предыдущих уровней $\rightarrow$ более точное представление при том же бюджете.
- K-Means используется для обучения кодовых векторов (центров).

Пример конфигурации

- $m = 3$ уровня
- $K_1 = K_2 = K_3 = 256$ (8 бит на уровень)
- Общая длина кода: 24 бита на товар
- $d = 768$ (размер эмбединга)



Декодирование (восстановление)

Восстанавливаем вектор как сумму кодовых векторов по индексам.

$$\hat{x} = c_{i_1}^1 + c_{i_2}^2 + \dots + c_{i_m}^m$$

Пример

Уровень	Индекс	Кодовый вектор
1	7	c_7^1
2	12	c_{12}^2
3	3	c_3^3

$$\hat{x} = c_7^1 + c_{12}^2 + c_3^3$$

Сравнение с другими подходами

Метод	Как учится	Как кодирует	Плюсы	Минусы
RQ-KMeans (Open One Rec)	K-Means на остатках	Детерминированно (ближайший центр)	Просто, быстро, стабильно, без градиентов	Не учитывает задачу (нет fine-tuning на loss модели)
RQ-VAE	Энд-ту-энд с реконстр. loss	Через нейросеть (soft/hard)	Учитывает генеративный loss, task-aware	Сложнее, дольше обучается, менее стабильно
VQ (1 уровень)	K-Means / VQ	Один код (без остатков)	Очень просто и быстро	Меньшая точность реконструкции при том же бюджете


Интуиция

Каждый уровень уточняет представление, кодируя то, что не удалось объяснить предыдущим уровням.

Semantic ids: как получить через r3vae?

R3VAE: как это работает

Reference Vector-Guided Rating Residual Quantization VAE для Semantic IDs



Функция потерь

$$\mathcal{L}_{total} = \mathcal{L}_{rec} + \lambda \mathcal{L}_{metric}$$

A) Reconstruction loss

$$\mathcal{L}_{rec} = \|x - \hat{x}\|_2^2$$

Точная реконструкция embedding

B) Recommendation-aware regularization

$$\mathcal{L}_{metric} = -SC_{avg} + PD_{avg}$$

- SC (Semantic Cohesion): выше лучше — товары внутри SID-кластера должны быть похожи
- PD (Preference Discrimination): ниже лучше — разные SID-кластеры должны быть хорошо разделены



Почему R3VAE лучше обычного RQ-VAE



1) Reference vector задаёт более осмысленный стартовый residual



2) Soft rating quantization уменьшает зависимость от STE



3) Более стабильные и информативные codebooks



4) Semantic IDs становятся recommendation-aware



Идея: не просто реконструировать embedding, а получать Semantic IDs, которые лучше сохраняют структуру и полезны для downstream RecSys.

Semantic ids: как получить через r3vae?




Table 8 Ablation studies of key components on Amazon-Beauty.

Method	Recall $\uparrow$			NDCG $\uparrow$			SC $\uparrow$	PD $\downarrow$
	@10	@20	@30	@10	@20	@30		
R³-VAE (Full)	0.0716	0.1025	0.1250	0.0393	0.0470	0.0518	0.97	-1.81
w/o Reference Vector	0.0642	0.0975	0.1211	0.0357	0.0437	0.0486	0.94	-1.73
w/o Rating Quantization	0.0640	0.0968	0.1201	0.0351	0.0434	0.0478	0.90	-1.78
w/o SC Regularization	0.0652	0.0988	0.1217	0.0369	0.0451	0.0490	0.90	-1.85
w/o PD Regularization	0.0647	0.0981	0.1214	0.0367	0.0440	0.0487	0.96	-1.56

Semantic ids: игрушечный пример

Название товара	Описание	Эмбеddинг от LM	Semantic id
Банан	Это фрукт желтого цвета	[-2, 3, 0.3, 0.2]	1-2-3
Картофель	Обычно продается в килограммах и используется в большом количестве блюд	[-0.5, 3, 0.1, 0.2]	1-4-5
Молоко	Бывает разной жирности	[-2, -1, 0.5, 0.2]	3-2-1
Морковь	Овощ оранжевого цвета	[-2, 3, -0.2, 0.5]	1-4-5


Semantic ids: игрушечный пример + коллизии

Название товара	Описание	Эмбеddинг от LM	Semantic id	Item_id
Банан	Это фрукт желтого цвета	[-2, 3, 0.3, 0.2]	1-2-3	1
Картофель	Обычно продается в килограммах и используется в большом количестве блюд	[-0.5, 3, 0.1, 0.2]	1-4-5	2
Молоко	Бывает разной жирности	[-2, -1, 0.5, 0.2]	3-2-1	3
Морковь	Овощ оранжевого цвета	[-2, 3, -0.2, 0.5]	1-4-6	4
Картофель молодой	Обычно продается в килограммах и используется в большом	[-0.5, 3, 0.1, 0.3]	1-4-5	5

Если модель умеет рекомендовать только semantic-id, она не может отличить разные item_id при одном semantic-id!

Можно добавить «уникализирующий id»: 1-4-5-1 для Картофеля и 1-4-5-2 для Картофеля молодого

Semantic ids: демапинг sid -> id при коллизиях



Semantic ids: как считаем метрики recsys?

История пользователя оригинальная:

Обучение: 1-4-5-1, 1-4-2-5, 5-2-3-1, 3-4-2-1, 4-5-6-2, и true next-item: 3-2-4-1

В контексте semantic-id без уникализации:

Обучение: 1-4-5, 1-4-2, 5-2-3, 3-4-2, 4-5-6, и true next-item: 3-2-4



Как нам считать метрики качества предсказания next-item – по 3-2-4-1 или по 3-2-4?

Semantic ids: как считаем метрики recsys?

История пользователя оригинальная:

Обучение: 1-4-5-1, 1-4-2-5, 5-2-3-1, 3-4-2-1, 4-5-6-2, и true next-item: 3-2-4-1

В контексте semantic-id без уникализации:

Обучение: 1-4-5, 1-4-2, 5-2-3, 3-4-2, 4-5-6, и true next-item: 3-2-4

Расчет метрик по 3-2-4 – ок, но как промежуток. Конечным образом нужны метрики по 3-2-4-1.

Причина:

- 1) Юзеры видят конечные айтемы: 3-2-4-1, «бекенд» ожидает 3-2-4-1
- 2) В случае коллапса (все item_id мапятся в один sid), у вас идеальные метрики, но бесполезный рексис. Где вы находитесь между коллапсом и отсутствием этой проблемы?

Пример коллапса, когда все item_id мапятся в один s-id:

Обучение: 1-1-1, 1-1-1, 1-1-1, 1-1-1, 1-1-1, и true next-item: 1-1-1

Тривиальная задача! Идеальные метрики!

Semantic ids: внутренние метрики

	Метрика	Что измеряет	Хорошее значение / интерпретация	Зачем важна для RecSys
A. Базовые sanity-check метрики 	1 Uniqueness	Доля уникальных SID среди товаров	Выше	Sanity-check против коллапса
	2 Collision Rate	Доля неуникальных SID	Ниже	Много коллизий вредит retrieval
	3 Codebook Entropy	Насколько равномерно используются коды	Достаточно высокая	Показывает отсутствие collapse
B. Семантическая сохранность 	4 Semantic Cohesion	Похожи ли товары внутри одного SID-кластера	Выше	Сильный проху downstream-качества
	5 Neighborhood Preservation@K	Сохраняются ли ближайшие соседи	Выше	Сохраняет локальную структуру
	6 Rank Correlation	Сходство рангов/дистанций до и после SID	Выше	Сохраняет глобальный порядок похожести
C. Collaborative / preference-aware метрики 	7 Collaborative Cohesion	Похожесть по поведению внутри SID-кластера	Выше	Важно для recommendation, а не только текста
	8 Preference Discrimination	Разделяются ли разные preference-группы	Выше	Помогает ранжированию и персонализации
D. Метрики, важные для генеративной модели 	9 SID Sequence Perplexity	Насколько легко LM предсказывает последовательности SID	Ниже	Слишком сложные SID вредят генерации
	10 Correlation with Recall/NDCG	Связь SID-метрики с конечными RecSys-метриками	Сильнее	Проверка полезности проху-метрики

 **Практический вывод**

 Самые полезные проху-метрики: Semantic Cohesion, Collaborative Cohesion, Preference Discrimination.

 Neighborhood Preservation хорошо отражает сохранение структуры.

 Uniqueness и Entropy полезны как sanity-check, но сами по себе недостаточны.

 Для генеративных моделей важна learnability: SID Sequence Perplexity.

 Лучшая метрика — та, что реально коррелирует с Recall/NDCG.

1 Uniqueness = $\frac{|unique(SID)|}{N}$

2 Collision Rate = $1 - \text{Uniqueness}$

3 Entropy = $H = - \sum p(c) \log p(c)$

Semantic ids: Semantic Cohesion/Preference Discrimination

Косинусная близость

$$SC(\mathcal{G}) = \frac{2}{|\mathcal{G}|^2 - |\mathcal{G}|} \sum_{i,j \in \mathcal{G}, i \neq j} \frac{\mathbf{q}_i \cdot \mathbf{q}_j}{\|\mathbf{q}_i\| \cdot \|\mathbf{q}_j\|}$$

$$SC = \frac{1}{|\mathcal{C}|} \sum_{\mathcal{G} \in \mathcal{C}} SC(\mathcal{G})$$


$\mathcal{G}$ – кластер (конкретный semantic-id)

Эмбединг айтема

$$PD = \log \left(\frac{2}{M(M-1)} \sum_{a=1}^M \sum_{b=a+1}^M e^{-t \cdot \left(1 - \frac{\vec{\mathbf{p}}_{g_a} \cdot \vec{\mathbf{p}}_{g_b}}{\|\vec{\mathbf{p}}_{g_a}\| \cdot \|\vec{\mathbf{p}}_{g_b}\|}\right)} \right)$$

Центроиды

Semantic ids: реальные графики обучения



* Взято из курсовой работы студента этого года

Semantic ids: влияют ли разные sid политики на качество?

Table 7 Spearman rank correlation between SID metrics and UAUC or Recall@10.

Metric	Spearman Correlation with UAUC	Spearman Correlation with Recall@10
Semantic Cohesion	0.90	0.94
Preference Discrimination	-0.90	-0.75
Collision Rate	-0.70	-0.93
Gini Coefficient	-0.70	-0.64

Table 3 Generative offline MRR performance and online A/B test results on industrial dataset. The **bold** values indicate the best performance, and the underlined values denote the second-best performance.

Method	MRR $\uparrow$	StayTime/U $\uparrow$	LongStay/U $\uparrow$
RQ-VAE	0.605	2630	25.20
R-KMeans	<u>0.618</u>	<u>2650</u>	<u>25.28</u>
R³-VAE	0.628 (+1.62%)	2672 (+0.83%)	25.35 (+0.28%)


Table 4 Downstream discriminative recommendation performance and SID quality metrics of *R³-VAE* and baselines on industrial dataset.

Method	UAUC $\uparrow$	Semantic $\uparrow$ Cohesion	Preference $\downarrow$ Discrimination	Collision $\downarrow$ Rate	Gini $\downarrow$ Coefficient
RQ-VAE	0.6538	0.76	-1.950	1.271	0.0815
OPQ-KMeans	0.6571	0.85	-1.975	1.070	0.0692
R-KMeans	0.6577	0.92	-1.985	1.039	0.0366
MQ	0.6553	0.91	-1.960	1.037	0.0348
R³-VAE	0.6669	0.94	-1.980	1.033	0.0314

LLM овервью

LLM по этапам: задачи, лоссы и игрушечные примеры

Что именно решается на каждом этапе обучения



OpenOneRec – как пример llm4recsys



OpenOneRec Technical Report

An Open Foundation Model and Benchmark to Accelerate Generative Recommendation


OneRec Team




<https://huggingface.co/OpenOneRec>



<https://github.com/Kuaishou-OneRec/OpenOneRec>




OpenOneRec – фазы обучения



OpenOneRec работает на semantic-id

OpenOneRec: item tokens и рекомендация как autoregressive modeling

Схема по разделу про Itemic Tokens и unified Next-Token Prediction



OpenOneRec – пример данных

Multi-Domain Coverage. The benchmark spans three distinct domains, each capturing different user behavior patterns:

- **Short Video (Content Domain):** Short-form videos from Kuaishou, covering viewing behaviors across various APP tabs. We provide *impression sequences* along with the corresponding interaction type for each impression.
- **Ad (Commercial Domain):** Promotional short videos sponsored by advertisers on the Kuaishou platform, typically containing clickable redirects. We provide *click sequences* recording user ad click behaviors.
- **Product (E-commerce Domain):** Products listed in the Kuaishou Mall. We provide *click sequences* recording user product click behaviors.

Rich Metadata. Beyond interaction logs, RecIF-Bench provides comprehensive metadata across three dimensions:

- **User-side:** Each user is represented by a *User Portrait*—a unified narrative that interleaves natural language descriptions with itemic tokens. This portrait weaves together demographics (gender, age), content creation history, recent searches, followed creator types, viewing preferences, comments, livestream views, purchase records, shopping cart items, local service coupons, ad exposures, and commercial intent signals.
- **Item-side:** Each item is associated with multimodal embeddings (4096-dim text embedding and 5-frame visual embeddings with 1152-dim per frame). Additionally, we provide dense captions for approximately 13M videos.
- **Interaction-side:** For each user-video pair in the exposure sequence, we record multi-label behavioral signals including like, follow, comment, effective view, and dislike.

Domain	# Users	# Items	# Interactions	Avg. Hist. Item	Avg. Tgt. Item
Short Video	195,026	13,107,675	94,443,611	458.1	8.6
Ad	151,259	177,548	5,341,911	29.9	5.5
Product	144,307	2,055,240	20,087,210	132.5	6.7
Total	202,359	15,340,463	119,872,732	574.9	17.5

OpenOneRec – примеры данных

Interleaved User Persona Grounding

平台上有一名用户，她创作内容涵盖：8个其他，1个美食，1个数码，1个明星娱乐。
她近期的搜索记录包括：怎么拍游戏视频、黑白头像可爱、.....。
她近期的购买记录包括：商品<|item_begin|><item_a_6133><item_b_5060><item_c_5431><|item_end|>，具体类型为【女装-裤子-休闲裤】，花费290元。
她近期在视频<|item_begin|><item_a_3316><item_b_7440><item_c_2022><|item_end|>下评论了"这个短剧叫什么名字啊"；在视频<|item_begin|><item_a_7822><item_b_1648><item_c_5756><|item_end|>下评论了"嘻嘻嘻，真的吗？我也喜欢玩蛋仔派对，早就关注你了"；.....。
她点赞了视频<|item_begin|><item_a_5743><item_b_930><item_c_1231><|item_end|>.....；
收藏了视频<|item_begin|><item_a_468><item_b_8186><item_c_5877><|item_end|>.....；
分享了视频.....。她关注的博主类型有：【其他】占47.58%，【颜值】占16.52%，【明星娱乐】占8.37%，.....。
她近期观看的直播类型包括：【闲聊互动-热闹闲聊】分类下的直播点赞了6次，评论了59次；.....
她过去30天观看时间最长的1种短剧类型分别是:[解密_悬疑]看了30.0分钟
.....

There is a user on the platform whose content creation covers: 8 in "Other," 1 in "Food," 1 in "Digital Tech," and 1 in "Celebrity & Entertainment."
Her recent search history includes: "how to film game videos," "cute black and white avatars," ...
Her recent purchase records include the item <|item_begin|><item_a_6133><item_b_5060><item_c_5431><|item_end|>, categorized as [Women’s Wear - Pants - Casual Pants], costing 290 RMB.
In terms of recent social interactions, she commented "What is the name of this short drama?" under the video <|item_begin|><item_a_3316><item_b_7440><item_c_2022><|item_end|>; and commented "Really? I love playing Eggy Party too! Actually, I’ve been following you for a while" under the video <|item_begin|><item_a_7822><item_b_1648><item_c_5756><|item_end|>; ...
She also liked the video <|item_begin|><item_a_5743><item_b_930><item_c_1231><|item_end|> ...;
Bookmarked the video <|item_begin|><item_a_468><item_b_8186><item_c_5877><|item_end|> ...
Shared the video ...
The types of creators she follows are: [Others] accounting for 47.58%, [Beauty] accounting for 16.52%, [Entertainment] accounting for 8.37%, and ...
Her recent livestream viewing history includes: 6 likes and 59 comments in the [Chat & Interaction - Lively Chat] category; and 9 comments in another...
Over the past 30 days, her most-watched short drama genre was [Mystery/Suspense], with a total viewing time of 30.0 minutes...

B.3.1. Itemic Dense Caption Data

Itemic Dense Caption Data

视频<|item_begin|><item_a_5028><item_b_6733><item_c_2559><|item_end|> 展示了以下内容：视频内容聚焦在庆祝冬至这一重要节日的习俗，特别是享受饺子与汤圆等美食。视频表达了冬至节气的特色意义，以及人们对新一年开始的寓意。内容上，显现出浓浓的节日气氛与家庭温暖，可能会触动那些寻求传统节日体验和家的感觉的观众。视频还可能激发观众对中华优秀传统文化的兴趣，以及对家人团聚时的美好记忆。通过美食与节日的结合，观众可感受到温馨和幸福，为冬至节日的到来营造了欢乐与期盼。

<|item_begin|><item_a_5028><item_b_6733><item_c_2559><|item_end|> focuses on the customs of celebrating the Winter Solstice, a significant traditional festival, with a particular emphasis on enjoying delicacies such as dumplings and tangyuan. It conveys the unique cultural significance of the Winter Solstice solar term and its symbolism as the beginning of a new cycle. In terms of content, the video exudes a profound festive atmosphere and familial warmth, likely resonating with viewers seeking traditional holiday experiences and a sense of home. Furthermore, it may spark interest in traditional Chinese culture and evoke cherished memories of family reunions. By blending culinary traditions with the holiday spirit, the video allows the audience to experience warmth and happiness, fostering a sense of joy and anticipation for the arrival of the Winter Solstice.

B.3.2. Sequential User Behavior Data

Sequential User Behavior Data

用户的曝光序列为<|item_begin|><item_a_1023><item_b_5426><item_c_6422><|item_end|>, <|item_begin|><item_a_3168><item_b_7950><item_c_4134><|item_end|>,.....;
其中长播列表是<|item_begin|><item_a_4988><item_b_7436><item_c_2477><|item_end|>, <|item_begin|><item_a_5087><item_b_7888><item_c_4759><|item_end|>,.....;
点赞列表是<|item_begin|><item_a_3168><item_b_7950><item_c_4134><|item_end|>, <|item_begin|><item_a_250><item_b_2310><item_c_4925><|item_end|>,.....

The user’s exposure sequence is <|item_begin|><item_a_1023><item_b_5426><item_c_6422><|item_end|>, <|item_begin|><item_a_3168><item_b_7950><item_c_4134><|item_end|>, ...;
The long-viewed list is <|item_begin|><item_a_4988><item_b_7436><item_c_2477><|item_end|>, <|item_begin|><item_a_5087><item_b_7888><item_c_4759><|item_end|>, ...;
The like list is <|item_begin|><item_a_3168><item_b_7950><item_c_4134><|item_end|>, <|item_begin|><item_a_250><item_b_2310><item_c_4925><|item_end|>, ...

OpenOneRec – как пример llm4recsys




Table 2 | Task Taxonomy of RecIF-Bench. We formalize 8 tasks across 4 capability layers, specifying the input/output format and evaluation focus.


Layer	Task	Input (X)	Target (Y)	Metric
L0: Alignment	Item Understanding	Item i	Item Description	LLM-as-Judge
L1: Fundamental Recommendation	Short Video Rec	History $\mathcal{H}^{video}$	Next item i_{video}	Pass@1/32, Recall@32
	Ad Rec	$\mathcal{H}^{video} + \mathcal{H}^{ad}$	Next item i_{ad}	Pass@1/32, Recall@32
	Product Rec	$\mathcal{H}^{video} + \mathcal{H}^{product}$	Next item $i_{product}$	Pass@1/32, Recall@32
	Label Pred.	$\mathcal{H}^{video} + \text{Item } i_{video}$	Binary (Yes/No)	AUC
L2: Instruction Following	Interactive Rec	Portrait $\mathcal{P}$ + Query q	Item i user engages with	Pass@1/32, Recall@32
	Label-Cond. Rec	$\mathcal{H}^{video} + \text{Action } a$	Item i with action a	Pass@1/32, Recall@32
L3: Reasoning	Rec. Explanation	$\mathcal{P} + \mathcal{H}^{video} + \text{Item } i$	Explanation	LLM-as-Judge

3.5. Sanity Check: General Intelligence

To assess whether recommendation-focused models retain general intelligence capabilities, we include a sanity check suite covering four categories: (1) **Math & Text Reasoning**: MATH-500, GSM8K, and AIME’24; (2) **General Tasks**: MMLU-Pro and GPQA-Diamond; (3) **Alignment**: IFEVAL (strict prompt); (4) **Coding**: LiveCodeBench v5. A successful foundation model should maintain competitive performance on these benchmarks while mastering recommendation tasks.

Figure 4 | Task Taxonomy of RecIF-Bench. We organize 8 tasks across 4 capability layers, specifying the instruction, context, and target.

OpenOneRec – как пример llm4recsys



$$L(N, D) = 0.4232 + \frac{502.32}{N^{0.3325}} + \frac{7.02}{D^{0.1865}}$$

$$N_{\text{opt}} \propto C^{0.44}, \quad D_{\text{opt}} \propto C^{0.56}$$

Figure 5 | **Scaling laws on recommendation-domain data.** **Top-left:** training loss vs. FLOPs for different model sizes, and the smooth convex envelope shown in grey. **Top-right:** log-log plot of training loss vs. model size under fixed token budgets. **Bottom-left:** compute-optimal model size $N_{\text{opt}} \propto C^{0.44}$ as a function of compute budget C . **Bottom-right:** compute-optimal token budget $D_{\text{opt}} \propto C^{0.56}$ as a function of C .

OpenOneRec – как пример llm4recsys

5. Post-Training




Figure 6 | Post-training pipeline of the OneRec series models.




Figure 7 | **The pipeline of On-policy Distillation via Policy Gradient.** The student model (Policy Model) samples a trajectory o for the given prompt q , while the Teacher Model provides feedback through Reverse KL divergence as reward r . The Policy Model is iteratively optimized using policy gradient methods based on reward.

B.5. Detailed Data Composition and Token Budgets for Multi-task SFT



Table 15 | **Data Mixture for Multi-task SFT.** The table presents the distribution across reasoning and recommendation domains, showing the sampling weight of each dataset and the subtotal ratio for each category.

Dataset	Weight (%)	Category	Subtotal (%)
OpenMathReasoning ¹⁵	12.971%	Math	64.978%
R1-Distill-SFT ¹⁶	12.784%	General	
Infinity_Instruct ¹⁷	11.359%	Instruction	
OpenCoderReasoning ¹⁸	11.130%	Code	
Chinese-Reasoning-Distil-Data ¹⁹	4.552%	General	
Reasoning_Multi_subject_RLVR ²⁰	4.376%	Multi-subject	
Reasoning_KodCode_V1_SFT_R1 ²¹	4.167%	Code	
DeepMath103K ²²	2.362%	Math	
medical-o1-reasoning-SFT ²³	1.277%	Medical	35.022%
Label prediction	7.800%	Reco	
SID to Caption generation	7.493%	Reco	
Interactive recommendation	6.392%	Reco	
Video recommendation	3.971%	Reco	
Label conditional recommendation	3.575%	Reco	
Product recommendation	2.878%	Reco	
Ad recommendation	2.820%	Reco	
Recommendation reasoning	0.094%	Reco	

OpenOneRec – как пример llm4recsys

Rec-RL в OpenOneRec: GRPO для рекомендаций

Как recommendation-oriented reinforcement learning напрямую оптимизирует hit-based метрики



OpenOneRec – как пример llm4recsys

Table 4 | Unified performance comparison across all tasks. For each task, the **bold** results highlight the best results (with an orange background), while the second-best ones are underlined. Missing entries are marked as “–”.

Task	Metric	SASRec	BERT4Rec	GRU4Rec	HSTU	ReaRec	TIGER	LC-Rec-8B	OneRec-1.7B	OneRec-8B	OneRec-1.7B-Pro	OneRec-8B-Pro
Short Video Rec	Pass@1	0.0045	0.0040	0.0051	0.0043	0.0052	0.0168	0.0341	0.0496	<u>0.0542</u>	0.0456	0.0548
	Pass@32	0.1003	0.0951	0.0993	0.1010	0.1002	0.1061	0.1306	0.1710	<u>0.2104</u>	0.1706	0.2122
	Recall@32	0.0119	0.0113	0.0117	0.0119	0.0120	0.0132	0.0180	0.0272	<u>0.0355</u>	0.0274	0.0369
Ad Rec	Pass@1	0.0044	0.0061	0.0059	0.0076	0.0035	0.0125	0.0197	0.0169	<u>0.0219</u>	0.0190	0.0259
	Pass@32	0.0980	0.1225	0.1102	0.1266	0.1054	0.1769	0.2096	0.2037	<u>0.2490</u>	0.2126	0.2700
	Recall@32	0.0293	0.0381	0.0336	0.0409	0.0327	0.0581	0.0723	0.0707	<u>0.0877</u>	0.0735	0.0964
Product Rec	Pass@1	0.0052	0.0054	0.0047	0.0055	0.0030	0.0120	0.0178	0.0144	<u>0.0187</u>	0.0158	0.0223
	Pass@32	0.0914	0.0936	0.0821	0.0914	0.0907	0.1276	0.1809	0.1571	<u>0.1971</u>	0.1761	0.2290
	Recall@32	0.0175	0.0193	0.0161	0.0178	0.0189	0.0283	0.0416	0.0360	<u>0.0470</u>	0.0405	0.0538
Label-Cond. Rec	Pass@1	0.0026	0.0026	0.0032	0.0026	0.0027	0.0044	0.0079	0.0064	<u>0.0097</u>	0.0067	0.0099
	Pass@32	0.0380	0.0372	0.0393	0.0383	0.0381	0.0337	0.0420	<u>0.0431</u>	0.0535	0.0420	0.0549
	Recall@32	0.0140	0.0135	0.0143	0.0139	0.0137	0.0123	0.0170	0.0184	<u>0.0228</u>	0.0182	0.0235
Label Pred.	AUC	0.6244	0.6598	0.6640	0.6581	0.6204	<u>0.6675</u>	0.6139	0.6184	0.6615	0.6071	0.6912
Interactive Rec	Pass@1	–	–	–	–	–	–	0.0890	0.0660	<u>0.1230</u>	0.0800	0.1250
	Pass@32	–	–	–	–	–	–	0.3730	0.3170	<u>0.4570</u>	0.3370	0.5080
	Recall@32	–	–	–	–	–	–	0.2394	0.1941	<u>0.3032</u>	0.2024	0.3458
Item Understand.	LLM-Judge Score	–	–	–	–	–	–	0.2517	0.3175	<u>0.3202</u>	0.3133	0.3209
Rec. Explanation	LLM-Judge Score	–	–	–	–	–	–	<u>3.9350</u>	3.3540	3.6774	3.5060	4.0381

Table 5 | Performance comparison on general capability (Thinking). For each task, the **bold** results highlight the best results, while the second-best ones are underlined.

Category	Task	Qwen3-1.7B	OneRec-1.7B	OneRec-1.7B-Pro	Qwen3-8B	OneRec-8B	OneRec-8B-Pro
Math & Text Reasoning	MATH-500	0.8780	0.8840	0.8840	0.9520	<u>0.9460</u>	0.9380
	GSM8K	0.9121	0.8984	0.8999	<u>0.9568</u>	0.9575	0.9575
	AIME'24	0.4938	0.4104	0.4146	0.7917	<u>0.7250</u>	0.7188
General Tasks	MMLU-Pro	0.5422	0.3548	0.3932	0.7235	<u>0.5342</u>	0.5204
	GPQA-Diamond	0.3788	0.3232	0.3333	0.5606	<u>0.5000</u>	<u>0.5051</u>
Alignment Tasks	IFEVAL _{strict prompt}	0.6969	0.5471	0.5416	0.8577	<u>0.7893</u>	0.7634
Coding	LiveCodeBench v5	0.3907	0.2832	0.2832	0.5484	<u>0.4910</u>	0.4667

Table 6 | Performance comparison on general capability (Non-Thinking). For each task, the **bold** results highlight the best results, while the second-best ones are underlined.

Category	Task	Qwen3-1.7B	OneRec-1.7B	OneRec-1.7B-Pro	Qwen3-8B	OneRec-8B	OneRec-8B-Pro
Math & Text Reasoning	MATH-500	0.6980	0.7060	0.6940	0.8380	<u>0.8240</u>	0.7980
	GSM8K	0.8218	0.8036	0.8158	<u>0.9303</u>	0.9310	0.9196
	AIME'24	0.1313	0.1271	0.1250	0.2729	<u>0.2417</u>	0.2271
General Tasks	MMLU-Pro	0.4384	0.3072	0.2804	0.6632	<u>0.5795</u>	0.4521
	GPQA-Diamond	0.3030	0.3131	0.2778	<u>0.3990</u>	0.4040	0.3939
Alignment Tasks	IFEVAL _{strict prompt}	0.6747	0.4769	0.5250	0.8392	<u>0.7357</u>	0.7098
Coding	LiveCodeBench v5	0.1219	0.1219	0.1147	0.2760	<u>0.2401</u>	<u>0.2401</u>

OpenOneRec – transfer learning на Амазон бенчмарк


Table 7 | Cross-Domain generalization performance on Amazon domains. Best results are indicated with bold fonts and orange background.

Model	Metric	Baby	Beauty	Cell	Grocery	Health	Home	Pet	Sports	Tools	Toys
SASRec	R@5	<u>0.0232</u>	0.0393	0.0482	0.0480	0.0295	0.0133	0.0377	0.0240	0.0269	0.0420
	R@10	<u>0.0381</u>	0.0639	0.0782	0.0789	0.0506	0.0212	0.0607	0.0389	0.0437	0.0658
	N@5	0.0137	0.0209	0.0281	0.0262	0.0173	0.0070	0.0222	0.0130	0.0149	0.0217
	N@10	0.0185	0.0289	0.0378	0.0361	0.0242	0.0098	0.0296	0.0178	0.0203	0.0294
BERT4Rec	R@5	0.0117	0.0219	0.0325	0.0307	0.0204	0.0063	0.0218	0.0151	0.0145	0.0200
	R@10	0.0228	0.0419	0.0569	0.0534	0.0353	0.0113	0.0412	0.0261	0.0264	0.0362
	N@5	0.0065	0.0120	0.0190	0.0174	0.0117	0.0038	0.0123	0.0083	0.0083	0.0102
	N@10	0.0101	0.0185	0.0268	0.0247	0.0165	0.0054	0.0186	0.0119	0.0121	0.0154
GRU4Rec	R@5	0.0202	0.0322	0.0430	0.0362	0.0256	0.0090	0.0264	0.0174	0.0176	0.0266
	R@10	0.0346	0.0539	0.0676	0.0591	0.0423	0.0156	0.0449	0.0278	0.0305	0.0453
	N@5	0.0124	0.0201	0.0275	0.0230	0.0164	0.0058	0.0163	0.0110	0.0116	0.0171
	N@10	0.0170	0.0271	0.0355	0.0303	0.0217	0.0079	0.0222	0.0144	0.0158	0.0231
HSTU	R@5	0.0226	0.0456	0.0475	0.0458	0.0330	0.0134	0.0362	0.0227	0.0231	0.0489
	R@10	0.0350	0.0643	0.0725	0.0712	0.0485	0.0197	0.0521	0.0347	0.0337	0.0649
	N@5	<u>0.0156</u>	0.0308	0.0314	0.0297	0.0215	0.0092	0.0239	0.0151	0.0159	0.0339
	N@10	<u>0.0196</u>	0.0368	0.0395	0.0378	0.0265	0.0112	0.0290	0.0190	0.0193	0.0391
ReaRec	R@5	0.0197	0.0488	0.0444	0.0454	0.0326	0.0150	0.0299	0.0231	0.0219	<u>0.0517</u>
	R@10	0.0320	0.0702	0.0711	0.0730	0.0481	0.0210	0.0486	0.0348	0.0310	<u>0.0706</u>
	N@5	0.0123	<u>0.0341</u>	0.0269	0.0289	0.0213	0.0101	0.0189	0.0152	0.0143	<u>0.0369</u>
	N@10	0.0163	0.0409	0.0355	0.0378	0.0263	0.0121	0.0249	0.0189	0.0173	<u>0.0430</u>
TIGER	R@5	0.0191	0.0413	0.0540	0.0447	0.0328	0.0142	0.0343	0.0216	0.0228	0.0367
	R@10	0.0318	0.0628	0.0786	0.0691	0.0534	0.0216	0.0542	0.0331	0.0344	0.0527
	N@5	0.0125	0.0277	0.0350	0.0295	0.0222	0.0094	0.0232	0.0145	0.0148	0.0255
	N@10	0.0162	0.0346	0.0429	0.0373	0.0289	0.0118	0.0295	0.0182	0.0184	0.0307
LC-Rec	R@5	0.0232	<u>0.0495</u>	<u>0.0585</u>	<u>0.0501</u>	<u>0.0412</u>	<u>0.0199</u>	<u>0.0388</u>	<u>0.0269</u>	<u>0.0288</u>	0.0350
	R@10	0.0344	<u>0.0764</u>	<u>0.0883</u>	<u>0.0790</u>	<u>0.0616</u>	<u>0.0293</u>	<u>0.0612</u>	<u>0.0418</u>	<u>0.0438</u>	0.0549
	N@5	0.0151	0.0338	<u>0.0392</u>	<u>0.0328</u>	<u>0.0272</u>	<u>0.0138</u>	<u>0.0247</u>	<u>0.0177</u>	<u>0.0187</u>	0.0221
	N@10	0.0187	<u>0.0424</u>	<u>0.0488</u>	<u>0.0421</u>	<u>0.0338</u>	<u>0.0168</u>	<u>0.0320</u>	<u>0.0225</u>	<u>0.0235</u>	0.0285
Ours	R@5	0.0352	0.0646	0.0717	0.0688	0.0534	0.0279	0.0563	0.0365	0.0412	0.0693
	R@10	0.0513	0.0924	0.1036	0.1029	0.0768	0.0390	0.0834	0.0547	0.0593	0.0953
	N@5	0.0238	0.0456	0.0490	0.0460	0.0376	0.0202	0.0389	0.0252	0.0295	0.0496
	N@10	0.0289	0.0545	0.0593	0.0570	0.0452	0.0237	0.0476	0.0310	0.0354	0.0579
Improve (%) R@10		34.6↑	20.9↑	17.3↑	30.3↑	24.7↑	33.1↑	36.3↑	30.9↑	35.4↑	35.0↑

OpenOneRec переносится на Амазон без дообучения

OpenOneRec – как пример Ilm4recsys



Адаптивные стратегии использования предобученной модели (6.3.1)



Результаты: средний R@10 (чем больше — тем лучше)

Стратегия	Метрика	Baby	Beauty	Cell	Grocery	Health	Home	Pet	Sports	Tools	Toys	Средний R@10
Extended Residual Quantization	R@5	0.0688	0.0584	0.0574	0.0562	0.0179	0.0227	0.0518	0.0315	0.0559	0.0511	0.0511
	R@10	0.0457	0.0393	0.0383	0.0361	0.0073	0.0123	0.0347	0.0207	0.0432	0.0370	0.0315
Text-Only Adaptation	R@5	0.0517	0.0620	0.0588	0.0667	0.0529	0.0285	0.0545	0.0308	0.0414	0.0605	0.0548
	R@10	0.0454	0.0411	0.0431	0.1048	0.0722	0.0769	0.0850	0.0615	0.0521	0.0521	0.0634
Text-Augmented Itemic Tokens	R@5	0.0852	0.0646	0.0717	0.0688	0.0534	0.0285	0.0563	0.0348	0.0416	0.0603	0.0625
	R@10	0.0811	0.0594	0.1106	0.1029	0.0788	0.0698	0.0781	0.0471	0.0621	0.0623	0.0759
Улучшение (в средн. R@10)	относительно LC-Rec	+10.0%	+18.8%	+21.9%	—	—	—	—	—	—	—	—
	относительно расшир. рез. квант.	+29.2%	+36.1%	+57.3%	—	—	—	—	—	—	—	—

Текстово-дополненные itemic токены дают лучший результат на почти всех датасетах



OpenOneRec – как пример Ilm4recsys




Figure 8 | **Impact of Training Strategies (Domain-Specific vs Multi-Domain Joint) and Few-Shot Learning on Transfer Performance.** We compare OneRec-Foundation (Ours) against TIGER across four Amazon domains under three settings: (1) Few-shot learning with 10% training data, (2) Full-data training with domain-specific strategy, and (3) Full-data training with joint multi-domain strategy. The green dashed line represents the performance gain (Recall@10 difference) of Ours over TIGER.

Отдельная модель на semantic id TIGER проигрывает от multi domain, тогда как OOR выигрывает

OpenOneRec – как пример llm4recsys

Table 10 | Performance comparison on general capability across post-training stages (Thinking).

	Math 500	GSM8K	AIME'24	MMLU Pro	GPQA Diamond	IFEVAL	LiveCodeBench
Qwen3-8B (Base)	0.952	0.9568	0.7917	0.7235	0.5606	0.8577	0.5484
Stage 1: Multi-task SFT	0.936	0.9083	0.5104	0.5307	0.4949	0.6174	0.4516
Stage 2: On-Policy Distillation	0.948	0.9538	0.7125	0.5454	0.5	0.7653	0.4659
Stage 3: Reinforcement Learning	0.938	0.9575	0.7188	0.5204	0.5051	0.7634	0.4667

Table 11 | Performance comparison on general capability across post-training stages (Non-Thinking).

	Math 500	GSM8K	AIME'24	MMLU Pro	GPQA Diamond	IFEVAL	LiveCodeBench
Qwen3-8B	0.838	0.9303	0.2729	0.6632	0.399	0.8392	0.276
Stage 1: Multi-task SFT	0.876	0.906	0.0688	0.4909	0.3384	0.5638	0.1756
Stage 2: On-Policy Distillation	0.848	0.9234	0.2521	0.583	0.4091	0.7689	0.2545
Stage 3: Reinforcement Learning	0.798	0.9196	0.2271	0.4521	0.3939	0.7098	0.2401

Модель забывает general знания

Про рассуждения в LLM

Как LLM учат 'думать'

Простая схема про think tokens, данные и этапы обучения



OneRec think



ONEREC-THINK: In-Text Reasoning for Generative Recommendation

$$\begin{aligned}\tau &\sim P(\cdot \mid \mathcal{P}(s_{v_1}, \dots, s_{v_n}); \theta) \\ s_{v_{n+1}} &\sim P(\cdot \mid \mathcal{P}(s_{v_1}, \dots, s_{v_n}), \tau; \theta)\end{aligned}\quad (2)$$

where $\mathcal{P}(\cdot)$ means a valid prompt constructed for the recommendation.

Table 2: Ablation Study of different variants of OneRec-Think on Beauty dataset.

Training Method	R@5	R@10	N@5	N@10
Base	0.0460	0.0654	0.0314	0.0377
Base+IA	0.0532	0.0735	0.0342	0.0402
Base+IA+R	0.0563	0.0791	0.0398	0.0471





Figure 2: The framework of the OneRec-Think. In the first stage, we achieve item-level semantic alignment through multi-task pre-training. In the second stage, we activate explicit reasoning by prompting the model to generate preference rationales. In the third stage, we refine the reasoning paths through RL based on a reward tailored for recommendations.

OneRec think

OneRec-Think: активация reasoning на шумных пользовательских последовательностях

Как модель сначала учится рассуждать на очищенном контексте, а затем переносит это на сырые пользовательские истории



OneRec think



Figure 4: Demonstration of fine-grained interest reasoning, which shows the end-to-end process from user behavior analysis to interpretable recommendations.

Спасибо за
внимание