



Large Scale Recommendations

ML System Design

- это проектирование архитектуры общего ML pipeline, который подходит под поставленную бизнес-задачу и задает сценарий использования целевой бизнес-метрики и таргета, данных, подбор ML алгоритма для train и inference ML моделей, их тестирование и выкатку.

System Design



- это проектирование архитектуры для Backend & Frontend & DevOps разработки, которая обеспечивает генерацию персонализированных рекомендаций для пользователей, учитывая функциональные и нефункциональные требования, технические метрики и имеющуюся инфраструктуру для деплоя.

ML System Design

Умная лента

- Требуется построить персонализированную ML-based ленту

30 млн клиентов
100 млн постов
DAU – 1 млн
Пиковый RPS – 1k

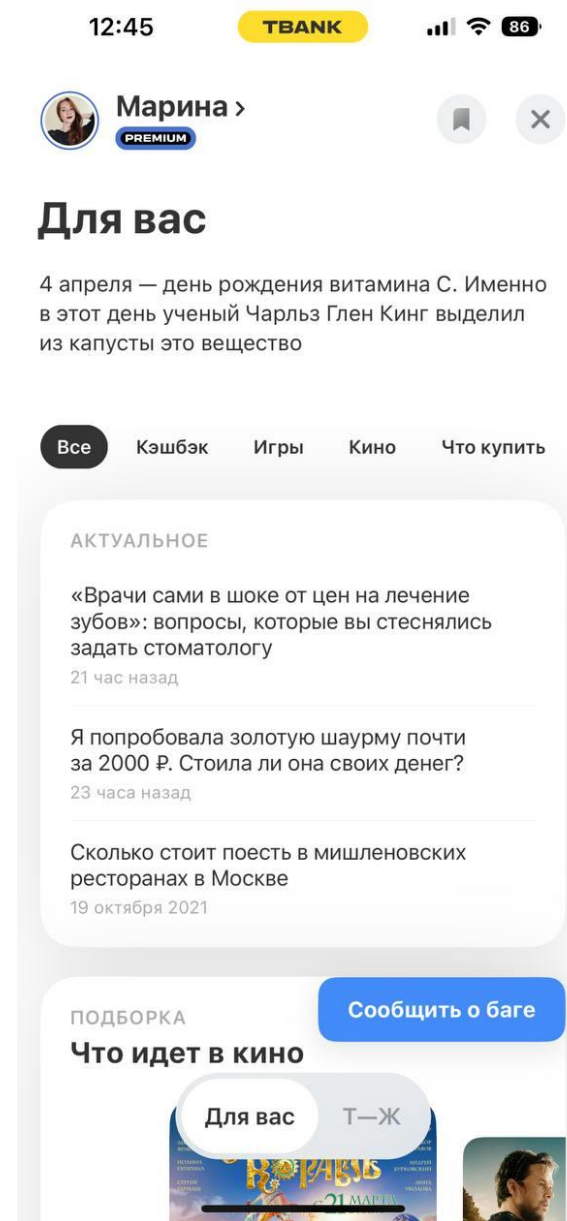


ML System Design

Умная лента

- Требуется построить персонализированную ML-based ленту

30 млн клиентов
100 млн постов
DAU – 1 млн
Пиковый RPS – 1k



1. Определение целей и метрик

Бизнес-цели: Увеличение CTR, среднего времени просмотра, конверсии.

Технические метрики:

Offline: Recall@K, NDCG, AUC.

Online: A/B-тесты на реальных пользователях (например, uplift в engagement).

Этические ограничения: Fairness (минимизация bias для minority групп), прозрачность рекомендаций.

2. Сбор и подготовка данных

Источники данных:

Явные сигналы (клики, лайки).

Неявные сигналы (время просмотра, скроллинг).

Контекстные данные (геолокация, устройство).

Feature Engineering:

Создание эмбедингов для пользователей и айтеров (Word2Vec, GraphSAGE).

Нормализация и обработка временных рядов (сессии пользователей).

Data Pipeline:

Реалтайм-обработка (Apache Kafka, Flink).

Хранение: Feature Store (Feast, Tecton).

ML System Design

Умная лента


- Требуется построить персонализированную ML-based ленту

30 млн клиентов

100 млн постов

DAU — 1 млн

Пиковый RPS — 1k



3. Архитектурный дизайн

Ключевые компоненты:

Candidate Generation:

Методы: Collaborative Filtering, ANN (Faiss, HNSW), Two-Tower модели.

Пример: YouTube'set DNN для генерации тысяч кандидатов.

Ranking:

Модели: Transformer, Deep & Wide архитектуры.

Multi-Task Learning: Оптимизация CTR, watch time, revenue.

Re-Ranking:

Диверсификация (Maximal Marginal Relevance).

Бизнес-правила (продвижение премиум-контента).

Инфраструктура:

Масштабирование: Kubernetes, Ray.

Low-latency inference: Triton Inference Server, ONNX.

4. Разработка и оптимизация модели

Эксперименты:

Сравнение алгоритмов (GNN vs. Transformer vs. классические методы).

Кросс-валидация на временных срезах (time-based split).

Оптимизация для продакшена:

Квантование моделей (TensorFlow Lite).

Динамический выбор фичей (Feature Importance via SHAP).

Сжатие эмбеддингов (TensorFlow Model Optimization Toolkit).

Multi-Objective оптимизация:

Pareto-optimal решения через RL (например, Facebook's).

ML System Design

Умная лента

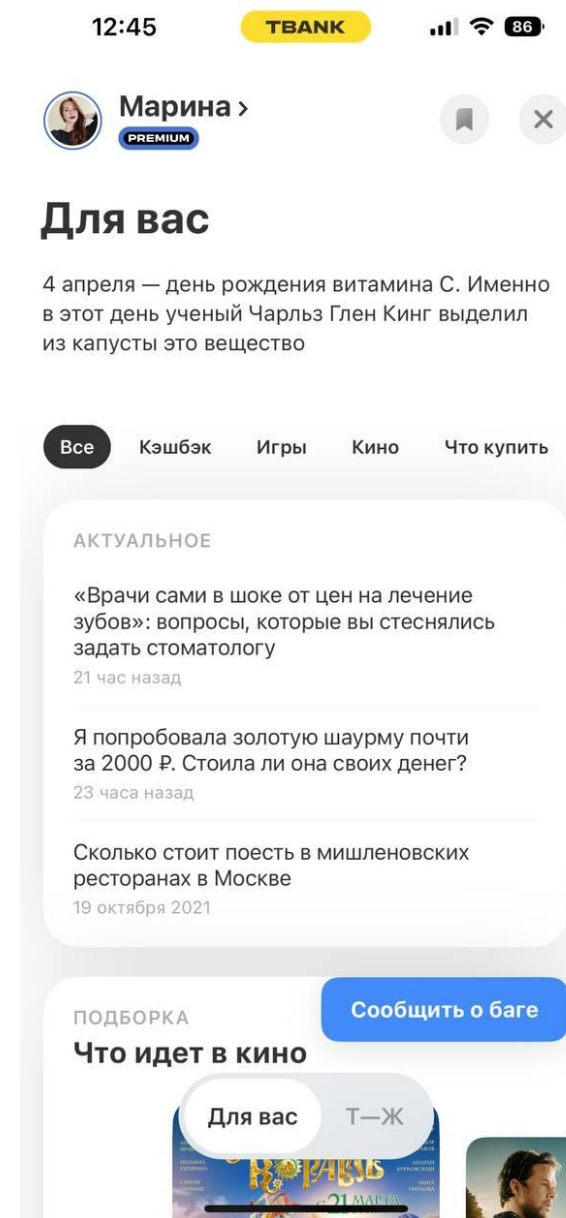
- Требуется построить персонализированную ML-based ленту

30 млн клиентов

100 млн постов

DAU — 1 млн

Пиковый RPS — 1k



5. Тестирование и валидация

Offline-тесты:

Симуляция пользовательского поведения (Replay Testing).

Проверка на leakage и стабильность метрик.

Онлайн-тесты:

A/B-тесты с постепенным rollout (1% → 50% трафика).

Canary-деплой для мониторинга аномалий (Prometheus, Grafana).

Стресс-тесты:

Проверка latency под нагрузкой (например, 100k RPS).

6. Деплоймент и мониторинг

CI/CD для ML:

Автоматизация пайплайнов (MLflow, Kubeflow).

Версионирование моделей и данных (DVC, Neptune).

Мониторинг в реальном времени:

Дрейф данных (Evidently AI).

Деградация метрик (например, падение CTR).

Ресурсопотребление (CPU/GPU utilization).

Fallback-стратегии:

Резервные модели (например, простой Logistic Regression).

7. Итеративное улучшение

Обратная связь от пользователей:

Сбор implicit feedback (повторные клики, отмены действий).


Эксперименты с Exploration-Exploitation (Bandit-алгоритмы).

Адаптация к трендам:

Интеграция новых типов данных (видео, аудио через CLIP).


Переход на энергоэффективные архитектуры (TinyML).

Сценарии доставки RecSys



- Низкая частота обновляемости признаков для моделей
- Редкое обновление рекомендаций
- Обработка большого объема данных за раз
- Большие вычислительные и временные ресурсы на итерацию обновления рекомендаций
- Простой и быстро настраиваемый способ доставки скоров по расписанию для MVP

Сценарии доставки RecSys




- Низкая частота обновляемости признаков для моделей
- Редкое обновление рекомендаций
- Обработка большого объема данных за раз
- Большие вычислительные и временные ресурсы на итерацию обновления рекомендаций
- Простой и быстро настраиваемый способ доставки скоров по расписанию для MVP

- Высокая частота обновления контента и юзеров
- Быстрый процессинг актуальных признаков
- Минимальная задержка скоринга новых айтемов
- Расчет рекомендаций на лету (без предсохранения)
- Большой объем ранжируемых айтемов и юзеров
- Требуется наличие высокопроизводительной инфраструктуры
- Требуется разработки API сервисов и БД


System Design

Для рекомендаций и поиска



2 x 2 of online vs. offline environments, and candidate retrieval vs. ranking.

Лучшие практики RecSys Large-Scale Deploy



ANN benchmarks

ANN-Benchmarks is a benchmarking environment for approximate nearest neighbor algorithms search. This website contains the current benchmarking results. Please visit <http://github.com/erikbern/ann-benchmarks/> to get an overview over evaluated data sets and algorithms. Make a pull request on [Github](#) to add your own code or improvements to the benchmarking system.

Benchmarking Results

Results are split by distance measure and dataset. In the bottom, you can find an overview of an algorithm's performance on all datasets. Each dataset is annotated by $(k = \dots)$, the number of nearest neighbors an algorithm was supposed to return. The plot shown depicts *Recall* (the fraction of true nearest neighbors found, on average over all queries) against *Queries per second*. Clicking on a plot reveals detailed interactive plots, including approximate recall, index size, and build time.


Benchmarks for Single Queries

Results by Dataset

Distance: Angular

glove-100-angular (k = 10)


Метод	Идея	Примеры библиотек
HNSW	Иерархический навигируемый малый мир (граф)	hnswlib, FAISS
IVF (Inverted File)	Кластеризация + поиск по ближайшим кластерам	FAISS, Milvus
LSH (Locality-Sensitive Hashing)	Хеширование, сохраняющее "близость"	FALCONN, Annoy
PQ (Product Quantization)	Сжатие векторов + поиск по кодам	FAISS



Bloom Filter

- вероятностная структура данных для эффективной проверки **принадлежности элемента к множеству**.

Жертвует точностью, допуская **ложноположительные срабатывания** (элемента нет, но фильтр говорит, что есть), но исключает **ложноотрицательные** (если фильтр говорит, что элемента нет, его точно нет).




Example of Bloom Filter (We map each value x, y, z to bit arrays using 3 hash functions) [Source]

Шардирование

- стратегия горизонтального масштабирования с разбивкой базы данных на отдельные части (шарды) на разных серверах и группах серверов.

Партиционирование – разделение внутри одной БД, шардирование – на разных экземплярах БД.





Шардирование

- стратегия горизонтального масштабирования с разбивкой базы данных на отдельные части (шарды) на разных серверах и группах серверов.

Репликация

- дублирование или распространение одинаковых данных для inference или самих рекомендаций на каждом инстансе.




Map Reduce

- модель распределенной обработки больших данных из 2 этапов: отображения и свертки.

Примеры в RecSys:

- Предобработка данных (счетчики по логам user-item взаимодействий)
- Генерация признаков user/item
- Обучение модели (ALS, etc.)



Пример:

```
def mapper(log_entry):  
    user_id, item_id, action = log_entry.split(",")  
    yield (user_id, item_id), 1 # Ключ: (user_id, item_id), Значение: 1
```


```
def reducer(key, values):  
    total = sum(values)  
    yield key, total # (user_id, item_id) → общее количество взаимодействий
```

Map Reduce

- модель распределенной обработки больших данных из 2 этапов: отображения и свертки.

Примеры в RecSys:

- Предобработка данных (счетчики по логам user-item взаимодействий)
- Генерация признаков user/item
- Обучение модели (ALS, etc.)



Пример:


```
def mapper(log_entry):  
    user_id, item_id, action = log_entry.split(",")  
    yield (user_id, item_id), 1 # Ключ: (user_id, item_id), Значение: 1
```

```
def reducer(key, values):  
    total = sum(values)  
    yield key, total # (user_id, item_id) → общее количество взаимодействий
```

DWH vs Data Lake


Критерий	Data Warehouse	Data Lake
Структура данных	Только структурированные данные	Любые данные: структурированные, полуструктурированные, неструктурированные (текст, изображения, логи)
Схема данных	Схема определяется перед записью (Schema-on-Write)	Схема определяется при чтении (Schema-on-Read)
Цель	Оптимизирован для бизнес-аналитики, отчетности, SQL-запросов	Хранение сырых данных для ML, экспериментов, анализа "на будущее"
Гибкость	Жесткая структура, сложно модифицировать	Высокая гибкость: данные сохраняются в исходном виде
Пользователи	Бизнес-аналитики, менеджеры	Data Scientists, инженеры данных
Производительность	Высокая скорость выполнения сложных запросов	Зависит от инструментов (может быть медленнее для больших объемов)
Стоимость хранения	Дорого (требует очистки и трансформации)	Дешевле (сырые данные хранятся без обработки)
Масштабируемость	Ограничена архитектурой	Легко масштабируется в облаке (например, AWS S3)
Примеры технологий	Amazon Redshift, Snowflake, Google BigQuery	Hadoop HDFS, AWS S3, Azure Data Lake Storage
Типичные сценарии	Финансовая отчетность, KPI-дашборды	Обучение ML-моделей, анализ логов, хранение данных IoT

Alibaba TaoBao. Candidate retrieval




Alibaba's design for candidate retrieval in Taobao via item embeddings and ANN.

Alibaba TaoBao. Ranking




Alibaba's design for ranking in Taobao via a graph network (ATBRN).

Facebook. Search Retrieval




NVIDIA. Recommender system


- Data Pipeline
- Training and Continuous Retraining
- Deployment and Serving
- Logging and Monitoring



Пример sequence диаграммы



Пример sequence диаграммы



RecSysOps

- это набор практик для **эффективной эксплуатации рекомендательных систем** в продакшене, объединяющий принципы DevOps, MLOps и специфические требования ML-моделей.

RecSysOps

- это набор практик для **эффективной эксплуатации рекомендательных систем** в продакшене, объединяющий принципы DevOps, MLOps и специфические требования ML-моделей.

Цели:



- Снижение эксплуатационных рисков
- Повышение качества рекомендаций через поиск мест для улучшений
- Оптимизация времени на дебаг
- Сокращение TTM на внедрение инноваций

RecSysOps

- это набор практик для **эффективной эксплуатации рекомендательных систем** в продакшене, объединяющий принципы DevOps, MLOps и специфические требования ML-моделей.

Цели:



- Снижение эксплуатационных рисков
- Повышение качества рекомендаций через поиск мест для улучшений
- Оптимизация времени на дебаг
- Сокращение TTM на внедрение инноваций

Фокус на:



Надежности

Соблюдение SLO/SLA рекомендательных сервисов

RecSysOps

- это набор практик для **эффективной эксплуатации рекомендательных систем** в продакшене, объединяющий принципы DevOps, MLOps и специфические требования ML-моделей.

Цели:



- Снижение эксплуатационных рисков
- Повышение качества рекомендаций через поиск мест для улучшений
- Оптимизация времени на дебаг
- Сокращение TTM на внедрение инноваций

Фокус на:



Надежности

Соблюдение SLO/SLA рекомендательных сервисов



Масштабируемости

Обработка петабайтов данных, рост RPS нагрузки

RecSysOps

- это набор практик для **эффективной эксплуатации рекомендательных систем** в продакшене, объединяющий принципы DevOps, MLOps и специфические требования ML-моделей.

Цели:



- Снижение эксплуатационных рисков
- Повышение качества рекомендаций через поиск мест для улучшений
- Оптимизация времени на дебаг
- Сокращение TTM на внедрение инноваций

Фокус на:



Надежности

Соблюдение SLO/SLA рекомендательных сервисов



Масштабируемости

Обработка петабайтов данных, рост RPS нагрузки



Быстрых итерациях внедрения

CI/CD для ML, баланс между внедрением новых изменений и стабильностью

RecSysOps



Логирование

Например, датасетов (в т.ч. значения признаков),
предсказаний из моделей, их версионирование

RecSysOps



Логирование

Например, датасетов (в т.ч. значения признаков),
предсказаний из моделей, их версионирование



Exploration policy

Пайплайн, по какому принципу будет добавляться
новая для пользователей информация

RecSysOps



Логирование

Например, датасетов (в т.ч. значения признаков), предсказаний из моделей, их версионирование



Exploration policy

Пайплайн, по какому принципу будет добавляться новая для пользователей информация



Интерпретация моделей

Объяснение предсказаний для проверки ожидаемого поведения ML и дебага

RecSysOps



Логирование

Например, датасетов (в т.ч. значения признаков), предсказаний из моделей, их версионирование



Exploration policy

Пайплайн, по какому принципу будет добавляться новая для пользователей информация



Интерпретация моделей

Объяснение предсказаний для проверки ожидаемого поведения ML и дебага



ML модели для диагностики

Обнаружение и предсказание особенностей и проблем с продовой ML моделью

RecSysOps



Figure 1: Components of RecSysOps

Issue Detection

Включает unit тесты, обучение с нуля/дообучение ML, мониторинг и алерты на data drifts, алгоритмические метрики качества против устойчивой к ошибкам модели, обнаружение субоптимальных рекомендаций

RecSysOps



Figure 1: Components of RecSysOps

Issue Detection

Включает unit тесты, обучение с нуля/дообучение ML, мониторинг и алерты на data drifts, алгоритмические метрики качества против устойчивой к ошибкам модели, обнаружение субоптимальных рекомендаций

Issue Prediction

Практика Netflix - симуляция и предсказание рекомендаций до показа новых айтемов пользователям на изучение до запуска, оценка времени от cold start до warm up.

RecSysOps



Figure 1: Components of RecSysOps

Issue Detection

Включает unit тесты, обучение с нуля/дообучение ML, мониторинг и алерты на data drifts, алгоритмические метрики качества против устойчивой к ошибкам модели, обнаружение субоптимальных рекомендаций

Issue Prediction

Практика Netflix - симуляция и предсказание рекомендаций до показа новых айтемов пользователям на изучение до запуска, оценка времени от cold start до warm up.

Diagnosis

Обеспечение воспроизводимости проблемы (логи input/output real-time рекомендаций), поиск места (модель или данные). Anomaly Detection, объяснения (LIME, Shap). Визуализация этапов/компонент модели.

RecSysOps



Figure 1: Components of RecSysOps

Issue Detection

Включает unit тесты, обучение с нуля/дообучение ML, мониторинг и алерты на data drifts, алгоритмические метрики качества против устойчивой к ошибкам модели, обнаружение субоптимальных рекомендаций

Issue Prediction

Практика Netflix - симуляция и предсказание рекомендаций до показа новых айтемов пользователям на изучение до запуска, оценка времени от cold start до warm up.

Diagnosis

Обеспечение воспроизводимости проблемы (логи input/output real-time рекомендаций), поиск места (модель или данные). Anomaly Detection, объяснения (LIME, Shap). Визуализация этапов/компонент модели.

Resolution

В зависимости от времени и причины – быстрые или более долгое реагирование. Инструменты для hotfix/patches с RCA + unit тестами, откат к предыдущей версии модели. Тренировка устойчивых моделей к пропускам в данных по dropout логике.

Лучшие практики RecSysOps


01

Автоматизация
пайплайна

- Feature engineering
(Metaflow FS, Flink)
- Model training
(DVC, MLflow)



<https://github.com/Netflix/metaflow>



Лучшие практики RecSysOps

01

Автоматизация
пайплайна

- Feature engineering (Metaflow FS, Flink)
- Model training (DVC, MLflow)

02

Мониторинг
и алертинг

- Data drift detection
- Model fault detection
- Тех, ML и бизнес мониторинг

03

A/B тесты & rollout

- Постепенная раскатка
- A/B, Multi-armed bandits
- Holdbacks

04

Disaster Recovery

- Fallback стратегии
- Предотвращение каскадных сбоев

Netflix

Лучшие практики RecSysOps

Shadow mode

Запуск новой модели в параллель с текущей продовой моделью, но без влияния на пользователей для оценки рисков

Лучшие практики RecSysOps

Shadow mode

Запуск новой модели в параллель с текущей продовой моделью, но без влияния на пользователей для оценки рисков

Постепенный rollout

- Волновая раскатка ML на части трафика (Canary deploy).
- Многорукие бандиты для быстрой оценки эффективности вместо A/B тестов.
- Динамическое перераспределение трафика через Netflix Zuul



Лучшие практики RecSysOps

Shadow mode

Запуск новой модели в параллель с текущей продовой моделью, но без влияния на пользователей для оценки рисков

Постепенный rollout

- Волновая раскатка ML на части трафика (Canary deploy).
- Многорукие бандиты для быстрой оценки эффективности вместо A/B тестов.
- Динамическое перераспределение трафика через Netflix Zuul

Гранулярное логирование

Запись контекста (user_id, session_id, features) для дебага и воспроизведения сценариев. Внедрение телеметрии (например, OpenTelemetry).

Лучшие практики RecSysOps

Disaster Recovery

- Практика fallback, в том числе через более “легкие” ML модели
- Кэширование (Redis, Memcached)
- Circuit Breakers на ML pipeline (например, недоступность Feature Store)

Лучшие практики RecSysOps

Disaster Recovery

- Практика fallback, в том числе через более “легкие” ML модели
- Кэширование (Redis, Memcached)
- Circuit Breakers на ML pipeline (например, недоступность Feature Store)

Resource-aware

- Оптимизация под квоты инфраструктуры
- Повышение эффективности (метрик оптимизации compute, утилизации GPU, etc.)

Лучшие практики RecSysOps

Disaster Recovery

- Практика fallback, в том числе через более “легкие” ML модели
- Кэширование (Redis, Memcached)
- Circuit Breakers на ML pipeline (например, недоступность Feature Store)

Resource-aware

- Оптимизация под квоты инфраструктуры
- Повышение эффективности (метрик оптимизации compute, утилизации GPU, etc.)

Автотесты на RecSys проблемы

- Например, тесты на проверку информационного пузыря (метрики сравнения diversity & novelty между train и новыми предсказаниями)
- Мониторинг доли cold start items/users и их частота появления в рекомендациях etc.

Netflix

Лучшие практики ResSysOps



<https://github.com/Netflix/chaosmonkey>






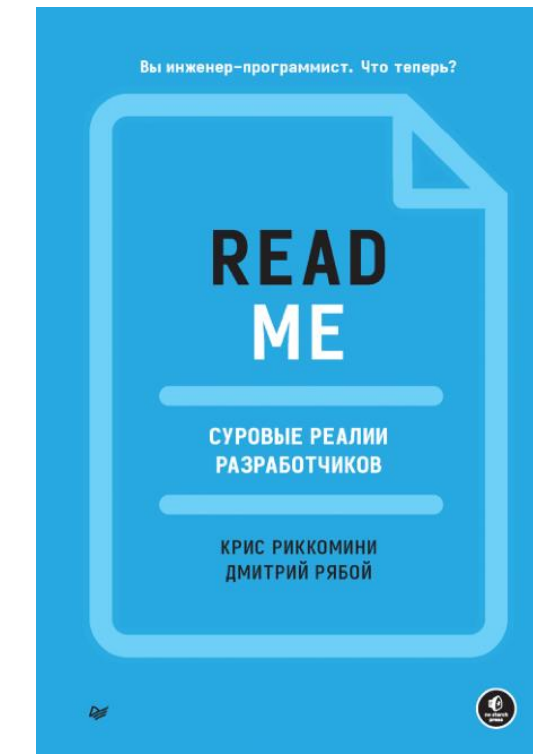



- Симуляция сбоев
- Случайным образом отключает инстансы виртуальных машин и контейнеров продовой среды



<https://github.com/Netflix/Hystrix>

- Обеспечение отказоустойчивости и низких latency
- Изоляция точек доступа к удаленным системам, службам и сторонним библиотекам, предотвращения каскадных сбоев и обеспечения устойчивости в сложных распределенных системах, где сбои неизбежны

Рекомендации по литературе



Спасибо!

