

Лекция 19.

Дизайн рексистем и сервинг моделей



Миша Печатов

Логи

- сразу стоит проверять, что логи не совсем плохие
- надо хранить всегда максимально долгий период
- использовать единые события в моделях, бордах и аналитике

Как доставлять рекомендации

Как доставлять рекомендации

Батчевые процессы

Semi-realtime

Realtime

Батчевые рекомендации

В чем идея?

Раз в N часов пересчитываем рекомендации на всех* пользователей и сохраняем их в хранилище

Плюсы

- Легко реализовать и поддерживать
- Можно затаскивать сложные модели
- Моментальный ответ системы

Минусы

- Дорого вычислительно
- Не учитывается контекст
- Не учитывается текущая сессия
- Подходит не для всех задач

Semi-realtime

В чем идея?

Насчитываем рекомендации заранее, но во время сессии пересчитываем их по триггерам

Плюсы

- Хороший баланс между реактивностью системы и сложностью моделей
- Не очень жесткие требования по latency

Минусы

- Нужны сервисы которые будут инференсить модели в реалтайме

Realtime

В чем идея?

Считаем рекомендации по запросу

Плюсы

- Супер реактивные рекомендации
- Используем самые актуальные фичи и контекст

Минусы

- Очень жесткие требования по latency(200-500мс)
- Нужны быстрые и надежные сервисы которые будут держать нагрузку

Спасибо за внимание