

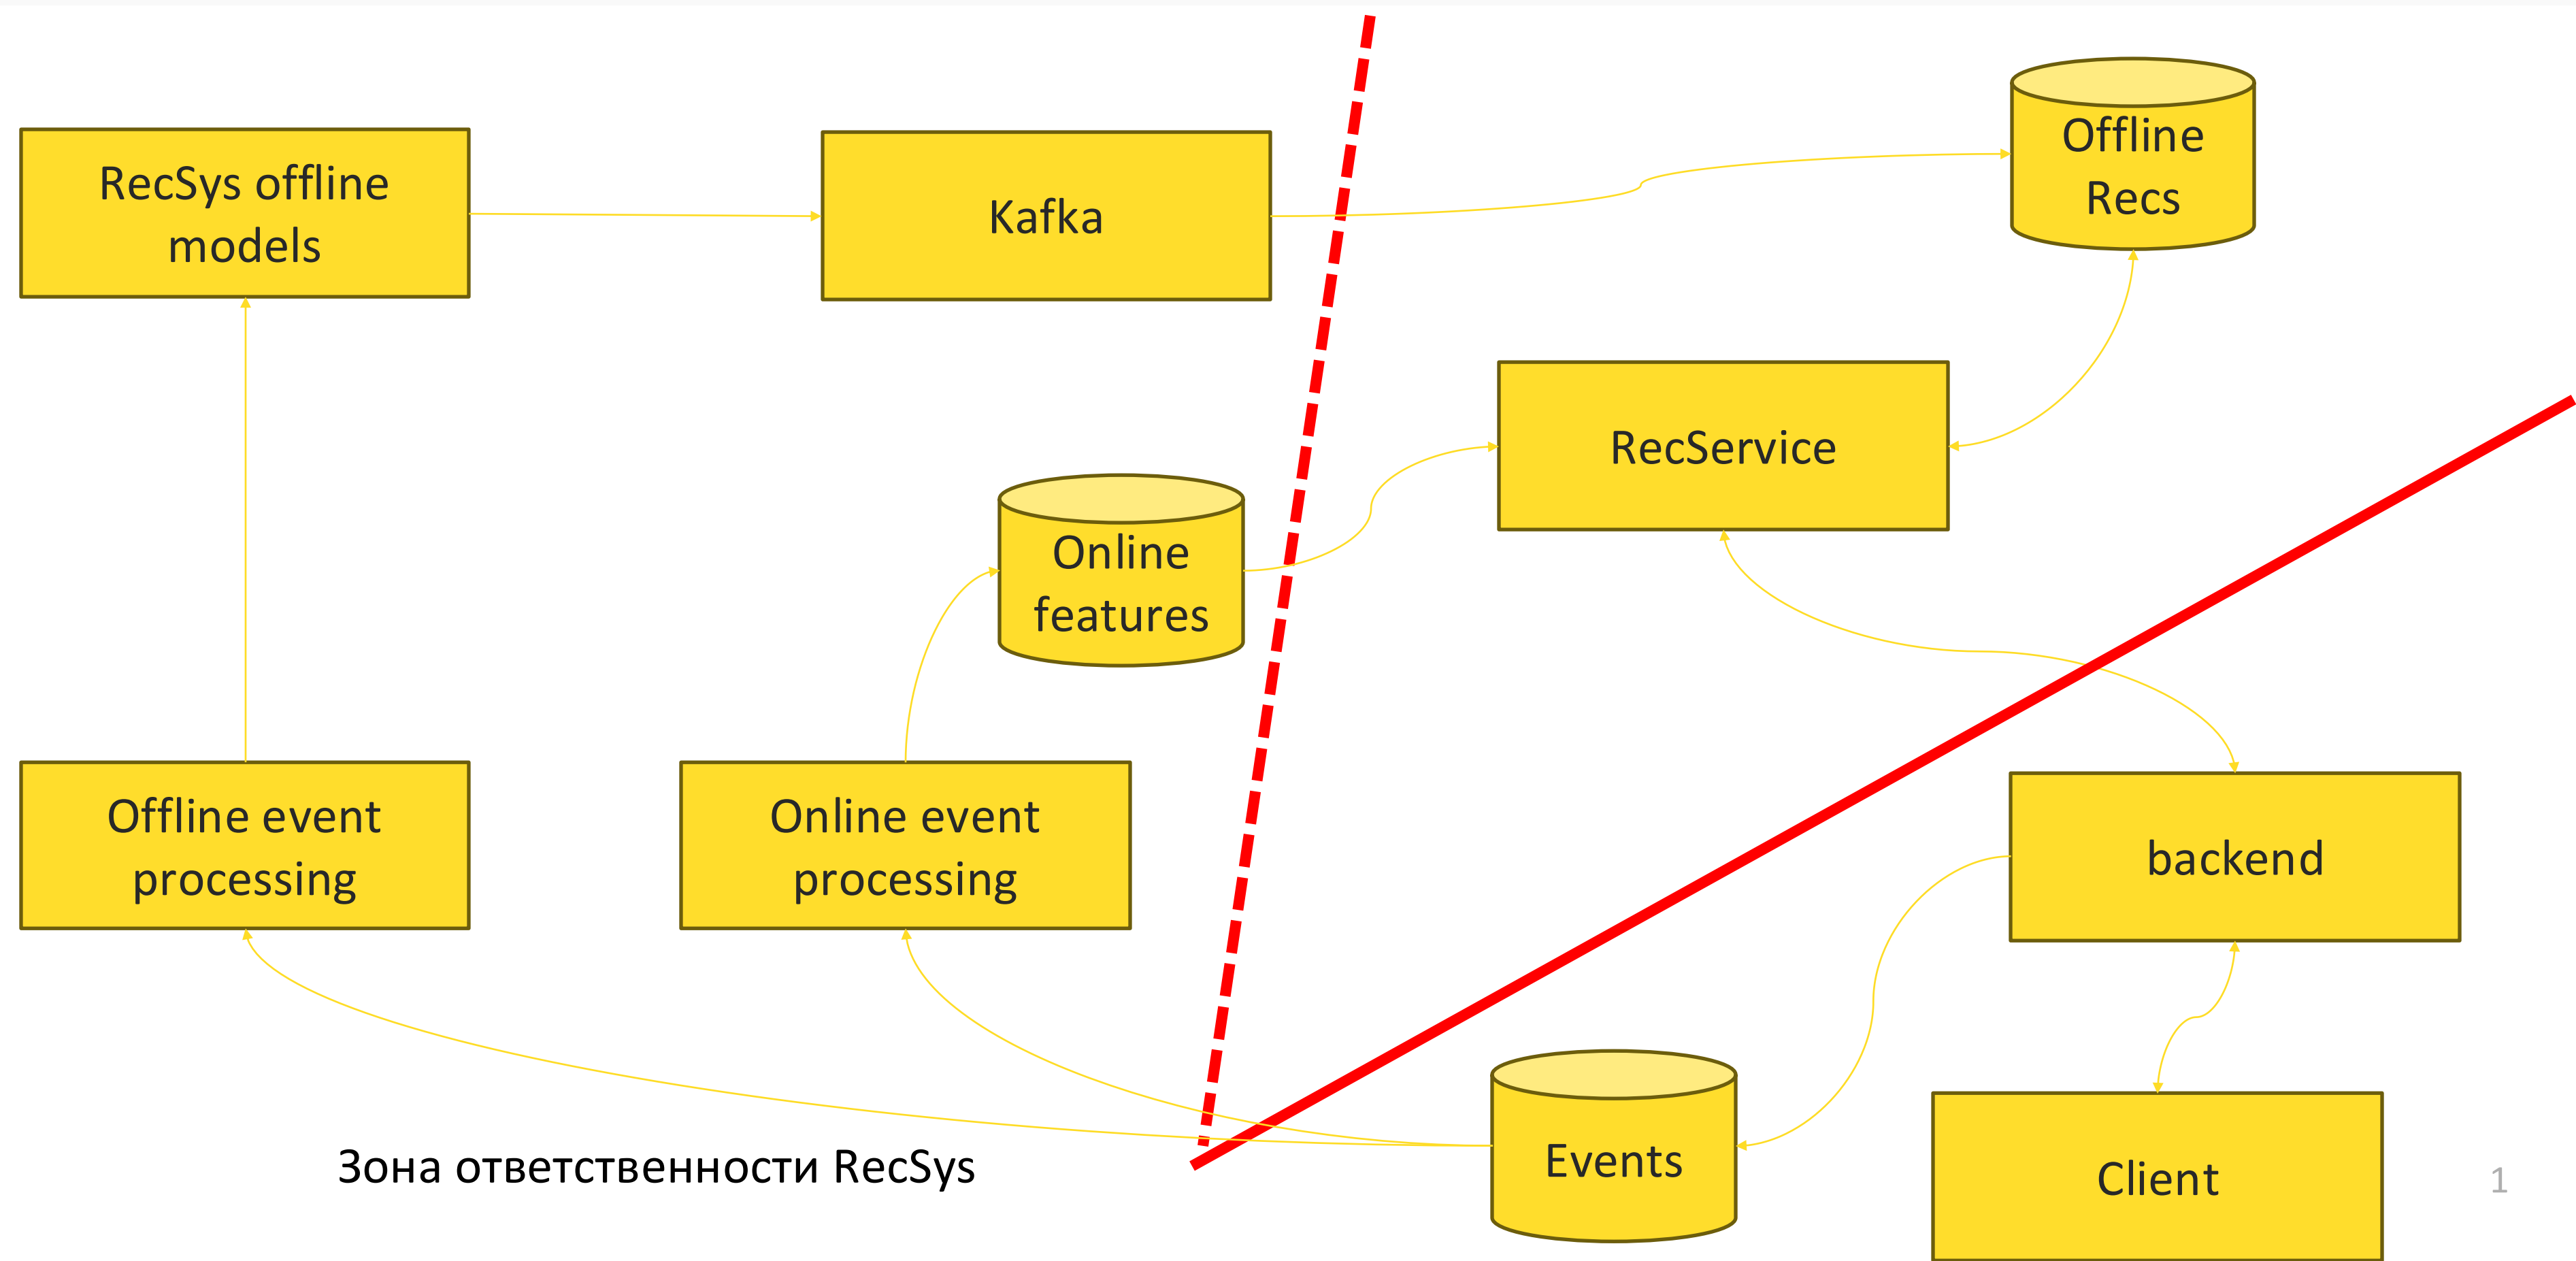


Курс: Рекомендательные системы  
Занятие 20:  
Прикладные аспекты и тренды в  
рекомендательных системах


# План

- Различные прикладные аспекты
  1. про дизайн апдейтов рекомендаций
  2. постпроцессинг штуки и почему так слипается, и что можно делать
  3. про данные с разных поверхностей
  4. про кроссдоменность в трансформере
  5. дилемма про сегментацию + персонализацию
  6. про пагинацию
  7. про чувствительную нерелевантность
  8. про разногласия между кандидатом и ранкером
  9. про круговорот конверсий
- Тренды
  1. ODS
  2. RecSys conference Topics
  3. SIGIR Conference topics
  4. novel directions
  5. LLM as recommender
  6. Онлайнизация
  7. Масштабирование vs окупаемость
  8. дизайны интерфейсов
  9. uplift models
  10. ARGUS
  11. решение от Сбера на avito cup
  12. TG каналы с инфой

# Оффлайн vs нирлайн vs онлайн — pros&cons подходов, use-case сценарии.




# Оффлайн vs нирлайн vs онлайн — pros&cons подходов, use-case сценарии.







# Оффлайн vs нирлайн vs онлайн — pros&cons подходов, use-case сценарии.



# Оффлайн vs нирлайн vs онлайн — pros&cons подходов, use-case сценарии.



# Оффлайн vs нирлайн vs онлайн — pros&cons подходов, use-case сценарии.




# Оффлайн vs нирлайн vs онлайн — pros&cons подходов, use-case сценарии.

|                                              | Offline                      | Near online 1 ч            | Near online ~ минуты       | Online                    |
|----------------------------------------------|------------------------------|----------------------------|----------------------------|---------------------------|
| Сложность разработки                         | просто                       | сложнее                    | Существенно сложнее        | Самое сложное             |
| Скорость учета действий<br>(зависит от базы) | сутки                        | час                        | Несколько минут            | Секунды-десятки секунд    |
| Гибкость по фичам                            | Можно крутить тяжелые модели | В целом гибко              | Сложные фичи сложно тянуть | Низкая                    |
| Бесполезный расчет рекомендаций              | Крайне высокая               | Такая же, но пользы больше | -                          | Низкая, расчет по запросу |
| Фокус разработки                             | Больше ML                    | ML + инфра                 | Эвристики + инфра          | Инфра + немного ML        |



# Нужно понимать ценность каждого контура!




# Пагинация

Можно обновлять  
рекомендации,  
пока человек листает ленту!

Сервис может запрашивать по  
N товаров, но между  
запросами рекомендации  
можно поменять



Только по изменениям



# Пагинация


Пусть я кликнул на Steam Deck,  
тогда на следующей «странице»  
Покажем больше приставок

(эвристика i2i товаров)






# Пагинация + фищи в бустинге



Первая страница



Вторая страница

## MULTISLOT RERANKER: A GENERIC MODEL-BASED RE-RANKING FRAMEWORK IN RECOMMENDATION SYSTEMS

Qiang Charles Xiao<sup>1,†</sup> Ajith Muralidharan<sup>1,†</sup> Birjodh Tiwana<sup>†</sup> Johnson Jia<sup>‡,\*</sup> Fedor Borisjuk<sup>†</sup> Aman Gupta<sup>†</sup> Dawn Woodard<sup>†</sup>

<sup>†</sup> LinkedIn  
<sup>‡</sup> Google


Table 1: A List of Features for Sequential Greedy Algorithm

| Feature Category           | Features                                                                                                                                                                                                                                                                                                             |
|----------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Second Pass Ranking Scores | p(Click)<br>Contribution responses such as p(Like), p(Comment), p(Share), p(Skip)<br>p(Contributions) whose label is positive if any of Like, Comment, Share, Skip is positive.                                                                                                                                      |
| Current Slot's Features    | Slot index $i$<br>Embeddings of item at slot $i$<br>Type of item at slot $i$ such as Video, Image, Job, Company, Article, etc.                                                                                                                                                                                       |
| Interaction Features       | Type of items in previous slots<br>Count of each type of items in previous slots<br>Cross feature with item type among slot $i$ and previous slots<br>Embeddings dot product of items among current slot $i$ and previous slots<br>Whether items at current slot $i$ and previous slots are created by the same user |

Table 2: Relative AUC Improvement By MultiSlot Models



| Response | MultiSlot Logistic Regression | MultiSlot XGBoost |
|----------|-------------------------------|-------------------|
| like     | +3.86%                        | +10.07%           |
| skip     | +3.87%                        | +6.82%            |
| share    | +0.40%                        | +8.08%            |
| click    | +4.17%                        | +8.50%            |
| comment  | +0.41%                        | +6.05%            |

# Про постпроцессинг



25 999 Р ~~28 999 Р~~  
Планшет HUAWEI MatePad  
11.5 Wi-Fi 8/128Gb Space Gra  
Huawei

26 990 Р  
**В рассрочку по 4 498 Р**  
Планшет HUAWEI MatePad  
11.5 LTE 6/128Gb Space Gray  
Huawei



25 999 Р

27 999 Р



Главная



Медиа



Заказы



Видео




На кассе



- 1) Почему модель рекомендаций рекомендует рядом одинаковые товары?
- 2) Почему они в целом получаются рядом?
- 3) Почему можно предположить, что это неэффективно?


Лента рекомендаций

# Про постпроцессинг






# Про постпроцессинг



Зачем может быть выгоднее показать кольцо?

Лента рекомендаций

# Про постпроцессинг




Зачем может быть выгоднее показать кольцо?

Чтобы с большей вероятностью собрать различные данные позитивные о юзере

Лента рекомендаций



# Про постпроцессинг



Лента рекомендаций

Простой алгоритм диверсификации от ChatGPT:

python

Копировать Редактировать

```
# Вход:
# items: список товаров [(item_id, category), ...]
# w: размер окна (например, 3)

function diversify(items, w):
    result = [] # Финальный отсортированный список товаров
    used = [False] * len(items) # Флаг для уже добавленных товаров

    while len(result) < len(items):
        window_categories = set() # Категории последних w-1 товаров в result
        for i in range(1, w):
            if len(result) - i >= 0:
                window_categories.add(result[-i][1])

        best_item_index = -1
        for i in range(len(items)):
            if not used[i]:
                item, category = items[i]
                if category not in window_categories:
                    best_item_index = i
                    break

        # Если не удалось найти подходящий товар (все конфликтуют по категории), ослабляе
        if best_item_index == -1:
            for i in range(len(items)):
                if not used[i]:
                    best_item_index = i
                    break

        result.append(items[best_item_index])
        used[best_item_index] = True

    return result
```












# Про данные с разных поверхностей



Про данные для базиса бустинга (ключи для датасета user – item – timestamp – label). Impression пришел из


- Поиска – тут скорее всего высокая конверсия, айтем более релевантен в моменте
- Каталога – что-то среднее между рекомендациями и поиском
- Рекомендаций – может **вообще не зависеть от юзера**, тут то, что мы хотели показать. Данные зависят от наших моделей

# Про данные с разных поверхностей



Юзер долго листает  
рекомендации, что-то тапает из  
них


Ему может быть легче «допродать» что-то,  
Более uplift сценарии возможны



Юзер в основном пользуется  
поиском

Зона для роста рекомендаций,  
либо человек никогда не будет ими пользоваться  
(хочет сам все контролировать)


# Про кроссдоменность



Обычный SASRec




# Про кроссдоменность




Обычный SASRec, но домены перемешаны

# Про кроссдоменность



Обычный SASRec, но домены перемешаны

# Про кроссдоменность



Обычный SASRec, но домены перемешаны, предсказываем разные айтемы

# Про кроссдоменность

## Преимущества:

- холодные пользователи у продукта будут видеть рекомендации лучше
- может появиться ценность данных одного продукта для другого (экономика данных)
- для активных юзеров может быть лучше персонализация, даже если они не холодные
- возникает «синергия» между продуктами

## Недостатки:


- домены не факт, что помогают друг друга
- старые данные по продукту могут «вымываться» другими доменами при фиксированном SEQ\_LEN
- больше компьютера для расчета рекомендации
- сложнее в реализации

Пример: помогает ли Яндекс музыка для рекомендаций на Яндекс Маркете?  
Помогает ли данные о заказах для рекламы товаров в Озоне?






# Сегментация vs приоритезация vs ранжирование




# Сегментация vs приоритезация vs ранжирование



# Сегментация vs приоритезация vs ранжирование




А что будет  
с  
конверсией  
у айтема?



ML модель  
скорит  
кандидатов

Кандидаты



Не кладем  
в ленту!



Товар для владельцев животных

ML модель на  
вероятность  
владения  
животным

$P = 0.01$

Товар для автовладельцев

ML модель на  
вероятность  
владения авто

$P = 0.8$

Человек автовладелец, но домашних животных нет!  
Что делать тогда?

Результат:

Плюсы:

- 1) Освободили место в ленте
- 2) Убрали нерелевантный товар

Минусы:

- 1) кого-то все равно упустим (кто-то бы кликнул/купил, если бы ему показать)
- 2) возможно не очень масштабируемо

# Сегментация и приоритезация vs полное ранжирование




## Развилка

Сегментация через  
отдельные модели +  
общая мета-модель  
ранжирования более  
верхнеуровневая

Обычный recsys пайплайн (в том числе с  
отбором кандидатов)



# Про чувствительную нерелевантность




Пусть конверсии из просмотра в тап у них примерно равны,  
А ничего из этого вы все равно не купите – все три айтема вам нерелевантны


Одинаково ли нерелевантны вам этим айтемы?



# Про чувствительную нерелевантность



9 999 Р  
Умная колонка Яндекс  
Станция Мини 3 с Алисой



12 150 Р  
В рассрочку по 4 050 Р  
Сборочный комплект AEG SBS KIT  
A3



13 394 Р  
Долями по 3 348 Р  
Вышка-тура каркас сталь рабочая  
высота 5 м

Человек в ленте рекомендаций видел три товара:

- 1) Умная колонка Яндекс Станция Мини 3 с Алисой
- 2) Сборочный комплект AEG SBS KIT A3
- 3) Вышка-тура каркас сталь рабочая высота 5м

Ни на один товар человек не кликнул, только посмотрел. Но какие-то ему понравились больше, какие-то меньше. Угадай какие понравились, а какие нет?

## Вывод:

Наиболее вероятно, что:



✓ Понравилась (вызвала интерес, но не хватило мотивации купить):

- Яндекс Станция Мини 3 (потому что это гаджет, который может быть полезен многим).

✗ Не понравились (или не актуальны):

- Сборочный комплект AEG и Вышка-тура (слишком узкоспециализированные товары, если человек не связан со строительством/ремонтom).

# Про чувствительную нерелевантность



## Вывод:

Наиболее вероятно, что:

✓ Понравилась (вызвала интерес, но не хватило мотивации купить):

- Яндекс Станция Мини 3 (потому что это гаджет, который может быть полезен многим).

✗ Не понравились (или не актуальны):

- Сборочный комплект AEG и Вышка-тура (слишком узкоспециализированные товары, если человек не связан со строительством/ремонтom).



Однако надо понимать, что если кандидатогенераторы  
высокоперсонализированные,  
то человеку это показалось не просто так.  
Но если кандидатогенератор ошибся – это слишком  
заметно


# Про круговорот конверсий

Айтем показывается редко, но на хороший сегмент


Конверсия из просмотра в тап уменьшается

Конверсия из просмотра в тап увеличивается

Айтем показывается часто, но на более широкий сегмент



# Про круговорот конверсий



Если конверсии считаем суммарно по поиску/каталогу/рекомендациям, то рекомендации - самые гибкие:

- можно показать на нерелевантную аудиторию, и конверсия упадет
- можно вообще не показывать, останется только поиск и каталог, а там конверсии высокие

- Проблема, если система не в равновесии и итерации обновлений медленные:
  - Айтем 1 имел конверсию 50%, но показывался на 1000 человек.
  - Новая модель показала его на 1М человек (конверсия 50%), конверсия быстро упала, но убрать уже нельзя



# Про разногласия между ранкером и кандидатогенератором



**Две проблемы:**

- 1) Кандидатогенератор сгенерил крутых кандидатов, но они «плохие» для ранкера и не «пролезают»**
- 2) Ранкер хочет подкинуть классные айтемы вперед, но их нет в кандидатогенераторе**



**Почему так? И что делать?**



# Про разногласия между ранкером и кандидатогенератором



**Две проблемы:**

- 1) Кандидатогенератор сгенерил крутых кандидатов, но они «плохие» для ранкера и не «пролезают»**
- 2) Ранкер хочет подкинуть классные айтемы вперед, но их нет в кандидатогенераторе**

## Что делать:

- 1) Можно явно зафиксировать места в ленте под него (мимо ранкера), можно докинуть в ранкер нужных фичей**
- 2) Можно посмотреть, что любит ранкер и сделать такой же кандидатогенератор (например, айтемы, которые юзер покупал; категории, которые юзер кликал)**

# Тренды. Ods и RecSys коммьюнити доклады

| Зал "Атриум"2024                      |                                                                                                     |                                   |        |
|---------------------------------------|-----------------------------------------------------------------------------------------------------|-----------------------------------|--------|
| <div>Hide fieldsFilterGroupSort</div> |                                                                                                     |                                   |        |
|                                       | Тема                                                                                                | Спикер                            | Секция |
| 1                                     | Открытие                                                                                            | Андрей Зимовнов ML директор AI VK |        |
| 2                                     | Как мы перешли от марковской цепочки к sasrec модели                                                | Анатолий Мاستрюков                | RecSys |
| 3                                     | Эксперты в шоке: ГЕНИАЛЬНАЯ стратегия поиска аудитории кликбейтному контенту                        | Максим Утушкин                    | RecSys |
| 4                                     | Как мы обучали контентный видео-энкодер не используя размеченные данные                             | Евгений Астафуров                 | RecSys |
| 5                                     | Как мы растим маленькие сообщества с помощью верных алгоритмов: показываем людям интересные ...     | Элеонора Пословская               | RecSys |
| 6                                     | Трансформируем рекомендации                                                                         | Александр Пославский              | RecSys |
| 7                                     | Перерыв (большой)                                                                                   |                                   |        |
|                                       |                                                                                                     |                                   |        |
| 8                                     | Технологические тренды в Recsys                                                                     | Кирилл Хрыльченко                 | RecSys |
| 9                                     | Прогрев холодного пользователя                                                                      | Валерия Можарова                  | RecSys |
| 10                                    | RetrievalRecsys: модификация архитектуры для учета текста в персональных рекомендательных системах. | Карина Романова                   | RecSys |
| 11                                    | Чтение между строк: как с помощью ML собирать персональные подборки лучше редакторов                | Денис Красильников                | RecSys |

| 2025                                  |                                                                                       |                                                      |        |
|---------------------------------------|---------------------------------------------------------------------------------------|------------------------------------------------------|--------|
| <div>Hide fieldsFilterGroupSort</div> |                                                                                       |                                                      |        |
|                                       | Тема                                                                                  | Спикер                                               | Секция |
| 2                                     | Ранжирование историй ВК                                                               | Степан Малькевич AI VK<br>Руководитель группы ...    | Recsys |
| 3                                     | Графовые методы в рекомендациях: как мы справляемся с большими графами взаимодействий | Максим Утушкин AI VK<br>Старший разработчик групп... | Recsys |
| 4                                     | Разработка мультимодальных контентных моделей для рекомендаций                        | Илья Алтухов AI VK<br>Руководитель группы ...        | Recsys |
| 5                                     | О глубокой пользе бесполезных почтовых рассылок                                       | Мария Анисимова Mail<br>Руководитель группы ...      | Recsys |
| 6                                     | Перерыв                                                                               |                                                      |        |
| 7                                     | Ускоряем инференс на графовых моделях для теплого старта (AIRI)                       | Евгений Фролов AIRI                                  | Recsys |
| 8                                     | Рекомендация и оптимизация. Как порекомендовать клиентам кэшбек и не разориться?      | Игорь Дойников Альфа-Банк                            | Recsys |
| 9                                     | Масштабирование рекомендательных систем                                               | Кирилл Хрыльченко Яндекс                             | Recsys |
| 10                                    | Масштабирование функций потерь для последовательных рекомендаций с большими ...       | Данил Гусак AIRI                                     | Recsys |
| 11                                    | Опыт трансформерной персонализации в Авито                                            | Александр Михеев Авито                               | Recsys |

Про трансформеры

# Тренды. RecSys topics

- Societal recommender systems
  - Adapting recommendation algorithms to suit different cultural contexts and multilingual users
  - Addressing global digital divides by exploring the design, development and deployment of systems for low-resource environments
  - Bias, fairness, bubbles, and ethics of recommender systems
  - Diversity and inclusion models
  - Eco-aware recommendation models
  - Ensuring equitable access to digital resources for understudied populations
  - Implications of recommendation algorithms when the main stakeholders are understudied populations
  - Recommendation models for sustainable tourism
  - Studying the effects of recommendation systems on cultural and global diversity lenses
  - Supporting understudied communities by elevating diverse and underrepresented content
  - Sustainable Recommender Systems Development
- Human-centered recommendation approaches
  - Adaptive algorithms that adjust recommendations dynamically based on user interactions
  - Explanation methods and interfaces for recommender systems
  - Human-in-the-loop model learning and validation
  - Innovative user interfaces for recommender systems
  - Novel interaction paradigms
  - Novel methods for improving the explainability of recommendation models
  - Novel methods for preference elicitation
  - Novel perspectives on the role of transparency in recommender systems
  - Studies that investigate how real-time events (e.g., trends and holidays) influence user preferences
  - User control of RecSys
  - User experiments and studies of recommendation applications
- Computational innovations, evaluation, and real-world applications
  - Building large-scale, standardized datasets for benchmarking algorithms
  - Case studies of real-world implementations
  - Conversational and natural language recommender systems
  - Cross-domain recommendation
  - Design of usability studies
  - Economic models and consequences of recommender systems
  - Generative models in recommender systems
  - Legal and regulatory aspects of recommender systems
  - Knowledge-based recommender systems
  - Multimodal approaches for recommendation
  - Multi-stakeholder recommendations
  - Novel evaluation metrics beyond accuracy
  - Privacy and security
  - Recommendation models for education and learning-related technologies
  - Studies that investigate the relationship between evaluation metrics and real-world outcomes
  - Tailoring recommendations for applications beyond e-commerce



The ACM Conference Series on  
**Recommender Systems**



# Тренды. SIGIR (A\* conf) topics



SIGIR 2025, Padua, 13-18 July \_ Ас...  
PDF

суммаризируй направления мысли ученых именно по рекомендательным системам - что нового? что исследуют?

В сборнике принятых статей на **SIGIR 2025** чётко прослеживаются ключевые направления мысли учёных в области рекомендательных систем. Вот краткое обобщение главных исследовательских векторов:

## 1. Интеграция больших языковых моделей (LLM)

- **LLM в рекомендациях:** работа над тем, как использовать LLM для генерации, объяснения и усиления рекомендаций (например, *"LLM-Empowered Creator Simulation"*, *"Multi-Interest Matching with LLMs"*).
- **Совмещение с Retrieval-Augmented Generation (RAG):** рекомендации становятся генеративными, с использованием внешней памяти или поиска (*"Retrieval-Augmented Generation with Collaborative Filtering"*, *"InstructRAG"*, *"Bridging Personalization and Control in Scientific Personalized Search"*).

## 2. Диффузионные и генеративные модели

- Много работ посвящено **diffusion-based** моделям, адаптированным под задачи рекомендаций, включая работу с мультимодальными входами, интересами пользователей и разнообразием рекомендаций.
  - Примеры: *"Diffusion-based Multi-modal Synergy"*, *"Intent-aware Diffusion with Contrastive Learning"*, *"Conditional Diffusion for Cross-Domain Recommendation"*.



## 3. Каузальный инжиниринг и контрфактуальные подходы

- Акцент на **каузальные** (причинно-следственные) методы для устранения bias в данных и улучшения обобщающей способности моделей.
  - Примеры: *"CSRec: Rethinking Sequential Recommendation from a Causal Perspective"*, *"Improving Sequential Recommenders through Counterfactual Augmentation"*, *"CoDIME: Counterfactual Approach for Dimension Importance Estimation"*.



## 4. Объяснимость, справедливость и устойчивость

- Работы над интерпретируемыми, справедливыми и устойчивыми рекомендательными системами:
  - *"Enhancing New-item Fairness"*, *"Can LLMs Enhance Fairness in Recommendation?"*, *"Refining Fidelity Metrics for Explainable Recommendations"*.



## 5. Последовательные, сессионные и продолжительные рекомендации

- Улучшение **моделирования пользовательских интересов во времени** (drift, контекст, и сессии).
  - Примеры: *"STAR-Rec"*, *"Towards Interest Drift-driven User Representation"*, *"Multi-Scenario Instance Embedding"*, *"Pre-train, Align, and Disentangle"*.



## 6. Мультимодальность и графовые методы

- Объединение **текста, изображений, графов**, аудио и видео для более богатых рекомендаций.
  - *"Hypercomplex Knowledge Graph-Aware Recommendation"*, *"COHESION: Composite GCN for Multimodal Recommendation"*, *"MSCRS: Multimodal Semantic Graph Prompt Learning"*.

# Тренды. Какие самые необычные новые области?

-  1. Eco-aware recommendation models
-  2. Recommendation models for sustainable tourism
-  3. Supporting understudied communities by elevating diverse and underrepresented content
-  4. Adapting recommendation algorithms to suit different cultural contexts and multilingual users
-  5. Generative models in recommender systems
-  6. Legal and regulatory aspects of recommender systems
-  7. Recommendation models for education and learning-related technologies



# Тренды. LLM as recommender

Порекомендуй мне города в России для путешествий.  
Последнее время я был в Москве, Санкт-Петербурге,  
Калининграде, Мурманске, Петрозаводске.

Мне нравится историческая архитектура, нежаркая погода,  
различные возможности для проведения времени, красивая  
природа, возможность поехать на велосипеде. Порекомендуй  
мне 10 направлений и объясни, почему



Отлично, у тебя уже довольно богатый список путешествий по северо-западу России! Судя по твоим предпочтениям — историческая архитектура, нежаркая погода, разнообразные активности, природа и возможность велопоездки — вот 10 направлений, которые, скорее всего, тебе подойдут:




## 1. Великий Новгород

Почему:


- Один из древнейших городов России, с уникальной архитектурой XII–XV веков (Софийский собор, Ярославово Дворище, Новгородский Кремль).
- Плоский рельеф — отлично для велопогулоков.
- Тихий, неспешный ритм, зелёные зоны и берег Ильменя.



# Тренды. LLM as recommender



Мне хочется прочитать книгу про историю Севера-Запада России, желательно до советского времени. Желательно исторические книги, а не художественные. Также хочется, чтобы книга была связана с какими-то местами, которые потом можно посетить



Вот подборка исторических книг о Северо-Западе России до советского времени, которые сочетают научный подход с описанием конкретных мест и достопримечательностей:



## Рекомендуемые книги

- Элькин Г.Н., Власов А.С. «Древнерусские города Северо-Запада»
  - Познакомит с древними городами Северо-Запада России, их историей, достопримечательностями, жизнью горожан и значимыми событиями, когда эти города играли ключевую роль в защите Отечества. В книге рассказывается о Новгороде, Пскове и других городах, сыгравших важную роль в становлении древнерусской государственности. Книга рассчитана на широкий круг читателей, но содержит много исторических фактов и описаний реальных мест, которые можно посетить и сегодня <sup>3</sup>.
- Аграрная история Северо-Запада России XVI века. Север. Псков. Общие итоги развития Северо-Запада / Под ред. А.Л. Шапиро
  - Книга подробно рассматривает сельские и городские поселения Северо-Запада России, включая Северную Двину, Каргопольский и Важский уезды, Лопские погосты, Псковскую землю. В ней анализируются крестьянские промыслы, торговля, ремесленные поселения, земельные наделы и социально-экономическое развитие региона в XVI веке. Много внимания уделено конкретным территориям и населенным пунктам, многие из которых сохранились до наших дней <sup>4</sup>.

## LLM vs обычный интерфейс



# Тренды. LLM as recommender (Яндекс Лавка)



Яндекс, кажется, одним из первых в РФ затащил что-то такое в прод

# Тренды. LLM as recommender (Яндекс Лавка)

Алиса

привет предложи мне какие нибудь товары из яндекс лавки на завтрак

Вот несколько товаров из Яндекс Лавки для завтрака:

- каша рисовая с персиковой сгущёнкой;
- сырники с малиной;
- блинчики «Цезарь»;
- оладушки «Домашние» от Мираторг;
- рисовая каша на молоке;
- вареники с творогом и сметаной;
- вареники с картофелем и грибами;
- блинчики с сулугуни и зеленью;
- вареники с вишней и сметаной.

добавь кашу рисовую и вареники блинчики и оладушки в корзину и заверши сбор в корзину

Добавила: “Рисовая каша на молоке Из Лавки”, 250 г за 209 рублей, “Блинчики С пылу с жару сгущёнка”, 360 г за 119 рублей и “Оладушки Домашние Мираторг”, 260 г за 189 рублей. Что ещё положим в корзину?



# LLMs for User Interest Exploration in Large-scale Recommendation Systems

Jianling Wang\*

Google DeepMind

[jianlingw@google.com](mailto:jianlingw@google.com)

Haokai Lu\*

Google DeepMind

[haokai@google.com](mailto:haokai@google.com)

Yifan Liu

Google

[yifanliu@google.com](mailto:yifanliu@google.com)

He Ma

Google

[htm@google.com](mailto:htm@google.com)

Yueqi Wang

Google

[yueqiw@google.com](mailto:yueqiw@google.com)

Yang Gu

Google

[greeness@google.com](mailto:greeness@google.com)

Shuzhou Zhang

Google

[shuzhouz@google.com](mailto:shuzhouz@google.com)

Ningren Han

Google

[peterhan@google.com](mailto:peterhan@google.com)

Shuchao Bi

Google

[shuchaobi@google.com](mailto:shuchaobi@google.com)

Lexi Baugher

Google

[baugher@google.com](mailto:baugher@google.com)

Ed H. Chi

Google DeepMind

[edchi@google.com](mailto:edchi@google.com)

Minmin Chen

Google DeepMind

[minminc@google.com](mailto:minminc@google.com)



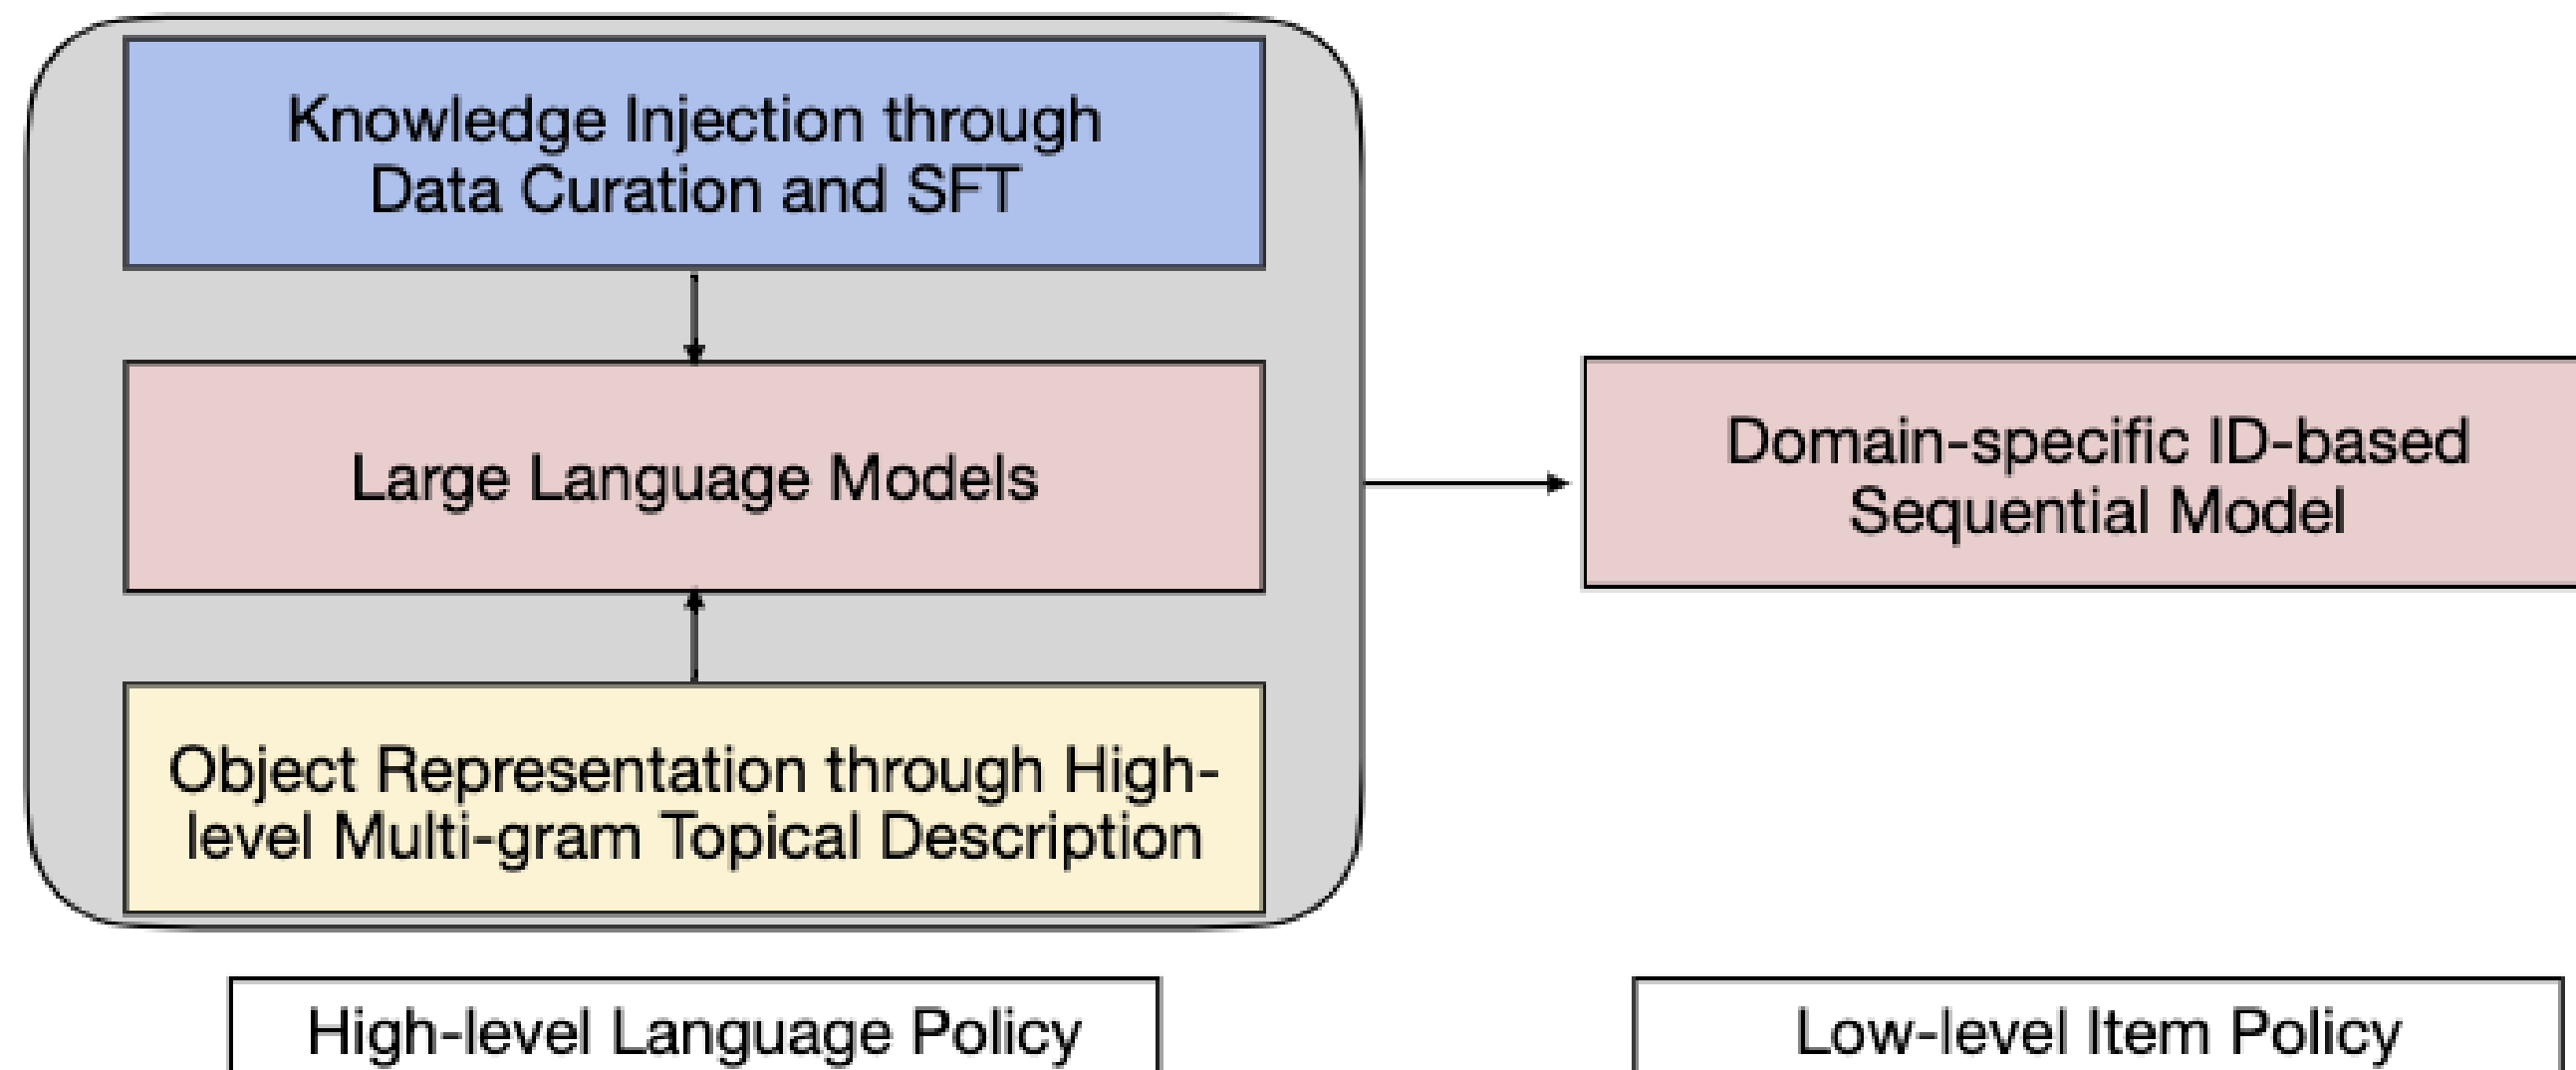
# LLM4Rec от Youtube Shorts

- Рекомендации не предсказывают новые интересы, а это важно!
- Это может сделать LLM

# В чем проблема LLM для industrial recsys?

- Не знают item corpus (500 часов контента в минуту)
- Не знают коллаборативные сигналы
- Latency/cost are large (100ms)

# LLM4Rec от Youtube Shorts. Что сделали?



**Figure 1: LLM-powered hybrid hierarchical planning diagram for user interest exploration.**

# LLM4Rec от Youtube Shorts. Что сделали?

## Prompt

The short-form videos I watched most recently are in the following clusters:

Cluster 1: {*Bus, Truck, Road, Commercial vehicle, Bus Simulator Indonesia, Om Telolet Om, Accident, Motor vehicle, Hino Motors, Tour bus service*}

Cluster 2: {*Coconut, Banana, Fruit, Durian, Fruit, Oil palms, Mango, Jackfruit, Durian, Papaya*}.

Each cluster is described with salient phrases or entity names. With less than 30 words, generate **a new and different short-form video cluster** I will watch next with highly specific salient phrases or entity names, with a prefix that says "New cluster: "


## Label

New cluster: Sharks, Underwater environment, Underwater diving, Dolphin, Orca, Mermaid, Penguins, Whale, Fish, Ocean


**Figure 2: Prompt for Novel Interest Prediction when  $K = 2$ .**



# Нужно выделить видео в 4-х уровневую кластеризацию



Кластер 1



Кластер 2

## LLM4Rec от Youtube Shorts. Что дальше?

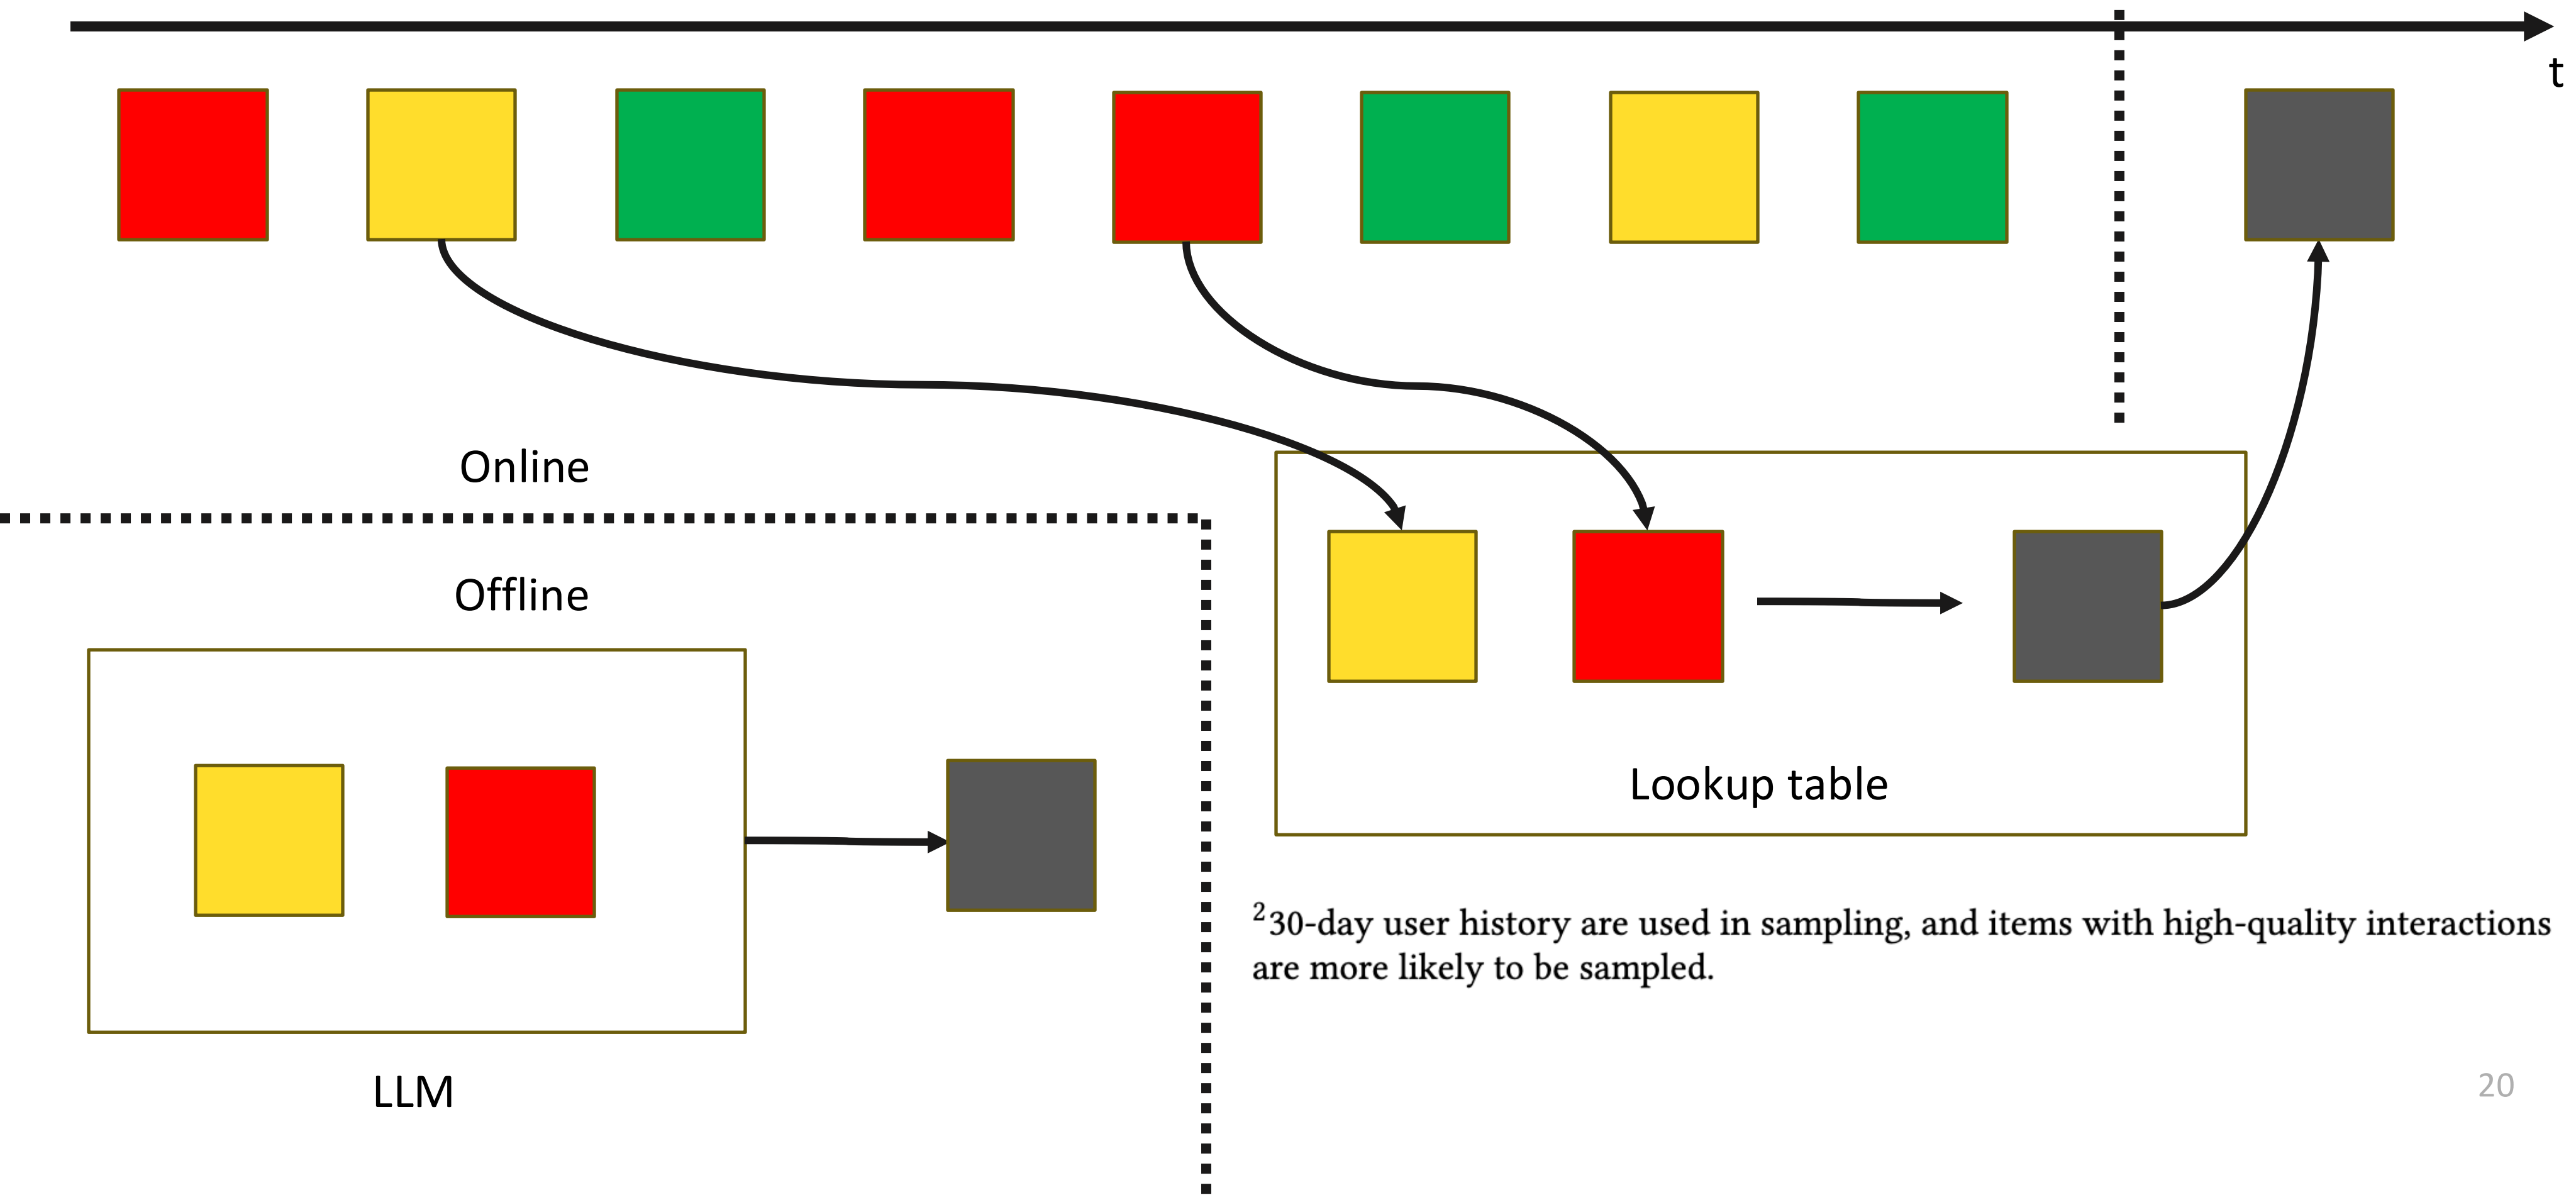
ance representation granularity and computation efficiency. In our experiment, the level-2 clustering produced 761 clusters. We can therefore enumerate all  $761 * 761 = 579,121$  cluster pairs and perform a batch inference with LLM to obtain novel interests for each cluster pair under just a few hours. These novel interests, together

# LLM4Rec от Youtube Shorts. Что дальше?

История пользователя

Сейчас

t



<sup>2</sup>30-day user history are used in sampling, and items with high-quality interactions are more likely to be sampled.

# LLM4Rec от Youtube Shorts. Как из кластера получить айтемы?

- Можно отправить запрос в поиск
- В поиске обычно немного персонализации 😊
- Давайте ограничим recsys на айтемы из этого кластера



# LLM4Rec от Youtube Shorts. Supervised fine-tuning (SFT)

$[(C_1, C_2), C_L]$  250K сэмплов  
качественных собрали

- 1) Интерес  $C_L$  успешно получен
- 2) Он точно отличен от  $C_1$  и  $C_2$


Дальше: берем топ-10 встречаемых пар  $C_1, C_2$  для каждого  $C_L$

Получили  $761 * 10$  сэмплов


# LLM4Rec on Youtube Shorts. Supervised fine-tuning (SFT)



# LLM4Rec on Youtube Shorts. Results




(b) Novelty (x-axis) and Quality (y-axis) Comparison




(c) Improvement of UCI@N

# LLM4Rec on Youtube Shorts. Results



(a) Overall Watch Time



(b) Number of Users watch  $\geq 10$ min

**Figure 5: The proposed method drives user growth.**



# LLM4Rec от Youtube Shorts. Выводы

- 1) Начали с малого применения LLM и смогли
- 2) Выиграли АБ тест
- 3) LLM не подвержено feedback loop, привнесла новые знания
- 4) LLM применили в оффлайне

# Тренды. А что нынче по соревнованиям?

June 3

**RecSys Community**

Команда Сбера обошла всех и забрала кубок Авито! 🏆

Наша команда рекомендательных систем одержала победу в Avito ML Cup 2025 по задаче «Персональные рекомендации» и доказала, что лучшая в рекомендациях. Поздравляем с триумфальной победой! 🎉

▶ Вот почему эта победа заслуживает особого внимания:


- ✅ **Победители среди лучших:**  
Команду возглавляли Владислав Костоглодов и Григорий Вязников, уверенно занявшие лидирующую позицию в соревнованиях, обогнав более 300 команд и свыше 1500 участников.
- ✅ **Инновационные методы:**  
В решении команда использовала передовые (SOTA) подходы:
  - **EASE-DAN:** Свежая и мощная версия линейного автоэнкодера для извлечения коллаборативного сигнала.
  - **SASRec (RePlay):** Для извлечения позиционного сигнала последовательностей действий.
  - **Экспериментальный лосс Barlow Twins:** Примененный к SASRec, этот новый подход, который в этом году проходит ревью на самой главной конференции в мире по рекомендательным системам – ACM RecSys 2025, и помог улучшить результаты.
- ✅ **Выходящие за рамки задачи:**  
Ключевым вызовом было определение **наиболее релевантных новых товарных категорий** для каждого пользователя (тех, с которыми он раньше не сталкивался!), основываясь на его прошлых действиях и метаданных. Команда изобрела уникальное решение в учете персонализированных рекомендаций товаров и блестяще справились именно с этой задачей!

Развитие существующих идей

+ бустинг реранкер

из фичей классические user-item  
и item статистики + скоры и  
ранги из EASE/SASRec

# Тренды. Про recsys интерфейсы



Google Scholar

short video recommendation



Articles

About 2,510,000 results (0.17 sec)

Any time

Since 2025

Since 2024

Since 2021

Custom range...

**Real-time short video recommendation on mobile devices**

X Gong, Q Feng, Y Zhang, J Qin, W Ding, B Li... - Proceedings of the 31st ..., 2022 - dl.acm.org

... • We present an edge-side re-ranking solution for **short-video recommendation** to leverage valuable real-time signals only available on mobile devices and overcome intrinsic limitations ...

☆ Save Cite Cited by 58 Related articles All 5 versions

[PDF] arxiv.org



# Тренды. Персональный контент

нарисуй мне картину. Мне нравятся реалистичные картины с пейзажем севера России (сосны, озера, тундра, закат, сопки)



Изображение создано




< 1/2 >

## Leading Platforms for Personalized Music Generation

- **Murkeka**
  - Allows users to train personalized AI models with their own uploaded music, ensuring generated tracks match their unique style and taste.
  - Offers multiple input methods: text descriptions, reference tracks, vocals, or recorded melodies.
  - Provides granular editing tools and song extension features.
  - Suitable for both consumers and developers via API integration <sup>1</sup>.



## История пользователя



Представим историю пользователя в виде троек (**context**, **item**, **feedback**):

- Контекст  $c_t$  — время дня, устройство, настройки моей волны
- Айтем  $i_t$  — объект рекомендации; музыкальный трек, его жанр, исполнители, мета-информация, эмбединги
- Фидбек  $f_t$  — реакция пользователя в ответ на рекомендацию: дослушал, лайкнул, скипнул



# Тренды. Про ARGUS от Яндекса


## SASRec

Next Item  
Prediction




$P(\text{item} \mid \text{history, positive feedback})$

## ARGUS



Next Item  
Prediction

Feedback  
Prediction




- $P(\text{item} \mid \text{history, context})$
- $P(\text{positive feedback} \mid \text{history, context, item})$

# Тренды. Про ARGUS от Яндекса

| Энкодер |              |           | Предобучение         |                     |                 |
|---------|--------------|-----------|----------------------|---------------------|-----------------|
| Модель  | Конфигурация | Параметры | Next Item Prediction | Feedback Prediction |                 |
|         |              |           |                      | Consumption         | Engagement      |
| Mini    | L4 H256      | 3.2M      | 0.4777 (-0.00%)      | 0.5830 (-0.00%)     | 0.5855 (-0.00%) |
| Small   | L6 H512      | 18.9M     | 0.4691 (-3.81%)      | 0.5756 (-1.28%)     | 0.5707 (-2.51%) |
| Medium  | L10 H1024    | 126.0M    | 0.4502 (-7.68%)      | 0.5690 (-2.41%)     | 0.5556 (-5.10%) |
| Large   | L20 H2048    | 1.007B    | 0.4372 (-10.36%)     | 0.5631 (-3.43%)     | 0.5436 (-7.15%) |

# Тренды. Про ARGUS от Яндекса и масштабируемость



## Результаты A/B

| Внедрение          | Длина истории | Конфигурация | Параметры | TLT    | Like Likelihood |
|--------------------|---------------|--------------|-----------|--------|-----------------|
| Offline V1         | 512           | L6 H512      | 18.9M     | +0.52% | +1.11%          |
| Offline V2         | 1024          | L6 H512      | 18.9M     | +1.00% | +0.73%          |
| Offline V3         | 1024          | L6 H512      | 18.9M     | +0.73% | +5.00%          |
| Real-time V1       | 1024          | L4 H256      | 3.2M      | +0.32% | +1.38%          |
| Offline V4 (ARGUS) | 8192          | L10 H1024    | 126.0M    | +2.26% | +6.37%          |

Окупается ли такое масштабирование?

Если доп. доход – затраты на обучение < 0 → будут ли это делать?

# Тренды. Про uplift модели

| Кейс\Вариант аплифта<br>от показа в<br>рекомендациях | Отрицательный                        | Нейтральный                                                                               | Позитивный       |
|------------------------------------------------------|--------------------------------------|-------------------------------------------------------------------------------------------|------------------|
| Скрол ленты<br>рекомендаций для<br>компании          | Почти невероятный                    | Бесполезный или мало<br>полезный продукт или<br>его часть                                 | Целевой сценарий |
| Реклама товара для<br>рекламодателя                  | Ужасный вариант для<br>рекламодателя | Бесполезно<br>заплаченные деньги                                                          | Целевой сценарий |
| Скрол ленты<br>рекомендаций для<br>юзера             | Низкая репутация у<br>рекомендаций   | Бесполезная трата<br>времени + либо<br>сокращение времени<br>(например. сбора<br>корзины) | Ценность recsys  |

$$\tau_{u,i} = Y_{u,i}^1 - Y_{u,i}^0$$



# Тренды. Про баланс между размером и скоростью

Масштабирование



Скорость учета  
событий  
(онлайнизация)



# ТГ Каналы по RecSys



Рекомендации, Поиск и Путе...

907 subscribers



#recommender\_systems

1 315 members



[t.me/ods\\_recommender\\_systems](https://t.me/ods_recommender_systems)

Link



RecSys Community

365 subscribers



WildRecSys

1 529 subscribers



Персонализация неизбежна

953 subscribers



Рекомендательная [RecSys Ch...

2 056 subscribers



Wazowski Recommends

2 026 subscribers



Information Retriever

2 886 subscribers



Рисерчошная

2 064 subscribers